

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ  
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ  
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ  
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»  
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК

Лемехова Ольга Александровна

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Исследование методов эффективного применения адаптеров (LoRA)  
для дообучения моделей в условиях ограниченных вычислительных ресурсов

Research on the effective use of adapters (LoRA)  
for fine-tuning models under limited computational resources

по направлению 01.04.02 Прикладная математика и информатика  
образовательная программа «Аналитика больших данных»

Студент

---

О.А. Лемехова

Научный руководитель

---

старший преподаватель  
факультета компьютерных наук НИУ ВШЭ  
Е.А. Паточенко

Соруководитель

---

Ведущий специалист по науке о данных  
ООО Ле Монлид Цифровые Технологии  
Е.В. Гаврилова

Москва 2026

# ОГЛАВЛЕНИЕ

|                                                                                     |    |
|-------------------------------------------------------------------------------------|----|
| Аннотация .....                                                                     | 4  |
| Глава 1. Введение .....                                                             | 5  |
| 1.1. Актуальность исследования .....                                                | 5  |
| 1.2. Цель и задачи исследования .....                                               | 6  |
| 1.3. Объект и предмет исследования .....                                            | 7  |
| 1.4. Научная новизна .....                                                          | 7  |
| 1.5. Практическая значимость .....                                                  | 8  |
| Глава 2. Обзор литературы и теоретические основы .....                              | 9  |
| 2.1. Проблема дообучения LLM в условиях ограниченных ресурсов .....                 | 9  |
| 2.2. Parameter-Efficient Fine-Tuning (PEFT) .....                                   | 9  |
| 2.3. Метод LoRA и его развитие .....                                                | 9  |
| 2.4. Совместное применение LoRA и квантизации .....                                 | 10 |
| 2.5. Геометрические и структурные расширения LoRA .....                             | 10 |
| 2.6. Выводы .....                                                                   | 10 |
| Глава 3. Описание и подготовка набора данных .....                                  | 12 |
| 3.1. Описание и источники данных .....                                              | 12 |
| 3.2. Сбор, очистка и предобработка данных .....                                     | 13 |
| 3.3. Формирование обучающих выборок .....                                           | 14 |
| Глава 4. Описание методологии эксперимента .....                                    | 15 |
| 4.1. Open-source библиотеки для дообучения LLM .....                                | 15 |
| 4.2. Подходы к дообучению .....                                                     | 15 |
| 4.3. Метрики для оценки .....                                                       | 16 |
| 4.4. Ограничения экспериментов .....                                                | 17 |
| 4.5. Постановка NLP-задачи .....                                                    | 18 |
| 4.6. Выбор базовой языковой модели .....                                            | 19 |
| 4.7. Предобработка данных .....                                                     | 20 |
| Глава 5. Построение базовой модели .....                                            | 21 |
| 5.1. Конфигурация .....                                                             | 21 |
| 5.2. Результаты базовой конфигурации .....                                          | 21 |
| Глава 6. Дообучение языковой модели с использованием LoRA, QLoRA и OrthoGeoLoRA ... | 23 |
| 6.1. Исследуемые параметры LoRA .....                                               | 23 |
| 6.2. Интеграция базового PEFT метода - LoRA в архитектуру модели .....              | 24 |
| 6.3. Метод квантизации - QLoRA .....                                                | 24 |

|                                                                                                                            |    |
|----------------------------------------------------------------------------------------------------------------------------|----|
| 6.4. Геометрическая модификация – OrthoGeoLoRA.....                                                                        | 25 |
| 6.5. Экспериментальная схема обучения .....                                                                                | 27 |
| Глава 7. Анализ результатов. Выявленные зависимости и закономерности. ....                                                 | 28 |
| 7.1. Методология анализа и статистические методы .....                                                                     | 28 |
| 7.2. Анализ результатов .....                                                                                              | 29 |
| 7.2.1. Оценка влияния факторов на качество модели.....                                                                     | 29 |
| 7.2.2. Сравнение моделей .....                                                                                             | 30 |
| 7.2.3. Исследование влияния ранга LoRA на качество адаптации.....                                                          | 32 |
| 7.2.4. Расширение target modules. Сравнение: $q+v$ , $q+k+v$ , $q+k+v+o$ .....                                             | 33 |
| 7.2.5. Совместное влияние ранга и набора модулей на потребление времени и памяти.....                                      | 35 |
| 7.2.6. QLoRA vs LoRA .....                                                                                                 | 36 |
| 7.2.7. FP4 vs NF4 .....                                                                                                    | 38 |
| 7.2.8. Baseline.....                                                                                                       | 38 |
| 7.2.9. Влияние качества набора данных (RU vs EN).....                                                                      | 39 |
| 7.2.10. Метод OrthoGeoLoRA (OGLoRA).....                                                                                   | 39 |
| 7.3. Выявленные зависимости и закономерности .....                                                                         | 42 |
| 7.4. Выбор оптимальных конфигураций .....                                                                                  | 43 |
| 8. Заключение .....                                                                                                        | 47 |
| Список литературы .....                                                                                                    | 49 |
| Приложения .....                                                                                                           | 52 |
| Приложение А. Ссылка на GitHub, где расположены исходники всего проекта, включая код. Описание структуры репозитория. .... | 53 |
| Приложение Б. Скрипты парсинга новостных заголовков на русском языке.....                                                  | 54 |
| Приложение В. Обработанные данные после парсинга новостных заголовков на русском языке .....                               | 55 |
| Приложение Г. Реализация базового метода .....                                                                             | 56 |
| Приложение Д. Реализация метода LoRA.....                                                                                  | 57 |
| Приложение Е. Реализация метода QLoRA .....                                                                                | 58 |
| Приложение Ж. Реализация метода OrthoGeoLoRA.....                                                                          | 59 |
| Приложение З. Результаты всех экспериментов .....                                                                          | 60 |

## Аннотация

Работа посвящена исследованию влияния параметров PEFT-методов (ранг, набор модулей, тип квантизации) семейства LoRA на качество и вычислительную эффективность языковых моделей в задачах классификации коротких текстов в условиях ограниченной инфраструктуры (время, память, объем выборки). Исследование не претендует на всеохватный обзор PEFT-методов, а фокусируется на трёх показательных: LoRA, QLoRA и OrthoGeoLoRA.

В качестве экспериментальной среды использована задача классификации новостных заголовков на английском и русском языках. Для английского языка использовался эталонный датасет AG News, для русского - самостоятельно собранный корпус. Эксперименты проводились на разномасштабных моделях Qwen2.5-1.5B и Qwen3-0.6B. Реализация метода OrthoGeoLoRA была выполнена самостоятельно на основе теоретического описания ввиду отсутствия открытой реализации. Всего проведено 934 эксперимента с варьированием ранга адаптеров (4, 8, 16, 32), набора модулей ( $q+v$ ,  $q+k+v$ ,  $q+k+v+o$ ), типа квантизации (NF4, FP4) и объёма обучающей выборки (от 300 до 30000 образцов в каждом классе).

В работе выполнен многокритериальный анализ качества моделей (accuracy, F1-score) и вычислительных затрат (время обучения, потребление GPU-памяти). Установлено, что объём обучающей выборки является основным фактором, влияющим на качество моделей и время обучения. Определён порог в 1500 образцов на класс, начиная с которого различия между методами по качеству становятся минимальными. Конфигурация  $q+v$  обеспечивает наилучшее соотношение качества и вычислительных затрат, тогда как максимальное качество достигается при использовании  $q+k+v+o$ . Набор адаптируемых модулей влияет на время обучения и потребление GPU-памяти значительно сильнее, чем увеличение rank. Также выявлен эффект убывающей отдачи: для больших выборок плато качества достигается уже при  $\text{rank}=4-8$ , тогда как для малых данных требуется  $\text{rank}=32$ . Влияние rank и набора модулей на потребление GPU-памяти и времени носит преимущественно аддитивный характер.

Эксперименты показали различия между моделями разных масштабов и поколений. Qwen2.5-1.5B обеспечивает более высокое качество при достаточном объёме данных, Qwen3-0.6B демонстрирует более стабильное обучение и меньшее потребление памяти. На малых выборках конфигурация Qwen3-0.6B + OrthoGeoLoRA показывает высокую эффективность по соотношению качество/GPU, однако требует большего времени обучения.

Полученные результаты позволяют сформулировать практические рекомендации по выбору конфигураций PEFT-методов, обеспечивающих оптимальный компромисс между качеством модели и вычислительными затратами без необходимости полного перебора параметров.

# Глава 1. Введение

## 1.1. Актуальность исследования

С каждым годом большие языковые модели (LLM) показывают все большую эффективность в области обработки естественного языка, включая генерацию, суммаризацию и классификацию текста. Однако, использование LLM ограничено в условиях лимитированной инфраструктуры (одиночные GPU, локальные машины, исследовательские среды). В последнее время, можно наблюдать внедрение компактных моделей (0.5-7 млрд параметров), например семейства Qwen [21]. Их применение более доступно. Однако, применение даже таких моделей зависит от располагаемых вычислительных ресурсов.

Т.к. полное дообучение все еще требует больших объёмов видеопамяти (VRAM), времени и вычислительных мощностей, в практике распространены параметрически эффективные методы дообучения (PEFT - parameter-efficient fine-tuning), среди которых одно из популярных – LoRA (Low-Rank Adaptation) и ее вариаций, направленных на экономию ресурсов и достижение конкурентного качества, их число растёт каждый год [2]. Такие подходы позволяют снизить вычислительные затраты за счет того, что обновляют только небольшую часть обучаемых параметров модели, но в итоге выдают конкурентное качество.

Эффективность методов PEFT зависят от выбираемых параметров, таких как ранг адаптеров (rank), выбор модулей (target modules), тип квантизации, объём данных, язык обучающей выборки и т.д. В существующих работах часто данные параметры рассматриваются изолированно, либо в ограниченных сценариях [19]. Отмечается недостаток исследований, направленных на разработку конфигураций, адаптированных под конкретные задачи и условия применения [18]. В отсутствие конкретных рекомендаций часто подбор параметров в практических работах осуществляется методом проб и ошибок [17], что требует проведения большого количества экспериментов для нахождения оптимальных значений [18].

Также, в литературе наблюдается недостаточное количество исследований, направленных на комплексный анализ влияния этих факторов в совокупности, в частности, в контексте задач классификации коротких текстов в условиях ограниченных ресурсов [19]. Так, я не обнаружила систематизированные рекомендации по выбору конфигураций для LoRA и ее модификаций, таких, чтобы обеспечивали оптимальный компромисс между качеством модели и затратами ресурсов (время обучения, потребление GPU-памяти). В литературе в основном проводится сравнительный анализ методов LoRA без особого внимания к их настройкам и вариантам ограниченности исходных данных [20].

Таким образом, актуальность данного исследования можно обосновать:

1. необходимостью экономии вычислительных затрат при дообучении языковых моделей;
2. отсутствием практических рекомендаций по выбору конфигураций LoRA и ее модификаций (в частности для задач классификации текстов);
3. отсутствием комплексного анализа влияния параметров PEFT-методов на качество и эффективность.

## 1.2. Цель и задачи исследования

Целью работы является исследование влияния параметров LoRA-методов на качество и вычислительную эффективность языковых моделей в задачах классификации коротких текстов при ограниченных вычислительных ресурсах в условиях ограниченной инфраструктуры.

Таким образом, основной задачей стоит исследование влияния ранга, набора модулей и размера данных; выявление закономерностей и поиск компромисса между точностью и ресурсными затратами.

Таким образом, решаемая задача является многокритериальной, т.е. для каждой конфигурации из спектра параметров (ранг, набор адаптируемых модулей, тип квантизации, объём данных) необходимо оценить одновременно и показатели качества (ассигасу, F1) и ресурсоёмкость (VRAM, время обучения). При этом задача классификации текста в данной работе выступает своего рода бенчмарком, т.е. управляемой экспериментальной средой, которая позволяет получить воспроизводимые эксперименты и сопоставимые результаты по всем вариантам конфигураций.

Для реализации поставленных задач предусматривается выполнение следующих шагов:

1. Провести анализ современных PEFT-методов.
2. Изучить особенности применения методов LoRA выбрать несколько для исследования.
3. Подготовить экспериментальную среду и датасеты (англоязычный, русскоязычный).
4. Реализовать baseline-подход и выбранные методы дообучения (LoRA, QLoRA, OrthoGeoLoRA) для задач классификации текстов.
5. Провести серию экспериментов на различных предобученных моделях разного размера (Qwen2.5-1.5B и Qwen3-0.6B) с варьированием параметров: rank (4, 8, 16, 32), набора модулей (qkv, qkv, qkvo), типа квантизации (nf4, fp4), объёма обучающей выборки.
6. Оценить влияние параметров конфигурации на показатели качества (ассигасу, F1).
7. Проанализировать вычислительные затраты (время обучения, потребление GPU-памяти).
8. Исследовать зависимости и выявить закономерности между параметрами модели, качеством и ресурсами.

9. Оценить баланс между качеством и вычислительными затратами для каждого метода и конфигурации.
10. Определить конфигурации, обеспечивающие лучший компромисс между качеством и ресурсоёмкостью, и сформулировать практические рекомендации.

### 1.3. Объект и предмет исследования

Объект - закономерности и компромисс между качеством классификации и вычислительными ресурсами при использовании методов LoRA, QLoRA и их модификаций.

Предмет - зависимости между параметрами методов параметрически эффективного дообучения (rank, набор адаптируемых модулей, тип квантизации, объём данных) и показателями качества модели и вычислительных затрат.

### 1.4. Научная новизна

Научная новизна работы заключается в следующем:

1. В работе проведен многокритериальный анализ пространства конфигураций LoRA, QLoRA и OrthoGeoLoRA для моделей семейства Qwen разного размера (0.6B и 1.5B), а именно проведена совместная оценка по четырём осям (rank, набор модулей, тип квантизации, объём данных) с одновременным измерением качества и ресурсоёмкости.
2. Показано, при каких значениях ранга дальнейшее увеличение качества модели перестаёт давать значимый прирост точности при продолжающемся росте потребления VRAM, а также выявлено различное влияние rank при разном объеме данных на разных моделях.
3. Проведен анализ взаимодействия факторов (ранг и объём обучающих данных, набор модулей и ресурсы, и т.д.), позволяющий выявить эффективные конфигурации.
4. В сравнительный анализ включена новая вариация LoRA - OrthoGeoLoRA [Wang et al., 2026].
5. Проведено исследование влияния объёма обучающих данных на эффективность PEFT для русского и английского языков в условиях одного GPU. Определен порог объёма данных, начиная с которого различия в эффективности конфигураций LoRA становятся несущественными, а влияние PEFT меняется.
6. Установлены различия в поведении моделей разных архитектур и масштабов (Qwen2.5 vs Qwen3), которые заключаются в разной чувствительности к параметрам PEFT и объёму исходных данных.
7. Выявлены зависимости между точностью, потреблением VRAM и временем обучения.
8. Сформулированы практические рекомендации по выбору конфигураций PEFT в условиях ограниченных вычислительных ресурсов, в том числе если в распоряжении слишком малая выборка для обучения, для задач классификации коротких текстов.

## 1.5. Практическая значимость

Разработанный подход может использоваться для быстрой классификации текста на основе LLM при ограниченных вычислительных ресурсах, например, классификация в новостных агрегаторах, для задач классификации обращений в поддержку или в государственные органы и т.п.).

Результаты позволяют осознанно выбирать модель, ранг, набор модулей и метод квантизации без полного перебора конфигураций на основе имеющихся данных.

Выявленные зависимости от объёма данных помогают оценить минимально достаточную выборку либо выбрать подход работы с уже имеющимися данными ограниченного объема.

Реализованные эксперименты могут служить бенчмарком для сравнения будущих PEFT-методов, включая OrthoGeoLoRA.



## Глава 2. Обзор литературы и теоретические основы

### 2.1. Проблема дообучения LLM в условиях ограниченных ресурсов

Основные проблемы дообучения LLM в условиях ограниченных ресурсов - это высокие требования к видеопамяти, длительное время обучения и значительные затраты на хранение моделей при дообучении LLM в условиях ограниченных ресурсов (например, одной GPU).

### 2.2. Parameter-Efficient Fine-Tuning (PEFT)

Существующие методы дообучения (PEFT) позволяют адаптировать модели за счёт обучения лишь небольшой части параметров, что снижает требования к памяти и вычислениям, ускоряет обучение и упрощает воспроизводимость экспериментов. Среди различных подходов PEFT наибольшее практическое распространение получили методы, основанные на низкоранговой параметризации обновлений весов, прежде всего - семейство LoRA [1].

### 2.3. Метод LoRA и его развитие

Метод Low-Rank Adaptation (LoRA) является одним из наиболее эффективных и широко используемых подходов PEFT. Его ключевая идея заключается в представлении обновлений весов в виде произведения двух матриц малого ранга ( $\Delta W = BA^T$ ), при этом исходные веса модели остаются замороженными [2]. LoRA обеспечивает значительное сокращение числа обучаемых параметров, тем самым снижая требования к памяти и обеспечивает качество, сопоставимое с полным дообучением. LoRA применяется к слоям внимания трансформера (например, проекциям  $q$ ,  $k$ ,  $v$ ,  $o$ ), однако его эффективность зависит от выбора параметров.

На базе LoRA сформировалось активное направление исследований, направленное на улучшение эффективности и адаптивности этого метода, среди которых:

QLoRA, L4Q, CoA-LoRA - LoRA сочетается с 4-битной квантизацией весов, что позволяет дообучать крупные модели затрачивая меньше памяти и сохраняя уровень качества [1][13][14][15].

AdaLoRA, DoRA, GLoRA - вводят адаптивное распределение ранга и более гибкую параметризацию обновлений [3].

ARD-LoRA и GeLoRA - предлагают динамическое или теоретически обоснованное распределение ранга между слоями и головами внимания [4][5].

LoRA Soups - исследуют объединение нескольких LoRA-адаптеров для формирования мультизадачных моделей и т.д. [6]

OrthoGeoLoRA - вводит геометрические ограничения на параметры адаптеров (2026) [7].

Выборочное применение LoRA (например, метод Aletheia (2026)). Вместо того чтобы добавлять адаптеры во все слои модели, этот метод анализирует, какие слои наиболее важны для конкретной задачи, и дообучает только их [26] и т.д.

Таким образом, LoRA стал базовой архитектурой, вокруг которой формируется широкая система методов, направленных на повышение эффективности использования параметров.

## 2.4. Совместное применение LoRA и квантизации

Даже при использовании LoRA основная модель остаётся ресурсоёмкой. Поэтому важным направлением является сочетание LoRA с квантизацией.

Ключевой метод в этом направлении - QLoRA квантует веса модели до 4 бит (например NF4, FP4), обучает только LoRA-адаптеры и позволяет дообучать модели на одной GPU [1][13].

## 2.5. Геометрические и структурные расширения LoRA

Одним из современных направлений развития является метод OrthoGeoLoRA (Orthogonal Geometric Low-Rank Adaptation), который вводит геометрические ограничения на параметры адаптеров [Wang et al., 2026] [7]. В отличие от стандартного LoRA ( $\Delta W = BA^T$ ), он использует разложение вида:  $\Delta W = B\Sigma A^T$ , где матрицы имеют ортонормированные столбцы.

Преимущества подхода состоит в более стабильной оптимизации, предотвращении коллапса ранга, более эффективном использовании параметров, улучшенном качестве без увеличения вычислительных затрат [7].

Данный подход показывает, что дальнейшее развитие LoRA связано не только с выбором ранга и квантизации, но и с геометрией параметрического пространства.

## 2.6. Выводы

Большинство современных исследований в части формирования новых методов LoRA сосредоточено на решении задач экономии ресурсов и их число продолжает расти, а интерес к поиску наиболее эффективных настроек не иссякает. Остается еще ряд вопросов, которые могут быть изучены, такие как выбор оптимального ранга, чувствительность слоёв модели, неочевидная деградация качества при более «мощных» параметрах, влияние квантизации на стабильность обучения, зависимость эффективности от объёма данных, отсутствие практических рекомендаций для разных языков, в том числе для русского.

Систематических сравнительных исследований, объединяющих все перечисленные факторы, в литературе не обнаружена, а именно к задаче классификации коротких текстов для разных языков в условиях ограниченных ресурсов. Обзорные исследования в основном проводятся на качественных англоязычных корпусах и не учитывают специфику

морфологически богатых языков (русский, немецкий, финский) , а также данных, используемых в практических задачах.

LoRA является центральным методом *parameter-efficient fine-tuning* и фактически стандартом для дообучения языковых моделей в условиях ограниченных ресурсов. Вокруг него сформировалось активное исследовательское направление, включающее адаптивные, геометрические и квантизационные расширения. Наиболее практичными на сегодняшний день являются комбинации LoRA и QLoRA, обеспечивающие хороший баланс между качеством и вычислительными затратами, а также различные новые методы, повышающие эффективность параметризации.

В рамках данной работы не ставится задача охватить все существующие модификации PEFT. Для исследования выбраны принципиально отличающиеся друг от друга методы: базовый метод LoRA, его квантованная версия QLoRA и современная ортогональная (геометрическая) модификация - OrthoGeoLoRA. Такой выбор позволил системно изучить влияние ключевых параметров (ранга, состава модулей и объёма данных) на баланс между вычислительными затратами и качеством модели. Расширение числа рассматриваемых методов привело бы к смещению акцента в сторону бенчмаркинга, что не соответствовало бы цели углублённого анализа зависимостей, заявленной в настоящем исследовании.

Далее в работе основное внимание будет уделено экспериментальному анализу эффективности применения LoRA и его вариантов при дообучении разных моделей семейства Qwen для задач классификации текста (EN, RU). Будут рассмотрены различные значения ранга (4, 8, 16, 32), конфигурации адаптации ( $q+v$ ,  $q+k+v$ ,  $q+k+v+o$ ), методы LoRA, QLoRA (NF4, FP4) и OrthoGeoLoRA, а также влияние объёма обучающей выборки на качество при различных конфигурациях параметров.

## Глава 3. Описание и подготовка набора данных

### 3.1. Описание и источники данных

Работа проводилась на двух вариантах данных:

1) **Эталонный набор данных - AG\_News – английский язык:** набор данных AG по классификации новостных тем на английском языке (Версия 3, 09.09.2015)

#### ИСТОЧНИК

AG - это коллекция из новостных статей. Новостные статьи были собраны ComeToMyHead из более чем 2000 источников за более чем год работы. ComeToMyHead - это академическая поисковая система новостей, работающая с июля 2004 года. Набор данных предоставляется академическим сообществом для исследовательских целей в области интеллектуального анализа данных (кластеризация, классификация и т. д.), поиска информации (ранжирование, поиск и т. д.), XML, сжатия данных, потоковой передачи данных и любой другой некоммерческой деятельности.

Набор данных для классификации новостных тем, созданный AG, разработан Сян Чжаном. Он используется в качестве эталонного набора данных для классификации текста в следующей статье: Xiang Zhang, Junbo Zhao, Yann LeCun. Character-level Convolutional Networks for Text Classification. Advances in Neural Information Processing Systems 28 (NIPS 2015) [16].

#### ОПИСАНИЕ

Набор данных для классификации новостных тем формируется путем выбора 4 крупнейших классов из исходного корпуса. Каждый класс содержит 30 000 обучающих и 1900 тестовых образцов. Классы строго сбалансированы. Общее количество обучающих образцов составляет 120 000, а тестовых - 7600.

Файл classes.txt содержит список классов, соответствующих каждой метке. Файлы train.csv и test.csv содержат все обучающие выборки в виде значений, разделенных запятыми [16].




Рисунок 1. Распределение длины текста в датасете AG\_News (EN)

## 2) Самостоятельно собранные данные (далее – PD\_News от parsed data news) – заголовки новостных статей русскоязычных сайтов.

### ИСТОЧНИК

Данные были собраны самостоятельно с русскоязычных новостных сайтов Санкт-Петербурга fontanka.ru («Фонтанка») и dp.ru («Деловой Петербург») с помощью библиотек Selenium и BeautifulSoup (приложение Б). Полученные данные приведены в Приложении В.

### ОПИСАНИЕ

Представляют собой набор заголовков новостных статей по четырем темам: Спорт, Недвижимость, Финансы, Авто. В итоге формируется набор данных, разбитый на 4 класса (sport, realty, finances, auto). В каждом классе по 10265 образцов. Классы сбалансированные. Общее количество образцов составляет - 41060, что соответствует 34,2% от количества образцов эталонного набора данных.




Рисунок 2. Распределение длины текста в датасете PD\_News (RU)

## 3.2. Сбор, очистка и предобработка данных

Данные AG\_News – эталонные, не требующие дополнительной очистки или обработки.

Данные PD\_News были предобработаны и очищены: удалены повторяющиеся заголовки, лишние символы и «мусор», удалены технические наименования, наименования подразбук и авторы статей, например «Александр Исаев. Страхование.», «Надежда Кузнецова. Налоги.» или «(фото, видео)» и т.п. Предобработка данных представлена в ноутбуке, расположенном по адресу [https://github.com/Lemekhova/msc-lemekhova/tree/main/«Анализ и гипотезы»/Notebooks/data\\_preprocessing.ipynb](https://github.com/Lemekhova/msc-lemekhova/tree/main/«Анализ и гипотезы»/Notebooks/data_preprocessing.ipynb) (Приложение А). Полученные в ходе парсинга и обработки данные представлены в Приложении В.

Следует отметить, что в среднем длина заголовков русскоязычных данных короче, чем англоязычных (Рисунки 1 и 2), в связи с этим, в том числе, могут быть связаны некоторые различия в поведении метрик.

### 3.3. Формирование обучающих выборок

Данные AG\_News уже имеют разбивку на тренировочную и тестовую выборки в размере 30 000 и 1 900 заголовков в каждом классе соответственно. Общее количество обучающих образцов – 120 000, а тестовых - 7600.

Для данных PD\_News с помощью функции `train_test_split` библиотеки *sklearn* в каждом классе было сформировано 8212 обучающих и 2053 тестовых образцов (деление 80/20%). Обучающая выборка составляет 27% от обучающей выборки AG\_News. Общее количество обучающих образцов составляет 32848, а тестовых - 8212.

Размеры обучающих выборок для экспериментов:

Эксперименты на подвыборках датасета AG\_News - EN:

- 1% (1 200 заголовков, по 300 в каждой категории)
- 5% (6 000 заголовков, по 1 500 в каждой категории)
- 10% (12 000 заголовков, по 3 000 в каждой категории)
- 27% (32 000 заголовков, по 8 000 в каждой категории)
- 50% (60 000 заголовков, по 15 000 в каждой категории)
- 100% (120 000 заголовков, по 30 000 в каждой категории)

Эксперименты на подвыборках самостоятельно собранного датасета PD\_News - RU:

- 3,6% (1 200 заголовков, по 300 в каждой категории) – 1% AG\_News
- 18% (6 000 заголовков, по 1 500 в каждой категории) – 5% AG\_News
- 37% (12 000 заголовков, по 3 000 в каждой категории) – 10% AG\_News
- 97% (32 000 заголовков, по 8 000 в каждой категории) – 27% AG\_News
- 100% (32 848 заголовков, по 8 212 в каждой категории) – 34% AG\_News

## Глава 4. Описание методологии эксперимента

### 4.1. Open-source библиотеки для дообучения LLM

Современные исследования в области дообучения больших языковых моделей активно поддерживаются развитой экосистемой open-source инструментов. Наиболее распространённые библиотеки ориентированы на упрощение интеграции методов parameter-efficient fine-tuning (PEFT), включая LoRA и его модификации.

Ключевыми инструментами являются:

- Transformers (Hugging Face) - базовая библиотека для работы с предобученными языковыми моделями, предоставляющая унифицированный интерфейс для обучения, инференса и токенизации [8];
- PEFT (Parameter-Efficient Fine-Tuning) - специализированная библиотека, реализующая методы LoRA, QLoRA, Prefix Tuning и другие подходы [9];
- BitsAndBytes - библиотека для низкобитной квантизации (4-bit, 8-bit), используемая в QLoRA [10];
- Accelerate - инструмент для оптимизации обучения и эффективного использования доступных вычислительных ресурсов [11].

Данные библиотеки обеспечивают быструю интеграцию LoRA в архитектуру модели, поддержку квантизации (NF4, FP4), воспроизводимость экспериментов, возможность работы в условиях ограниченных ресурсов (одна GPU).

Таким образом, современный стек инструментов делает практическое применение LoRA и QLoRA доступным даже при ограниченной вычислительной инфраструктуре.

### 4.2. Подходы к дообучению

Full Fine-Tuning характеризуется крайне высокой вычислительной стоимостью и требует значительных ресурсов видеопамяти. В условиях ограниченной инфраструктуры (одиночная GPU, локальная машина) его применение затруднено, поэтому в работе данный подход не рассматривается [12].

В качестве базовой точки отсчёта (baseline) используется модель с частичным дообучением (head-only), при котором обучается только классификационная голова, а остальные параметры остаются замороженными. Такой подход отличается низкими требованиями к ресурсам, высокой скоростью обучения и простотой реализации, однако, как правило, уступает по качеству более гибким методам адаптации. Реализация baseline представлена в ноутбуке по адресу <https://github.com/Lemekhova/msc-lemekhova/tree/main> Папка «Реализация методов»/methods.ipynb (Приложение А) и подробно описана в главе 5.

Далее в работе рассматриваются методы параметрически эффективного дообучения (PEFT), поскольку целью исследования является анализ влияния параметров таких методов (в первую очередь LoRA, QLoRA и их модификаций).

Ключевым представителем данного класса является метод LoRA (реализация метода в Приложении Г), основанный на обучении низкоранговых добавок к весам модели вместо полного обновления параметров. Его развитием является QLoRA (реализация метода в Приложении Д), дополнительно использующий низкоразрядную (4-битную) квантизацию весов, что существенно снижает потребление видеопамати. В работе рассматриваются форматы квантизации NF4 и FP4. Также анализируется модификация OrthoGeoLoRA (Приложение Ж), направленная на улучшение качества адаптации за счёт введения дополнительных ограничений на обучаемые матрицы [1][7][13]. Подробное описание рассматриваемых методов приведены в главе 6.

Каждый эксперимент повторялся 3 раза. Для анализа использовались усреднённые значения метрик с исключением выбросов, определяемых на основе стандартного отклонения.

LoRA и его расширения фактически стали стандартом дообучения LLM в условиях ограниченных ресурсов, а большинство современных исследований направлены на развитие и улучшение данной парадигмы. В рамках работы проводится сравнительный анализ подходов: head-only, LoRA, QLoRA (NF4, FP4) и OrthoGeoLoRA.

### 4.3. Метрики для оценки

Для комплексного анализа эффективности методов используются как качественные, так и ресурсные метрики.

Метрики качества:

- Ассурасу - основная метрика классификации, поскольку задача классификации новостных заголовков предполагает выбор одного корректного класса, а ассурасу напрямую отражает долю правильно классифицированных примеров. Эта метрика легко интерпретируема и позволяет сравнивать различные конфигурации моделей.
- F1-score (weighted) - учитывает баланс классов;
- Loss (cross-entropy) - характеризует процесс обучения. В отличие от ассурасу и F1, которые оценивают итоговое качество, функция потерь отражает степень уверенности модели в предсказаниях и позволяет выявлять проблемы обучения, такие как переобучение или численная нестабильность (например, возникновение NaN).

Ресурсные метрики:

- время обучения. Выбрано как ключевой показатель вычислительной стоимости. Эта метрика позволяет оценить практическую применимость различных конфигураций.



- потребление GPU-памяти. Является критически важным показателем при использовании PEFT-методов, так как одной из их ключевых задач является снижение требований к видеопамяти. Сравнение методов по этому параметру позволяет оценить их пригодность для использования на ограниченном оборудовании.

Такой набор метрик позволяет оценить не только точность модели, но и её практическую применимость в условиях ограниченных ресурсов.

#### 4.4. Ограничения экспериментов

Проводимое исследование имеет ряд ограничений:

- использование одной GPU и ограниченной видеопамяти. Все эксперименты проводились в контролируемых условиях на локальной вычислительной системе (GPU: AMD Radeon RX 9070 XT, RAM: 32 GB) с минимизацией фоновой нагрузки, что обеспечивало сопоставимость полученных результатов;

- фиксированное число эпох (1), что ограничивает сходимость моделей;
- ограниченный набор моделей (Qwen2.5-1.5B и Qwen3-0.6B);
- исследование проводится на задаче классификации (без генеративных задач);
- ограниченный набор данных (2 языка (EN, RU) одной тематики) ограниченного объема;
- фиксированные гиперпараметры (dropout, scaling).

Также следует учитывать, что:

- результаты могут зависеть от случайной инициализации (seed), поэтому во всех экспериментах seed фиксирован и равен 42;

- условия проведения экспериментов, фиксированные гиперпараметры и используемые конфигурации обеспечивают воспроизводимость полученных результатов при повторении вычислений в аналогичной программно-аппаратной среде;

- в связи с ограниченным объёмом доступных данных для русскоязычного датасета, в целях обеспечения чистоты экспериментов для сопоставительного анализа влияния языка данных эксперименты проводились на датасете, составленном из двух выборок - AG\_news (EN) и PD\_news (RU) - в эквивалентном диапазоне, а именно по 300, 1500, 3000 и 8000 образцов на каждый класс обучающей выборки. Для экспериментов по оценке влияния квантизации, типов адаптеров, рангов и архитектур моделей был использован эталонный англоязычный датасет AG\_news. Для него были сформированы выборки объёмом 300, 1500, 3000, 8000, 15000 и 30000 примеров на каждый класс обучающей выборки.

## 4.5. Постановка NLP-задачи

В рамках данной работы рассматривается задача классификации текстов как частный случай задач обработки естественного языка (Natural Language Processing, NLP). Основное внимание уделяется исследованию эффективности методов дообучения языковых моделей с использованием адаптеров типа LoRA в условиях ограниченных вычислительных ресурсов.

Формализация задачи:

Пусть задана  $D = \{(x_i, y_i)\}_{i=1}^N$  обучающая выборка,

где  $(x_i)$  - текстовый документ, а  $(y_i)$  - соответствующая метка класса.

Требуется построить функцию классификации  $f_\theta(x_i)$ , отображающую текстовый документ  $x_i$  в метку класса  $y_i \in \{1, \dots, K\}$ , где  $K=4$  - число классов.

Обучение модели заключается в минимизации функции потерь на обучающей выборке  $D$ :

$$L(\theta) = \frac{1}{|D|} \sum_{(x_i, y_i) \in D} \ell(f_\theta(x_i), y_i), \text{ где}$$

$f_\theta(x_i)$  - предсказание модели с параметрами  $\theta$ , а  $\ell$  - функция потерь cross-entropy для задачи многоклассовой классификации.

В отличие от полного дообучения (*full fine-tuning*), в рамках работы обновляются только параметры адаптеров LoRA, тогда как веса базовой языковой модели остаются замороженными. Это позволяет существенно сократить количество обучаемых параметров и снизить требования к вычислительным ресурсам.

Рассматриваемая задача характеризуется следующими особенностями:

- использование моделей различного масштаба (1.5B и 0.6B параметров);
- данные на разных языках (английский и русский языки);
- ограниченные ресурсы (ограничения по памяти, времени обучения и ограниченный объем обучающей выборки);
- необходимость эффективного дообучения модели без полного дообучения всех параметров.

Основная цель - определить конфигурации, обеспечивающие наилучший компромисс между качеством модели и вычислительными затратами.

Таким образом, задача формулируется как многокритериальная оптимизация, в которой необходимо максимизировать качество модели при одновременной минимизации вычислительных затрат.

Контролируемая экспериментальная среда: классификация коротких текстов

Размер обучающей выборки:

количество новостных заголовков в одном классе обучающей выборки:

|           |   |       |   |      |   |      |   |      |   |     |
|-----------|---|-------|---|------|---|------|---|------|---|-----|
| EN: 30000 | / | 15000 | / | 8000 | / | 3000 | / | 1500 | / | 300 |
| RU: -     | / | 8212  | / | 8000 | / | 3000 | / | 1500 | / | 300 |

Параметры обучения:

batch size: 4

число эпох: 1

максимальная длина: 256 токенов

оптимизация: стандартный Trainer из Hugging Face Transformers

смешанная точность: не используется (fp16=False) (отключен из-за особенностей используемой видеокарты)

#### 4.6. Выбор базовой языковой модели

В качестве базовых моделей используются современные предобученные трансформерные архитектуры. Выбор пал на модели **Qwen2.5-1.5B** и **Qwen3-0.6B**, поскольку они из одного семейства, но представляют разные масштабы (1.5 млрд и 0.6 млрд параметров соответственно) и доступны в открытом доступе, что обеспечивает воспроизводимость результатов исследования.

Семейство моделей Alibaba Qwen 3 – это трансформерная модель архитектуры Mixture-of-Experts (MoE). Ключевые инновации включают гибридную систему рассуждений, предлагающую режимы «мышления» и «немышления» для адаптивной обработки, а также поддержку расширенных контекстных окон, повышающих эффективность и масштабируемость [21].

Qwen2.5 от Alibaba - это языковая модель, использующая только декодер, доступна в различных размерах. Эта модель предварительно обучена на больших наборах данных, поддерживая расширенную длину контекста и многоязычную коммуникацию. Семейство включает в себя специализированные модели для кодирования, математики и мультимодальных задач, таких как обработка изображений и звука [22].

Выбор данных моделей обусловлен следующими факторами:

- наличие предобучения на больших корпусах текстов;
- поддержка эффективных методов дообучения (LoRA, QLoRA);
- различие в размере моделей, позволяющее анализировать влияние масштаба.

#### Архитектура

Используемые модели основаны на архитектуре трансформера [23]. Для решения задачи классификации в архитектуру добавляется классификационная голова, принимающая выходное

представление модели и отображающая его в пространство классов. Различие моделей представлены в Таблице 1.

Таблица 1

Различия моделей

| Характеристика | Qwen2.5-1.5B      | Qwen3-0.6B             |
|----------------|-------------------|------------------------|
| Поколение      | Qwen2.5 (2024 г)  | Qwen3 (2025 г)         |
| Параметры      | 1.5B              | 0.6B                   |
| Контекст       | до 128K           | ~32K                   |
| Архитектура    | Transformer + GQA | Улучшенный Transformer |
| Обучение       | ~18 трлн токенов  | ~36 трлн токенов       |
| На диске       | 3 ГБ              | 1–1.3 ГБ               |

#### 4.7. Предобработка данных

Перед обучением данные проходят этап токенизации:

- используется токенизатор, соответствующий выбранной модели;
- применяется усечение последовательностей до длины 256 токенов;
- используется padding до максимальной длины (*padding="max\_length"*);
- текстовая колонка преобразуется в формат, пригодный для PyTorch;
- целевая переменная приводится к формату *labels*.

Для формирования батчей используется динамический паддинг через `DataCollatorWithPadding`.

## Глава 5. Построение базовой модели

### 5.1. Конфигурация

Для анализа эффективности методов адаптации (LoRA и QLoRA) необходимо было задать базовую точку отсчёта - baseline-модель. В рамках данной работы baseline представляет собой предобученную языковую модель с минимальными изменениями, дообучаемую только за счёт классификационной головы. Таким образом, количество обучаемых параметров минимально, что позволяет оценить качество модели без применения адаптеров.

#### Особенности baseline-обучения

В baseline-подходе обучение проводится с заморозкой основной части модели, все параметры базовой языковой модели фиксируются, обучаются только параметры классификационной головы (classifier / score). Количество обучаемых параметров при этом существенно меньше общего числа параметров модели, что снижает вычислительную нагрузку и требования к памяти.

Реализация метода baseline представлена в Приложении Г, а результаты экспериментов размещены по адресу: <https://github.com/Lemekhova/msc-lemekhova/tree/main> папка «Эксперименты» (Приложение А):

папка Qwen2\_AG\_news\_EN - для Qwen2.5-1.5B и AG\_news (EN) для разного объема выборок;  
папка Qwen3\_AG\_news\_EN - для Qwen3-0.6B и AG\_news (EN) для разного объема выборок;  
папка Qwen2\_PD\_news\_RU - для Qwen2.5-1.5B и PD\_news (RU) для разного объема выборок;  
папка Qwen3\_PD\_news\_RU - для Qwen3-0.6B и PD\_news (RU) для разного объема выборок.

Для оценки baseline-модели используются определенные в главе 4 метрики для всех экспериментов: accuracy, F1-score, loss, время обучения, потребление GPU памяти на обучение. Используя все вариации модификации экспериментов для baseline в дальнейшем анализе участвуют результаты 22 экспериментов.


### 5.2. Результаты базовой конфигурации

Базовая модель задаёт границу качества, относительно которой оценивается эффективность других методов обучения - LoRA, QLoRA и OrthoGeoLoRA.

Проведённые эксперименты показывают, что:


- качество базовой модели определяется типом модели (Рисунок 3);
- Qwen3-0.6 показывает более высокое качество и меньший расход GPU на базовой конфигурации (Рисунок 3);
- обучение по базовой конфигурации обеспечивает низкие вычислительные затраты (Рисунок 4);

Сравнение использования GPU моделями qwen2.5 и qwen3



(А)


Сравнение моделей для baseline



(Б)


Рисунок 3. Сравнение моделей для baseline с указанием объема обучающей выборки (англоязычный датасет): А – по затратам GPU, Гб; Б – по времени, мин

Time vs Dataset Size - EN



(А)

GPU vs Dataset Size - EN




(Б)

Рисунок 4. Сравнение методов с указанием объема обучающей выборки (англоязычный датасет): А – по времени обучения, мин; Б – по затратам GPU, Гб

– увеличение объёма обучающей выборки модели Qwen3 приводит к росту качества модели. Хорошие результаты по *accuracy* можно наблюдать уже на объеме 3000 образцов в каждом классе обучающей выборки (Рисунок 5);


– на больших моделях (Qwen2.5-1.5B) Baseline-подход демонстрирует низкую эффективность: увеличение объёма данных и вычислительных ресурсов не приводит к устойчивому росту качества, что подтверждает необходимость применения методов параметрически эффективного дообучения, таких как LoRA и ее модификаций (Рисунок 3Б).

Accuracy vs Dataset Size - EN



(А)

Accuracy vs Dataset Size - RU



(Б)

Рисунок 5. Сравнение методов по качеству модели Qwen3-0.6B с указанием объема обучающей выборки для: А – англоязычного датасета, Б – русскоязычного датасета

## Глава 6. Дообучение языковой модели с использованием LoRA, QLoRA и OrthoGeoLoRA

В данной главе рассматривается применение методов параметр-эффективного дообучения (PEFT) для двух языковых моделей: Qwen2.5-1.5B и Qwen3-0.6B с использованием LoRA, её квантованных модификаций (QLoRA) и геометрических модификаций (OrthoGeoLoRA) на примере задачи классификации двух различных датасетов на английском и русском языках. Основной целью является исследование компромисса между качеством модели, временем обучения, потреблением GPU-памяти и размером выборки при различных конфигурациях.

### 6.1. Исследуемые параметры LoRA

В ходе экспериментов варьировались ключевые гиперпараметры LoRA:

1) Ранг (rank,  $r$ )

Рассматривались значения:  $r = 4, 8, 16, 32$

Что позволяет оценить влияние ранга на качество модели (accuracy, F1), время обучения и использование памяти

2) Набор адаптируемых модулей

Были исследованы следующие конфигурации:  $(q + v)$ ,  $(q + k + v)$ ,  $(q + k + v + o)$

Это позволяет оценить вклад различных частей механизма внимания в итоговое качество модели.

3) Коэффициенты масштабирования

Параметр  $\alpha = 2r$  и dropout = 0.05

использовались фиксированно во всех экспериментах.

Функция создания LoRA-модели, проведенные с ней эксперименты и результаты представлены по адресу: <https://github.com/Lemekhova/msc-lemekhova/tree/main> папка «Эксперименты» (Приложение А):

папка Qwen2\_AG\_news\_EN - для Qwen2.5-1.5 и AG\_news (EN) для разного объема выборок;

папка Qwen3\_AG\_news\_EN - для Qwen3-0.6 и AG\_news (EN) для разного объема выборок;

папка Qwen2\_PD\_news\_RU - для Qwen2.5-1.5 и PD\_news (RU) для разного объема выборок;

папка Qwen3\_PD\_news\_RU - для Qwen3-0.6 и PD\_news (RU) для разного объема выборок.

Используя все вариации факторов экспериментов для LoRA в дальнейшем анализе участвуют результаты 264 эксперимента.

## 6.2. Интеграция базового PEFT метода - LoRA в архитектуру модели

В рамках данного исследования разработана инфраструктура для дообучения языковых моделей с использованием базового PEFT метода LoRA (Low-Rank Adaptation). Реализация выполнена на основе библиотек Hugging Face (Transformers, PEFT, TRL) [27] и фреймворка PyTorch.

Конфигурация LoRA-адаптера задается гиперпараметрами ранг (rank) и target\_modules.

В рамках данной работы:

- LoRA внедрялась в линейные слои механизма внимания: q\_proj , k\_proj , v\_proj , o\_proj
- Базовые веса модели замораживались
- Обучались только LoRA-адаптеры и классификационная голова

Формально обновление весов представляется как:  $W' = W + BA$ , где:

$W$  - исходная матрица весов

$A \in \mathbb{R}^{d \times r}$  и  $B \in \mathbb{R}^{k \times r}$  - обучаемые матрицы

$r$  - ранг разложения (Приложение Д)

Функция создания LoRA-модели и проведенные с ней эксперименты и результаты представлены по адресу: <https://github.com/Lemekhova/msc-lemekhova/tree/main> папка «Эксперименты» (Приложение А):

папка Qwen2\_AG\_news\_EN - для Qwen2.5-1.5 и AG\_news (EN) для разного объема выборок;

папка Qwen3\_AG\_news\_EN - для Qwen3-0.6 и AG\_news (EN) для разного объема выборок;

папка Qwen2\_PD\_news\_RU - для Qwen2.5-1.5 и PD\_news (RU) для разного объема выборок;

папка Qwen3\_PD\_news\_RU - для Qwen3-0.6 и PD\_news (RU) для разного объема выборок.

## 6.3. Метод квантизации - QLoRA

Для снижения требований к GPU-памяти применялась квантизация весов модели.

Рассматривались два метода:

I - NF4 (NormalFloat4)

- Специальный формат 4-битной квантизации
- Учитывает распределение весов
- Используется как стандарт в QLoRA

II - FP4 (Float4)

- Более простой формат 4-битного представления
- Быстрее в вычислениях
- Может уступать NF4 в точности

Особенности QLoRA:



- Базовая модель хранится в 4-битном виде
- LoRA-адаптеры обучаются в более высокой точности (FP16/BF16)
- Используется двойная квантизация (double quantization)

Функция создания QLoRA-модели и проведенные с ней эксперименты и результаты представлены по адресу: <https://github.com/Lemekhova/msc-lemekhova/tree/main> папка «Эксперименты» (Приложение А):

папка Qwen2\_AG\_news\_EN - для Qwen2.5-1.5 и AG\_news (EN) для разного объема выборок;

папка Qwen3\_AG\_news\_EN - для Qwen3-0.6 и AG\_news (EN) для разного объема выборок;

папка Qwen2\_PD\_news\_RU - для Qwen2.5-1.5 и PD\_news (RU) для разного объема выборок;

папка Qwen3\_PD\_news\_RU - для Qwen3-0.6 и PD\_news (RU) для разного объема выборок.

Используя все вариации настроек для LoRA в дальнейшем анализе участвуют результаты 528 экспериментов.

## 6.4. Геометрическая модификация – OrthoGeoLoRA

OrthoGeoLoRA (Orthogonal Geometric Low-Rank Adaptation) представляет собой современную модификацию метода LoRA, направленную на устранение фундаментальных геометрических недостатков стандартной низкоранговой адаптации (Wang et al., 2026)[7]. В отличие от базовой LoRA, где обновление весов представляется как произведение двух матриц  $\Delta W = BA\Delta W = BA$  без каких-либо ограничений на их структуру, OrthoGeoLoRA накладывает условие ортогональности на факторы  $A$  и  $B$ , что обеспечивает более стабильное и эффективное обучение.

### Механизм метода

Согласно работам Wang et al. (2026) [7] и Chirkova et al. (2026) [24], стандартная LoRA страдает от трех основных проблем: *калибровочная свобода* (gauge freedom), когда одно и то же обновление может быть представлено бесконечным множеством пар  $(A, B)$ ; *масштабная неоднозначность* (scale ambiguity), затрудняющая настройку скорости обучения; и *склонность к коллапсу ранга* (rank collapse), когда эффективный ранг обновления оказывается ниже заданного, что ограничивает выразительную способность модели.

OrthoGeoLoRA решает эти проблемы путем введения SVD-подобной параметризации обновляющей матрицы:  $\Delta W = B\Sigma A^T$ , где:

- Матрицы  $A \in \mathbb{R}^{d \times r}$  и  $B \in \mathbb{R}^{k \times r}$  ортогональны (принадлежат многообразию Штифеля, Stiefel manifold);
- $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$  - диагональная матрица сингулярных значений.

Такая параметризация гарантирует, что столбцы  $A$  и  $B$  ортонормированы, т.е. каждый новый признак, вносимый адаптером, ортогонален остальным. Сингулярные значения обучаются

явно, т.е. параметр  $\log\_singular$  в реализации позволяет модели регулировать "важность" каждого из  $r$  направлений адаптации. Отсутствует калибровочная свобода, а именно представление  $\Delta W$  становится единственным для заданного ранга, что улучшает сходимость.

### Программная реализация

В оригинальной работе OrthoGeoLoRA Wang et al. (2026) [7] отсутствует открытая реализация метода или подробное описание программной части, которое можно использовать для непосредственного воспроизведения экспериментов. В связи с этим в рамках данного исследования реализация OrthoGeoLoRA была выполнена самостоятельно (Приложение В) на основе представленного теоретического описания и математической формализации метода.

Реализация OrthoGeoLoRA интегрирована с существующей экосистемой Hugging Face PEFT [27]. Реализация состоит из двух ключевых компонентов: слоя ортогонализации и основного модуля OrthoGeoLoRA (Приложение Ж). Данный слой использует QR-разложение для преобразования произвольной матрицы параметров  $\theta$  в ортогональную матрицу  $Q$ . Процедура коррекции знаков обеспечивает детерминированность отображения, что важно для воспроизводимости результатов.

Особенностью реализации является явное разделение направлений (ортогональные матрицы  $A$  и  $B$ ) и амплитуд (диагональная матрица  $\Sigma$ ). Функция *softplus* гарантирует положительность сингулярных чисел, что соответствует физическому смыслу важности каждого направления адаптации (Приложение Ж).




Рисунок 6. Геометрическая интерпретация преобразования метода OrthoGeoLoRA

Геометрическая интерпретация этого преобразования представлена на Рисунке 6 [7]. Входной вектор  $x$  сначала проецируется на ортогональный базис  $A$  (шаг 1), затем каждая проекция масштабируется соответствующим сингулярным значением (шаг 2), после чего результат проецируется на выходное пространство через ортогональный базис  $B$  (шаг 3). Такая структура обеспечивает максимальную эффективность использования каждого обучаемого параметра, так как между направлениями в пространстве признаков отсутствует корреляция.

Разработанная функция `convert_lora_to_orthogeolora` позволяет преобразовывать уже созданные LoRA-модели в OrthoGeoLoRA без необходимости повторной инициализации. Это дает возможность использовать стандартную конфигурацию PEFT и затем "усилить" модель геометрическими ограничениями, что существенно упрощает эксперименты (Приложение Ж).

Эксперименты на основе OrthoGeoLoRA проводились на разно-масштабных моделях (Qwen2.5-1.5 и Qwen3-0.6) и разноязычных данных (EN и RU).

Эксперименты на Qwen2.5 не дали стабильных результатов, что ожидаемо, о таком же эффекте на крупномасштабных моделях говорится в статье R. Chirkova et al. (2026) [24]. Наблюдался «развал» обучения, около 30% результатов экспериментов выдавали  $loss = nan$ ,  $accuracy = 0.25$ ,  $f1 = 0.10$ , что не дает права говорить об этом методе как о рабочем для модели Qwen2.5-1.5. На Qwen3-0.6 результаты были стабильные в 100% случаев. Поэтому далее в работе анализировалось поведение OrthoGeoLoRA только для модели Qwen3-0.6.

Функция создания OrthoGeoLoRA модели, проведенные с ней эксперименты и результаты представлены по адресу: <https://github.com/Lemekhova/msc-lemekhova/tree/main> папка «Эксперименты» (Приложение А):

папка Qwen3\_AG\_news\_EN - для Qwen3-0.6 и AG\_news (EN) для разного объема выборок;

папка Qwen3\_PD\_news\_RU - для Qwen3-0.6 и PD\_news (RU) для разного объема выборок.

Используя все вариации выбора параметров для экспериментов в дальнейшем анализе участвуют результаты 132 экспериментов.

## 6.5. Экспериментальная схема обучения

Факторы для экспериментов:

Модели: Qwen2.5-1.5B / Qwen3-0.6B

Язык: RU / EN

Метод: LoRA / QLoRA / OrthoGeoLora

Квантизация: NF4 / FP4

Ранг: 4 / 8 / 16 / 32

Модули:  $q+v$  /  $q+k+v$  /  $q+k+v+o$

Объем данных: 300/1500/3000/8000/15000/30000 образцов в классе

Метрики качества:

Для оценки используются определенные в главе 4 метрики для всех экспериментов:  $accuracy$ ,  $F1$ -score,  $loss$ , время обучения, потребление GPU (Гб) памяти на обучение. Используя все вариации факторов экспериментов всего в дальнейшем анализе участвуют результаты 934 эксперимента. Полученные значения метрик представлены в Приложении З.

## Глава 7. Анализ результатов. Выявленные зависимости и закономерности.

### 7.1. Методология анализа и статистические методы

В данной главе представлены результаты экспериментального исследования, направленного на проверку выдвинутых гипотез о влиянии различных факторов на качество и вычислительную эффективность методов параметрически эффективного дообучения.

Далее будут приведены только подтверждённые в ходе экспериментального исследования утверждения и наблюдаемые закономерности. Полный перечень гипотез и процедура их проверки детально описаны в ноутбуке, расположенном по адресу [https://github.com/Lemekhova/msc-lemekhova/tree/main/ «Анализ и гипотезы»/ Notebooks/ hypotheses.ipynb](https://github.com/Lemekhova/msc-lemekhova/tree/main/«Анализ%20и%20гипотезы»/Notebooks/hypotheses.ipynb) (Приложение А).

#### Структура анализа

Анализ результатов проводился по следующим направлениям:

- сравнение моделей (Qwen2.5-1.5B vs Qwen3-0.6B);
- исследование влияния ранга LoRA на качество адаптации;
- анализ эффективности расширения целевых модулей ( $q+v$ ,  $q+k+v$ ,  $q+k+v+o$ );
- совместное влияние ранга и набора модулей на качество;
- сравнение методов квантизации (LoRA vs QLoRA, NF4 vs FP4);
- оценка базовой-модели относительно методов PEFT;
- анализ влияния языка (русский vs английский);
- особенности OrthoGeoLoRA.

#### Методика статистического анализа

Для обеспечения достоверности выводов использовался комплекс статистических методов, выбор которых обусловлен характером анализируемых данных (Таблица 2).

Таблица 2

Используемый комплекс статистических методов

| Метод                                           | Назначение                                 | Обоснование применения                                                                                                        |
|-------------------------------------------------|--------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------|
| 1                                               | 2                                          | 3                                                                                                                             |
| Критерий Манна–Уитни (Mann-Whitney U test)      | Сравнение двух независимых выборок         | Распределение метрик качества может отклоняться от нормального; метод устойчив к выбросам и не требует гомогенности дисперсий |
| Критерий Уилкоксона (Wilcoxon signed-rank test) | Сравнение двух связанных (парных) выборок  | Используется для сопоставления LoRA и QLoRA на идентичных конфигурациях                                                       |
| Критерий Краскела–Уоллиса (Kruskal-Wallis test) | Сравнение трёх и более независимых выборок | Применён для анализа различий между разными значениями rank                                                                   |
| Тест Левена (Levene's test)                     | Сравнение дисперсий выборок                | Оценка стабильности моделей; устойчив к отклонениям от нормального распределения                                              |

| 1                                               | 2                                                | 3                                                                    |
|-------------------------------------------------|--------------------------------------------------|----------------------------------------------------------------------|
| Двухфакторный дисперсионный анализ (ANOVA [25]) | Оценка влияния двух факторов и их взаимодействия | Анализ совместного влияния rank и размера выборки на качество модели |
| Коэффициент $\eta^2$ (eta-squared)              | Оценка величины эффекта                          | Количественная мера вклада каждого фактора в общую вариативность     |
| Cliff's delta                                   | Оценка величины различий между группами          | Дополняет p-value информацией о практической значимости эффекта      |

### Инструментальная база

Все статистические расчёты выполнены с использованием библиотек `scipy.stats` и `statsmodels` в среде Jupyter Notebook (Приложение А – GitHub / «Анализ и гипотезы» /Notebooks /hypotheses.ipynb). Для каждого статистического теста пороговое значение уровня значимости принято равным  $\alpha = 0.05$ .

## 7.2. Анализ результатов

### 7.2.1. Оценка влияния факторов на качество модели

Для анализа взаимосвязей между качественными и ресурсными характеристиками была построена корреляционная матрица Спирмена, позволяющая выявить монотонные зависимости между параметрами адаптации, объёмом данных и итоговым качеством моделей. Для построения корреляционной матрицы использовалась подвыборка экспериментов в сопоставимом диапазоне объёмов обучающих данных (от 300 до 8000 образцов на класс), включающая только методы LoRA и QLoRA. Метод OGLoRA был исключён из анализа вследствие отсутствия полной серии результатов для модели Qwen2.5, поскольку его включение могло бы привести к смещению оценок и исказить интерпретацию выявленных зависимостей.

Корреляционный анализ Спирмена (Рисунок 7) показал, что наибольшее влияние на качество классификации оказывает объём обучающей выборки ( $\rho = 0.828$ ).




Рисунок 7. Матрица корреляций признаков.

Также видно, что вместе с объемом выборки соответственно увеличивается время обучения. Влияние ранга адаптеров является умеренным ( $\rho = 0.247$ ). Отрицательная корреляция с языковым признаком ( $\rho = -0.219$ ) свидетельствует о большей сложности русскоязычных данных. При этом связь между потреблением GPU-памяти и качеством практически отсутствует ( $\rho = -0.062$ ), что говорит о возможности эффективной оптимизации вычислительных ресурсов без существенной потери точности.

## 7.2.2. Сравнение моделей

- При дообучении методами LoRA и QLoRA Qwen2.5-1.5B чаще показывает сопоставимое или лучшее качество при достаточном объеме данных (более 1500 образцов в каждом классе обучающей выборки и больше). Модели статистически значимо различаются по качеству. При объеме 1500 образцов модели могут вести себя по-разному.




Рисунок 8. Сравнение качества моделей Qwen3-0.6B и Qwen2.5-1.5B в случаях работы на разных объемах данных на разных языках, используя методы LoRA, QLoRA nf4, QLoRA fp4

- Qwen3-0.6B даёт более стабильные результаты (меньше разброс loss) (Рисунок 9).




Рисунок 9. Сравнение разброса Loss моделей Qwen3-0.6 и Qwen2.5-1.5 в случаях работы на разных языках: А – англоязычный датасет; Б – русскоязычный датасет.

- Qwen3-0.6B более экономная в части затрат памяти (Рисунок 10)




Рисунок 10. Сравнение использования памяти на обучение (Гб) между моделями qwen2.5 и qwen3: А – точечная диаграмма для разных объемов выборки (EN); Б – общий боксплот (ящик с усами) (EN)

- Qwen3-0.6B отличается более высокой скоростью обучения (Рисунок 11)




Рисунок 11. Сравнение скорости на обучение (мин) между моделями qwen2.5 и qwen3: А – точечная диаграмма для разных объемов выборки (EN); Б – общий боксплот (ящик с усами) (EN)

### 7.2.3. Исследование влияния ранга LoRA на качество адаптации

— Оптимальный rank зависит от объёма данных.

Наибольшая чувствительность ассигасу к рангу проявляется при малых данных (300 образцов) (Рисунок 12). Также, статистические тесты говорят о том, что ни на одном шаге ранга при объеме выборки 1500 и более нельзя утверждать, что ассигасу перестаёт расти, что мы можем наблюдать на Рисунке 8. Парный t-тест показывает значимость ( $p < 0.05$ ) на каждом шаге, включая переход от 16 к 32 рангу.




Рисунок 12. Качество модели при различных рангах на разных выборках.

Однако, практически картина немного другая и можно наблюдать, что при объеме данных 8000 rank 4 уже даёт 99% от максимального значения ассигасу. При этом все шаги статистически значимы лишь потому, что у нас много повторений и маленький std (0.009), а не потому что разница реально важна. При объеме 3000 rank 8 даёт тоже более 99% от максимума качества. Ранг, при котором достигается 99% от максимального значения точности представлены в Таблице 3. Переход от ранга 4 к рангу 8 статистически незначим ( $p = 0.189$ ) и это как раз можно назвать локальным плато. Затем переход от ранга 8 к 16 и от 16 к 32 снова значимы, но с приростом всего 0.003–0.004 (Рисунок 12). Т.е. здесь можно говорить о практическом плато при статистической значимости, когда тест улавливает разницу, которая не имеет практического смысла.

Таблица 3

Rank, при котором достигается 99% от максимального значения ассигасу:

| Объем выборки | Ранг (99% от max ассигасу) |
|---------------|----------------------------|
| 300           | 32 (плато не достигается)  |
| 1500          | 16                         |
| 3000          | 8                          |
| 8000          | 4                          |



– Различие влияния ранга для разных моделей:

Для оценки силы влияния факторов был рассчитан коэффициент  $\eta^2$  [25].

Для модели Qwen2.5 основной вклад в качество вносит размер обучающей выборки, в то время как влияние rank является незначительным. Взаимодействие факторов оказывает ограниченное влияние.

Для модели Qwen3 наблюдается более выраженное влияние rank и особенно взаимодействия факторов, что указывает на зависимость эффективности выбора rank от объёма обучающей выборки.

Модель Qwen2.5 в основном определяется объёмом данных и слабо зависит от параметров адаптера, тогда как Qwen3 демонстрирует значительно более сложное поведение, включая существенную зависимость от rank и его взаимодействия с размером выборки.

#### 7.2.4. Расширение target modules. Сравнение: q+v, q+k+v, q+k+v+o

(q+v) даёт лучшее соотношение качество/ресурсы, максимальное качество достигается при использовании (q+k+v+o).

При увеличении модулей *Accuracy* растёт слабо ( $\approx +1-2\%$ ), но наблюдается рост времени обучения и GPU (Рисунок 14, таблица 4), что связано с увеличением числа обновляемых параметров и вычислительной нагрузки. Также, рост модулей не всегда дает пропорциональный рост ассурасу, (q+v) часто дает лучшее качество, чем (q+k+v). Аномалия с падением качества при добавлении K-проекции без Output проявляется в методах, работающих с полной точностью (LoRA, OGLoRA) (Рисунок 13). В квантованных методах QLoRA эта аномалия исчезает, и добавление K-проекции даёт ожидаемый прирост качества благодаря дополнительной гибкости, компенсирующей ошибки квантизации (Рисунок 13).




Рисунок 13. Качество модели Qwen3-0.6 для англоязычных данных при разном наборе модулей

Таблица 4

Точечные диаграммы сравнения зависимости времени выполнения и использования GPU памяти от набора модулей и выбора ранга для разных моделей





Рисунок 14. Точечные диаграммы сравнения зависимости времени выполнения и использования GPU памяти от типа модуля и ранга для разных моделей на разном объеме выборки

(q+v) можно использовать для экономии времени и памяти, а (q+k+v+o) - для большей точности и более высокой стабильности.

Также следует отметить отсутствие взаимовлияния ранга и модулей. ANOVA показал, что rank и набор модулей влияют на accuracy преимущественно независимо ( $p=0.999$  для взаимодействия). Их эффекты складываются, а не усиливают друг друга. Можно также говорить о взаимокompенсации. При rank=4 переход от q+v к q+k+v+o даёт +0.021 к accuracy. При rank=16 тот же переход даёт -0.002. Это означает, что q+k+v+o и rank частично взаимозаменяемы, т.е. при малом ранге q+k+v+o «добирает» качество за счёт большего охвата модулей механизма внимания.


### 7.2.5. Совместное влияние ранга и набора модулей на потребление времени и памяти

Влияние rank и набора модулей на время обучения



(A)

Потребление GPU для rank=4 и rank=32



(Б)

Рисунок 15. Влияние выбора модулей и ранга на прирост: А – времени, мин., Б – памяти, Гб

### Время

Дисперсионный анализ показал, что объём обучающей выборки является доминирующим фактором времени обучения ( $\eta^2=0.989$ ,  $p<0.001$ ). Влияние ранга адаптера на время обучения статистически незначимо ( $\eta^2=0.0002$ ,  $p=0.996$ ): переход от rank=4 к rank=32 увеличивает время не более чем на 0.7 мин независимо от объёма данных. Набор целевых модулей оказывает более выраженный, хотя также незначимый эффект ( $\eta^2=0.004$ ,  $p=0.588$ ): конфигурация q+k+v+o в среднем требует на 2.7 мин больше, чем q+v ( $r=+0.142$ ,  $p=0.02$ ). Таким образом, при выборе конфигурации с точки зрения времени обучения ранг является практически нейтральным параметром, тогда как расширение набора модулей даёт умеренный, но измеримый прирост временных затрат.

Если для практической задачи важно время обучения, то необходимо выбирать приемлемый объём данных и модулей, тогда как ранг можно повышать без временных потерь.

## Память

Дисперсионный анализ показал, что основным фактором потребления GPU-памяти является архитектура базовой модели и используемый метод. Из параметров адаптации набор целевых модулей оказывает в 40 раз более выраженный эффект на память, чем ранг, переход с  $q+v$  на  $q+k+v+o$  увеличивает потребление на 0.42 ГБ, тогда как рост ранга с 4 до 32 лишь на 0.07 ГБ ( $r=+0.082$ ,  $p=0.183$ ). Взаимодействие факторов rank и модулей практически отсутствует ( $\eta^2=0.00002$ ), что подтверждает аддитивный характер их суммарного вклада в GPU-потребление.




Рисунок 16. Влияние выбора модулей и ранга на потребление памяти:  
А – матрица потребления памяти при различных конфигурациях,  
Б – сравнение прироста памяти при выборе большего ранга или набора модулей.

Эффекты аддитивны, т.е. зная прирост от rank и прирост от модулей по отдельности, можно просто сложить их. Никакого усиления или подавления друг друга не наблюдается.

### 7.2.6. QLoRA vs LoRA

— QLoRA сохраняет более 95% качества LoRA (Рисунок 17) при значительном снижении затрат памяти (Рисунок 19), но требует существенно большего времени обучения (Рисунок 18).

В результате экспериментов установлено, что QLoRA в среднем сохраняет около 98.4% качества LoRA, при этом в 89% случаев достигается уровень не ниже 95%. Однако статистический анализ (тест Уилкоксона,  $p = 0.0013$ ) показывает наличие значимого снижения качества, что не позволяет утверждать сохранение более 95% качества во всех случаях. При этом QLoRA обеспечивает значительное снижение потребления GPU (в среднем до 71.6% от LoRA,  $p = 0.001$ ), что подтверждает его эффективность в условиях ограниченных вычислительных ресурсов. В то же время QLoRA требует большего времени обучения (в среднем время увеличивается на 49%) причём почти во всех случаях QLoRA. Это связано с дополнительными вычислительными затратами на операции квантования и деквантования.




Рисунок 17




Рисунок 18. Затраты времени (мин) при обучении для методов на различных объемах данных (Qwen3-0.6-B)




Рисунок 19. Затраты памяти (Гб) при обучении для методов на различных объемах данных (Qwen3-0.6-B)

— На малых данных (300 образцов) *accuracy* с QLoRA ниже, чем с LoRA.

При крайне малом размере выборки (300 примеров в классе) QLoRA демонстрирует качество ниже по сравнению с LoRA (разница около 8–10%,  $p < 0.001$ ), что указывает на недостаточную устойчивость метода в условиях ограниченных данных (Рисунок 17). Однако при увеличении размера выборки до 1500 и выше различия между методами становятся практически нулевыми (менее 1%) и статистически незначимыми или практически незначимыми с точки зрения эффекта. Таким образом, можно выделить порог стабилизации: начиная примерно с 1500 примеров, QLoRA достигает качества, сопоставимого с LoRA.

#### 7.2.7. FP4 vs NF4

- NF4 и FP4 демонстрируют практически одинаковое качество, несмотря на формальную статистическую значимость различий (Рисунок 20).




Рисунок 20. Распределение точности QLoRA: NF4 против FP4 (Qwen3-0.6B, EN)

Анализ показал, что различия между NF4 и FP4 по качеству являются статистически значимыми ( $p < 0.001$ ), однако их величина крайне мала. Средняя разница составляет менее 1%, а в более чем 90% случаев она не превышает 2%. При этом величина эффекта (*Cliff's delta*  $\approx 0.04$ ) указывает на пренебрежимо малый эффект, что свидетельствует об отсутствии практической значимости различий.

#### 7.2.8. Baseline

- Baseline проигрывает по качеству.

Разница качества: LoRA vs baseline: +17.5%, QLoRA vs baseline: +16.3%. Различия статистически значимы. Даже на малых данных базовая конфигурация сильно проигрывает методам LoRA

Fine-tuning только головы недостаточен при ограниченных ресурсах. При нетребовательных условиях к качеству модели baseline может быть актуален, т.к. тратит минимум памяти и времени на обучение по сравнению с другими моделями.

### 7.2.9. Влияние качества набора данных (RU vs EN)

- Качество выше на английском, чем на русском датасете

Результаты экспериментов показывают, что качество моделей на английском языке существенно выше, чем на русском. Средняя разница в ассигасу составляет около 5–6%. При парном сравнении английская версия превосходит русскую в 100% случаев, при этом в 94.6% случаев разница превышает 2%. Статистический анализ подтверждает значимость различий, а величина эффекта (*Cliff's delta*=0.54) указывает на сильный эффект.

- При уменьшении данных русский язык теряет в качестве сильнее английского.

Анализ влияния размера обучающей выборки на устойчивость моделей показал, что различия между английским и русским языками проявляются в условиях малых данных. При размере выборки 300 примеров наблюдается статистически значимо более сильная деградация качества на русском языке ( $p < 0.001$ ), с разницей около 7% по величине падения ассигасу. Однако при увеличении размера выборки до 1500 примеров различия становятся минимальными (0.09%) и практически незначимыми с точки зрения эффекта.

- Для русского языка Qwen2.5 дает более высокое качество

Анализ показал, что модель Qwen3 теряет значительно больше качества при переходе с английского на русский датасет по сравнению с Qwen2.5. Среднее снижение ассигасу составляет около 6% для Qwen3 против 1.3% для Qwen2.5.

Эти явления могут быть связаны как с морфологической сложностью языка так и с качеством подготовки данных. Например, предварительный анализ показал, что в данных на русском языке средняя длина теста значительно короче, чем на английском.

### 7.2.10. Метод OrthoGeoLoRA (OGLoRA)

- Модель: Эксперименты на Qwen2.5 не дали стабильных результатов. Примерно в 30% экспериментов наблюдался «развал» обучения ( $loss = nan$ ,  $accuracy = 0.25$ ,  $f1 = 0.10$ ), что не дает права говорить о методе OrthoGeoLoRA как о рабочем для модели Qwen2.5-1.5B. На Qwen3-0.6B результаты были стабильные. Поэтому в работе анализировалось поведение OrthoGeoLoRA только для модели Qwen3-0.6B.
- Ранг: при OrthoGeoLoRA
  - для малых данных (300) качество значимо не увеличивается (может даже уменьшаться при EN), начиная с  $rank=16$ ,

- при выборке 1500 и более качество достигает максимума при rank=8-16, далее также значимо не растет (RU) или деградирует (EN) (Рисунок 21).




Рисунок 21. Качество моделей при разных рангах на примере различных объемов обучающей выборки: А – для англоязычного датасета; Б – для русскоязычного датасета

- Число модулей:

- для лучшего качества на малых данных следует выбирать набор модулей (q+k+v+o)
- для данных  $\geq 1500$ : достаточно (q+v) (Рисунок 22)




Рисунок 22. Качество моделей при разном выборе набора модулей на примере различных объемов обучающей выборки: А – для англоязычного датасета; Б – для русскоязычного датасета

- Объем выборки: лучше всего себя проявил OrthoGeoLoRA + Qwen3 на малых данных ( $<1500$ ) (Рисунок 23):
  - Accurasy: значимо выше других рассмотренных методов (baseline, LoRA, QLoRA) (Рисунок 24).
  - GPU: затраты на GPU ниже, чем у LoRA (Рисунок 25).



- Время: занимает гораздо больше времени относительно других методов. Однако, при обучении на малом объеме данных абсолютные времязатраты сравнительно небольшие (OGLoRA  $\approx$  4 мин vs LoRA  $\approx$  2,5 мин) (Рисунок 26).

Этот эффект был подтвержден как на англоязычном так и на русскоязычном датасете, при этом на русскоязычном датасете эффект был даже ярче, чем на английском.

Этот метод также как и предыдущие изыскания обозначил порог объема датасета в 1500 образцов в каждом классе обучающей выборки, после которого результаты обучения методом OrthoGeoLoRA (OGLoRA) не отличались от результатов других методов LoRA.




Рисунок 23. Качество моделей для разных методов на примере различных объемов обучающей выборки: А – для англоязычного датасета; Б – для русскоязычного датасета




Рисунок 24. Сравнение распределений точности: LoRA, OGLoRA, QLoRA (FP4/NF4) и baseline: А – для малых данных (<1500); Б – для больших ( $\geq 1500$ )




Рисунок 25. Сравнение распределений GPU (Гб): LoRA, OGLoRA, QLoRA (FP4/NF4) и baseline: А – для малых данных (<1500); Б – для больших (>1500)




Рисунок 26. Сравнение распределений времени на обучение (мин.): LoRA, OGLoRA, QLoRA (FP4/NF4) и baseline: А – для малых данных (<1500); Б – для больших (>1500)

### 7.3. Выявленные зависимости и закономерности

- При дообучении методами LoRA и QLoRA Qwen2.5-1.5B чаще показывает сопоставимое или лучшее качество при достаточном объёме данных (более 1500 образцов в каждом классе обучающей выборки и больше). А Qwen3-0.6B + QLoRA превосходит Qwen2.5-1.5B при 300 образцов в каждом классе обучающей выборки. Модели статистически значимо различаются по качеству. При объёме 1500 образцов модели могут вести себя по-разному.
- Qwen3-0.6B даёт более стабильные результаты (меньше разброс loss). Разброс loss у модели Qwen3 статистически меньше.
- Qwen3-0.6B более экономная в части затрат памяти

- Rank, при котором достигается 99% от максимального значения ассигасы представлен в таблице 5

Таблица 5

Rank, при котором достигается 99% от максимального значения ассигасы в зависимости от объема выборки

| Объем выборки | Ранг (99% от max accuracy) |
|---------------|----------------------------|
| 300           | 32 (плато не достигается)  |
| 1500          | 16                         |
| 3000          | 8                          |
| 8000          | 4                          |

- Модель Qwen2.5 в основном определяется объёмом данных и слабо зависит от параметров адаптера, тогда как Qwen3 демонстрирует значительно более сложное поведение, включая существенную зависимость от rank и его взаимодействия с размером выборки
- $(q+v)$  даёт лучшее соотношение качество/ресурсы, максимальное качество достигается при использовании  $(q+k+v+o)$ .
- Набор модулей влияет на время обучения и потребление памяти значительно, чем выбор ранга
- QLoRA сохраняет более 95% качества LoRA при значительном снижении затрат памяти, но требует существенно большего времени обучения
- Fine-tuning только головы недостаточен при ограниченных ресурсах.
- Качество выше на английском, чем на русском
- На малых данных русский язык теряет в качестве сильнее английского
- Для русского языка Qwen2.5 дает более высокое качество
- OrthoGeoLoRA не работает на Qwen2.5 в связи с ее высоким масштабом
- На малых данных хорошо работает OrthoGeoLoRA+Qwen3, но долго. Экономнее по GPU, чем LoRA
- Порог объема датасета в 1500 образцов в каждом классе обучающей выборки, после которого результаты обучения различными PFET методами критические не отличается друг от друга по качеству, но имеет различие по времени и затратам памяти.

#### 7.4. Выбор оптимальных конфигураций

Для поиска наиболее эффективных конфигураций применялся метод визуального и аналитического анализа двумерного пространства компромиссов (trade-off space), в котором каждая точка соответствует одному эксперименту с конкретным набором параметров (метод, модель, ранг, модули, объём данных).

Пространство конфигураций оценивалось одновременно по двум осям эффективности: ось X – коэффициент эффективности по времени:  $\text{Accuracy} / \text{Time}$ , то есть точность, достигаемая за единицу времени обучения; ось Y – коэффициент эффективности по GPU-памяти:  $\text{Accuracy} / \text{GPU}$ , то есть точность, достигаемая на единицу потреблённой видеопамяти.

Таким образом, наилучшие конфигурации располагаются в правом верхнем углу графика - они одновременно быстры и экономны по памяти при высоком качестве. Конфигурации в левом нижнем углу либо медленны, либо ресурсоёмки при недостаточном качестве (Рисунок 27). На всём множестве 934 экспериментов строился сводный *scatter plot*, позволяющий выявить кластеры методов и моделей по соотношению эффективности. Например, на рисунке 27 видно, что: OGLoRA (ромбы фиолетовые) образует отдельный кластер с высокой эффективностью по GPU при невысокой эффективности по времени;

QLoRA на Qwen3 (зелёные и оранжевые ромбы) концентрируется в верхней части по оси GPU, но смещена влево по оси времени;

LoRA (синие круги и ромбы) демонстрирует наилучшую эффективность по времени, но проигрывает по GPU;

QLoRA на Qwen2.5 (красные и зелёные круги) держится в нижней части - квантизация экономит память, но на крупной модели это менее выгодно, чем на Qwen3 и т.д.

Эффективность конфигураций ( $\text{accuracy}/\text{time}$  vs  $\text{accuracy}/\text{gpu}$ ) для  $\text{accuracy} > 0.9$




Рисунок 27. Двумерное пространство эффективности конфигураций. по метрикам  $\text{Accuracy}/\text{Time}$  и  $\text{Accuracy}/\text{GPU}$  для всех экспериментов.

Предложенный подход позволяет перейти от полного перебора конфигураций к направленному выбору. Проведённый многофакторный анализ позволяет сформулировать общие практические рекомендации по выбору конфигураций PEFT-методов для задачи классификации текстов в условиях ограниченных вычислительных ресурсов (Таблица 6).

Таблица 6

Общие рекомендации по применению адаптеров (LoRA) для дообучения моделей в условиях ограниченных вычислительных ресурсов:

| Данных на класс                      | Сценарий       | Модель                                                           | Метод                                                                          | Ранг  | Модули               | Уровень качества<br>**** | Время, мин.***      | GPU         |
|--------------------------------------|----------------|------------------------------------------------------------------|--------------------------------------------------------------------------------|-------|----------------------|--------------------------|---------------------|-------------|
| Мало данных<br>300                   | GPU критично   | Выбор в пользу компактных и более новых модификаций (Qwen3-0.6B) | Выбор критически важен в пользу современных экономных методов (OrthoGeoLoRA)** | 32    | $q+v$ ,<br>$q+k+v+o$ | 0.85-0.89                | 3.4-5.3             | 2.7-2.9     |
|                                      | скорость важна | Выбор в пользу компактных и более новых модификаций (Qwen3-0.6B) | Выбор в пользу базовых методов LoRA с обновлением минимума параметров          | 32    | $q+v$ ,<br>$q+k+v+o$ | 0.82-0.88                | 1.9-2.5             | 3.1-4.6     |
| Среднее кол-во данных<br>1500 - 3000 | GPU критично   | Выбор в пользу более масштабных моделей (Qwen2.5-1.5B)*          | Выбор в пользу методов с использованием квантования (QLoRA NF4, FP4)           | 16-32 | $q+v$ ,<br>$q+k+v$   | 0.92 – 0.93              | 7.6-12.1<br>5.3-9*  | 3.7<br>2.5* |
|                                      | скорость важна | Выбор в пользу более масштабных моделей (Qwen2.5-1.5B)*          | Выбор в пользу базовых методов LoRA                                            | 16-32 | $q+v$                | 0.91 – 0.93              | 4.4-7.4<br>4.0-6.8* | 5.7<br>3.3* |
| Достаточно данных<br>$\geq 8000$     | GPU критично   | Выбор в пользу более масштабных моделей (Qwen2.5-1.5B)*          | Выбор в пользу методов с использованием квантования (QLoRA NF4)                | 4-8   | $q+v$                | 0.93-0.94                | >27.7<br>>20*       | 3.7<br>2.4* |
|                                      | скорость важна | Выбор в пользу более масштабных моделей (Qwen2.5-1.5B)*          | Выбор в пользу базовых методов LoRA                                            | 4-8   | $q+v$                | 0.93-0.94                | >17.6               | 5.9<br>3.3* |

\* - для эталонных (высокого качества) данных и для языков менее морфологически сложных можно использовать компактные и более новые модификации моделей (Qwen3-0.6B) с целью экономии памяти и времени на обучение;

\*\* - OrthoGeoLoRA стабильнее на малых данных;

\*\*\* - каждые 1000 образцов в классе добавляет примерно 1.7-2.4 минуты на обучение;

\*\*\*\* - ориентировочные значения для представления как улучшается качество с объемом выборки.

Выбор конфигурации определяется последовательно. Следует сперва отталкиваться от объема данных, на которых есть возможность обучить модель, далее смотреть на морфологию

языка, сложность и качество исходных данных. Выбирая корректные настройки, оцениваются ограничения по GPU-памяти и времени, после чего выбираются модель, метод, ранг и набор модулей. После оценки потенциальных затрат, возможно, следует урезать обучающую выборку с целью сокращения времени на обучение с сохранением приемлемого уровня качества.

Полученные рекомендации позволяют осознанно выбирать конфигурацию без полного перебора параметров, опираясь на три последовательных вопроса: сколько данных доступно, какой ресурс является приоритетным, на каком языке решается задача (какого качества данные). Ответы на эти вопросы указывают на оптимальный метод, ранг и набор модулей для конкретного сценария применения.

## 8. Заключение

В рамках данного исследования был проведён многокритериальный анализ влияния параметров PEFT-методов семейства LoRA (LoRA, QLoRA, OrthoGeoLoRA) на качество и вычислительную эффективность языковых моделей при решении задачи классификации коротких текстов в условиях ограниченных вычислительных ресурсов (одиночные GPU, локальная инфраструктура, ограниченный объем данных).

На основе серии из 934 экспериментов с варьированием ранга адаптеров (4, 8, 16, 32), набора модулей ( $q+v$ ,  $q+k+v$ ,  $q+k+v+o$ ), типа квантизации (NF4, FP4), объёма обучающей выборки (от 300 до 30000 образцов на класс), а также двух моделей семейства Qwen разного масштаба (0.6B и 1.5B) и двух языков (английский, русский), были получены следующие основные результаты.

Объём обучающей выборки является доминирующим фактором, определяющим итоговое качество моделей и время обучения. Установлен порог в 1500 образцов на класс: при превышении этого значения различия между PEFT-методами по качеству становятся минимальными, что позволяет выбирать конфигурацию, исходя исключительно из ресурсных ограничений.

Набор адаптируемых модулей влияет на потребление GPU-памяти и время обучения значительно сильнее, чем увеличение ранга. Конфигурация  $q+v$  обеспечивает наилучшее соотношение качества и вычислительных затрат, тогда как максимальное качество (ценой ресурсов) достигается при использовании полного набора  $q+k+v+o$ .

Обнаружен эффект убывающей отдачи от увеличения ранга адаптеров: для больших выборок качество стабилизируется уже при  $\text{rank}=4-8$ , в то время как для малых данных (менее 1500 образцов на класс) требуется  $\text{rank}=32$  для достижения конкурентных результатов. Влияние ранга и набора модулей на ресурсопотребление носит преимущественно аддитивный характер.

Выявлены систематические различия между моделями разных поколений и масштабов:

Qwen2.5-1.5B обеспечивает более высокое качество при достаточном объёме данных, но требует больше ресурсов.

Qwen3-0.6B демонстрирует более стабильное обучение и меньшее потребление памяти, что делает её предпочтительной для сверхограниченных сред.

На малых выборках конфигурация Qwen3-0.6B + OrthoGeoLoRA показывает высокую эффективность по соотношению качество/GPU, хотя и сопровождается бóльшим временем обучения.

Практическая значимость работы заключается в том, что полученные зависимости позволяют осознанно выбирать конфигурацию PEFT без полного перебора параметров: исследователь или практик может, исходя из объёма доступных данных и жёсткости ресурсных

ограничений (время, VRAM, объем выборки), определить минимально достаточный ранг, оптимальный набор модулей и целесообразность применения квантизации.

Таким образом, выявлены закономерности, определяющие компромисс между качеством классификации и вычислительными затратами при использовании LoRA-методов. Сформулированные практические рекомендации могут быть непосредственно применены в задачах классификации коротких текстов (новостные агрегаторы, обработка обращений в поддержку и госорганы) в условиях ограниченной инфраструктуры. Реализованные эксперименты и открытая реализация OrthoGeoLoRA могут служить бенчмарком для последующего сравнения новых PEFT-методов.



## Список литературы

1. Lialin V., Deshpande V., Rumshisky A. Scaling Down to Scale Up: A Guide to Parameter-Efficient Fine-Tuning // arXiv preprint arXiv:2303.15647. - 2023. - URL: <https://arxiv.org/abs/2303.15647> (дата обращения: 20.04.2026).
2. Hu E. J., Shen Y., Wallis P. et al. LoRA: Low-Rank Adaptation of Large Language Models // arXiv preprint arXiv:2106.09685. - 2021. - URL: <https://arxiv.org/abs/2106.09685> (дата обращения: 20.04.2026).
3. Zhang Q., Chen M., Bukharin A. et al. AdaLoRA: Adaptive Budget Allocation for Parameter-Efficient Fine-Tuning // arXiv preprint arXiv:2303.10512. - 2023. - URL: <https://arxiv.org/abs/2303.10512> (дата обращения: 20.04.2026).
4. Shinwari H. U. K., Usama M. ARD-LoRA: Dynamic Rank Allocation for Parameter-Efficient Fine-Tuning of Foundation Models with Heterogeneous Adaptation Needs // arXiv preprint arXiv:2506.18267. - 2025. - URL: <https://arxiv.org/abs/2506.18267> (дата обращения: 20.04.2026).
5. Ed-dib A., Datbayev Z., Aboussalah A. M. GeLoRA: Geometric Adaptive Ranks For Efficient LoRA Fine-tuning // Findings of the Association for Computational Linguistics: EMNLP 2025. - 2025. - С. 25174–25196. - URL: <https://aclanthology.org/2025.findings-emnlp.1372/> (дата обращения: 20.04.2026).
6. Prabhakar A., Li Y., Narasimhan K., Kakade S., Malach E., Jelassi S. LoRA Soups: Merging LoRAs for Practical Skill Composition Tasks // Proceedings of the 31st International Conference on Computational Linguistics: Industry Track (COLING 2025). - Abu Dhabi, UAE: Association for Computational Linguistics, 2025. - P. 644–655. - URL: <https://aclanthology.org/2025.coling-industry.55/> (дата обращения: 20.04.2026).
7. Wang Z., Wu X., Li C. et al. OrthoGeoLoRA: Geometric Parameter-Efficient Fine-Tuning for Structured Social Science Concept Retrieval on the Web // arXiv preprint arXiv:2601.09185. - 2026. - URL: <https://arxiv.org/abs/2601.09185> (дата обращения: 20.04.2026).
8. Wolf T., Debut L., Sanh V. et al. Transformers: State-of-the-Art Natural Language Processing // Hugging Face Documentation. - URL: <https://huggingface.co/docs/transformers> (дата обращения: 20.04.2026).
9. Mangrulkar S., Paul S., Bossan B. et al. PEFT: Parameter-Efficient Fine-Tuning of Billion-Scale Models on Low-Resource Hardware // Hugging Face Documentation. - URL: <https://huggingface.co/docs/peft> (дата обращения: 20.04.2026).
10. Dettmers T., Timmermans R., Belkada Y. et al. bitsandbytes: k-bit optimizers and matrix multiplication routines // GitHub repository. - URL: <https://github.com/bitsandbytes-foundation/bitsandbytes> (дата обращения: 20.04.2026).

11. Hugging Face Accelerate Documentation // Hugging Face Documentation. - URL: <https://huggingface.co/docs/accelerate/index> (дата обращения: 20.04.2026).
12. McMahan B., Moore E., Ramage D., Hampson S., y Arcas B. A. Communication-Efficient Learning of Deep Networks from Decentralized Data // Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS 2017). - 2017. - P. 1273–1282. - URL: <https://arxiv.org/abs/1801.06146> (дата обращения: 20.04.2026).
13. Dettmers T., Pagnoni A., Holtzman A., Zettlemoyer L. QLoRA: Efficient Finetuning of Quantized LLMs // arXiv preprint arXiv:2305.14314. - 2023. - URL: <https://arxiv.org/abs/2305.14314> (дата обращения: 20.04.2026).
14. Jeon H., Kim Y., Kim J.-J. L4Q: Parameter Efficient Quantization-Aware Training on Large Language Models via LoRA-wise LSQ // arXiv preprint arXiv:2402.04902. — 2024. — URL: <https://arxiv.org/abs/2402.04902> (дата обращения: 20.04.2026).
15. Ye R., Tang M., Ngai E. C.-H. On-the-Fly Adaptation to Quantization: Configuration-Aware LoRA for Efficient Fine-Tuning of Quantized LLMs // arXiv preprint arXiv:2509.25214. - 2025. - URL: <https://arxiv.org/abs/2509.25214> (дата обращения: 20.04.2026).
16. Zhang X., Zhao J., LeCun Y. AG News Corpus // Hugging Face Datasets. - URL: [https://huggingface.co/datasets/sh0416/ag\\_news](https://huggingface.co/datasets/sh0416/ag_news) (дата обращения: 20.04.2026).
17. Wang Y., Zhang H., Li X. et al. Efficient Fine-Tuning Strategies for Large Language Models under Resource Constraints // Buildings. - 2025. - Vol. 15, No. 19. - Art. 3477. - URL: <https://www.mdpi.com/2075-5309/15/19/3477> (дата обращения: 20.04.2026)
18. Luo D., Zheng K., Wu C., Wang X. MSLoRA: Meta-learned scaling for adaptive fine-tuning of LoRA / Neurocomputing. - URL: <https://www.sciencedirect.com/science/article/abs/pii/S092523122501046X> (дата обращения: 20.04.2026)
19. Nwaiwu S. Parameter-Efficient Fine-Tuning for Low-Resource Text Classification: A Comparative Study of LoRA, IA3, and ReFT // Frontiers in Big Data. - 2025. - Vol. 8. - Art. 1677331. - URL: <https://www.frontiersin.org/journals/big-data/articles/10.3389/fdata.2025.1677331/full> (дата обращения: 20.04.2026).
20. He H., Ye J., Li M., Wang Z., Chen T., Bai L., Ye P. A Unified Study of LoRA Variants: Taxonomy, Review, Codebase, and Empirical Evaluation // arXiv preprint arXiv:2601.22708. - 2026. - URL: <https://arxiv.org/abs/2601.22708> (дата обращения: 20.04.2026).
21. Qwen3-0.6B // APXML. Каталог языковых моделей. - URL: <https://apxml.com/models/qwen3-0-6b> (дата обращения: 20.04.2026).
22. Qwen2.5-1.5B // APXML. Каталог языковых моделей. - URL: <https://apxml.com/models/qwen2-5-1-5b> (дата обращения: 20.04.2026).

23. Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser Ł., Polosukhin I. Attention Is All You Need // Advances in Neural Information Processing Systems (NeurIPS 2017). - 2017. - Vol. 30. - URL: <https://arxiv.org/abs/1706.03762> (дата обращения: 20.04.2026).
24. R. Chirkova et al. "When Does Orthogonal LoRA Help Retrieval? Spectral Preservation, Alignment, and Operating Regimes." TMLR, 2026. URL: <https://openreview.net/forum?id=zhql8bU0QM> (дата обращения: 20.04.2026).
25. ANOVA // Statsmodels Documentation. - URL: <https://www.statsmodels.org/stable/anova.html> (дата обращения: 13.05.2026)
26. Saket A. Aletheia: Gradient-Guided Layer Selection for Efficient LoRA Fine-Tuning Across Architectures // arXiv. — 2026. — URL: <https://browse-export.arxiv.org/abs/2604.15351> (дата обращения: 13.05.2026).
27. Hugging Face PEFT Documentation // Hugging Face Documentation. - URL: <https://huggingface.co/docs/peft/index> (дата обращения: 19.05.2026).

## Приложения

## Приложение А. Ссылка на GitHub, где расположены исходники всего проекта, включая код. Описание структуры репозитория.

Ссылка: <https://github.com/Lemekhova/msc-lemekhova/tree/main>





Рисунок 28. Скриншот репозитория.

Описание структуры репозитория:

- Папка «Анализ и гипотезы» :
  - [Notebooks](#):
    - [analitics.ipynb](#) – анализ по результатам экспериментов
    - [hypotheses.ipynb](#) – проверка гипотез
    - [графики.ipynb](#) – построение графиков для наглядных иллюстраций в тексте
  - [Данные](#) – данные для анализа (результаты экспериментов)
- Папка «Парсинг и подготовка данных»:
  - [Notebooks](#) – скрипты парсинга новостных заголовков на русском языке
  - [Собранные файлы](#) – сырые собранные файлы
  - [result.csv](#) – очищенный датасет
- Папка «Реализация методов»:
  - [methods.ipynb](#) – реализация методов Baseline, LoRA, QLoRA, OrthoGeoLoRA
- Папка «Эксперименты»:
  - [Qwen2\\_AG\\_news\\_EN](#) – эксперименты для Qwen2.5-1.5 и датасета AG\_news
  - [Qwen2\\_PD\\_news\\_RU](#) – эксперименты для Qwen2.5-1.5 и датасета на русском
  - [Qwen3\\_AG\\_news\\_EN](#) – эксперименты для Qwen3-0.6 и датасета AG\_news
  - [Qwen3\\_PD\\_news\\_RU](#) – эксперименты для Qwen3-0.6 и датасета на русском
  - [all\\_exp\\_results.csv](#) – сводные результаты всех экспериментов
- Файл [BKP.pdf](#) – выпускная квалификационная работа
- Файл [Презентация.pdf](#) – защитная презентация

## Приложение Б. Скрипты парсинга новостных заголовков на русском языке

Скрипты парсинга новостных заголовков на русском языке представлены в блокноте на GitHub по адресу <https://github.com/Lemekhova/msc-lemekhova/tree/main>. Папка «Парсинг и подготовка данных»/Notebooks/scraper\_data.ipynb. Реализация осуществляется с помощью языка Python с помощью библиотек Selenium и BeautifulSoup. Для среды кодирования использовался Jupyter Notebook. Отрывки кода можно видеть на рисунках 29 и 30.



### Парсинг названий статей с сайта www.fontanka.ru.

```
In [ ]: import requests
from bs4 import BeautifulSoup
import csv


output_file = "finances_60.csv"

with open(output_file, "w", newline="", encoding="utf-8-sig") as f:
    writer = csv.writer(f)
    writer.writerow(["text", "label"])

    # перебираем страницы
    for page in range(1, 61):
        if page == 1:
            url = "https://www.fontanka.ru/finances/"
        else:
            url = f"https://www.fontanka.ru/finances/page-{page}/"

        print(f"Парсим {url}...")
        response = requests.get(url)
        html = response.content.decode("utf-8", errors="ignore")
        soup = BeautifulSoup(html, "html.parser")
```

Рисунок 29. Отрывок кода парсинга с сайта www.fontanka.ru



### Парсинг названий статей с сайта www.dp.ru.

```
In [ ]: import time
import csv
from bs4 import BeautifulSoup
from selenium import webdriver
from selenium.webdriver.common.by import By

def parse_articles_with_selenium(url, label="realty", max_clicks=10):
    """
    Парсинг статей с возможностью:
    - менять URL
    - задавать label
    """

    options = webdriver.ChromeOptions()
    options.add_argument('--headless')
    options.add_argument('--no-sandbox')
    options.add_argument('--disable-dev-shm-usage')

    driver = webdriver.Chrome(options=options)

    try:
        print(f"Загрузка страницы: {url}")
        driver.get(url)
        time.sleep(5)
```

Рисунок 30. Отрывок кода парсинга с сайта www.dp.ru

## Приложение В. Обработанные данные после парсинга новостных заголовков на русском языке

Результаты парсинга новостных заголовков на русском языке представлены в файле CSV на GitHub по адресу <https://github.com/Lemekhova/msc-lemekhova/tree/main> Папка «Парсинг и подготовка данных»/ [result.csv](#). Отрывок данных можно видеть на Рисунке 31.

| text                                                                                                                 | label  |
|----------------------------------------------------------------------------------------------------------------------|--------|
| В агломерации Петербурга в 2022 году ввели в эксплуатацию 614 тыс. м2 коммерческой недвижимости. Результат превысил  | realty |
| Утверждение нового Генерального плана Петербурга перенесли на следующий год. Причиной в Смольном называют больш      | realty |
| Комитет по градостроительству и архитектуре (КГА) согласовал архитектурно-градостроительный облик Дома молодёжи, к   | realty |
| На строящейся станции петербургского метро "Горный институт" завершаются внутренние работы.                          | realty |
| 39% действующих офисных площадей класса А и В в Петербурге расположены в объектах реконструкции, по данным NF GR     | realty |
| Где искать баланс между природой и городским ритмом                                                                  | realty |
| «Северная корона» оголила историческое нутро. Снос гостиницы приостановили из-за близости к историческим зданиям     | realty |
| Петербургские девелоперы, столкнувшиеся с противодействием своим проектам со стороны общественности, стали всё ча    | realty |
| В паркингах новостроек не хватает мест для электромобилей и гибридов.                                                | realty |
| В Петербурге в минувшем году на 30% выросло число самовольных построек, выявленных Смольным.                         | realty |
| Причаливаем на Васильевском! Как поселиться у моря с комфортом                                                       | realty |
| Миллион за квартал. Лидеры наращивают продажи на фоне общего уменьшения спроса на жилье. Смольный еще думает, и      | realty |
| Фармацевтическая компания "Фармасинтез-Норд" выкупит земельный участок на территории особой экономической зоны       | realty |
| В Петербурге с 2020 по 2025 год под современные нужды приспособили порядка 60 объектов культурного наследия (ОКН),   | realty |
| Кадастровую оценку поручили своим                                                                                    | realty |
| Зима как повод для прогулки: почему холода и плохая погода перестали мешать жителям новостроек                       | realty |
| Федеральный девелопер "Самолет" планирует продать участок на Васильевском острове в Петербурге, сообщил "Ъ-СПб".     | realty |
| В 2025 году объём инвестиций в коммерческую недвижимость, приобретённую на торгах в Петербурге и Ленинградской об    | realty |
| Загородный дом — мечта или реальность?                                                                               | realty |
| В России планируется ввести страхование вкладов до 10 млн рублей для покупки жилья. Соответствующие поправки к зак   | realty |
| На Архивной улице в Невском районе Петербурга ввели в эксплуатацию новый детский сад, рассказала пресс-служба Госст  | realty |
| Ботанический сад, обсерватория, стадион. Как поселиться рядом с будущим университетским кампусом                     | realty |
| Логистический комплекс "Кулон СПб" на Пулковском шоссе выставлен на торги. Начальная цена 100% долей компании сос    | realty |
| Квартиры в Петербурге дешевеют, пригород растёт в цене                                                               | realty |
| Назначенные на 4 июня торги по продаже 250 га бывшего сельхозкооператива "Цветы" на юге Петербурга на границе Пушк   | realty |
| В Петербурге снова заговорили о проекте новой переправы через Неву — Ново-Адмиралтейском мосте. Он был предусмот     | realty |
| В новых домах Петербурга прекратилась снижаться средняя площадь квартир, следует из обзора сервиса "Циан.Аналитика". | realty |
| В Петербурге увеличат площадь мемориального комплекса, посвящённого Ленинградской битве, на Пулковских высотах. О    | realty |
| "Метрострой Северной столицы" показал, как выглядит изнутри почти готовая станция метро "Юго-Западная".              | realty |
| ООО "Строительная фирма "СМУ-10" подала жалобу в Федеральную антимонопольную службу (ФАС) на подведение итогов       | realty |
| В Приморском районе Петербурга готовят демонтажный котлован, куда выйдет тоннелепроходческий комплекс "Надежда"      | realty |
| Топ-10 самых безопасных мест в Европе для инвестиций в недвижимость                                                  | realty |
| Доля ипотечных кредитов на вторичное жилье в России в апреле 2025 года впервые за полгода превысила 50%, достигнув   | realty |
| Губернатор Александр Беглов накануне грядущих выборов градоначальника отменил плановое повышение тарифов на ряд      | realty |
| Проект петербургского «Винзавода» кризис похоронил дважды                                                            | realty |
| Магазин у дома: как развивается стрит-ритейл в Петербурге                                                            | realty |

Рисунок 31. Отрывок обработанных собранных данных с сайтов [www.fontanka.ru](http://www.fontanka.ru) и [www.dp.ru](http://www.dp.ru) — новостные заголовки на русском языке, 4 категории (auto, sport, realty, finances)

## Приложение Г. Реализация базового метода

Реализация метода осуществлялась с помощью языка Python. Для среды кодирования использовался Jupyter Notebook. Блокнот с результатами представлен в репозитории по <https://github.com/Lemekhova/msc-lemekhova/tree/main> Папка «Реализация методов»/methods.ipynb. Отрывок кода можно видеть на Рисунке 32.

```
def load_base_model():
    return AutoModelForSequenceClassification.from_pretrained(
        MODEL_NAME,
        num_labels=num_labels,
        torch_dtype=torch.float16,
        device_map="auto",
        ignore_mismatched_sizes=True
    )

def compute_metrics(eval_pred):
    logits, labels = eval_pred
    predictions = np.argmax(logits, axis=-1)
    return {
        "accuracy": accuracy_score(labels, predictions),
        "f1": f1_score(labels, predictions, average="weighted")
    }

# Заморозка модели (baseline)
def freeze_all_but_head(model):
    for name, param in model.named_parameters():
        if "classifier" not in name and "score" not in name:
            param.requires_grad = False
    return model

# Подсчёт trainable параметров
def count_trainable_params(model):
    return sum(p.numel() for p in model.parameters() if p.requires_grad)

# Обучение + инференс
def train_and_predict(model, train_tok, test_tok, tokenizer):
    args = TrainingArguments(
        output_dir="._outputs/baseline",
        num_train_epochs=1,
```

Рисунок 32. Отрывок реализации базового метода (проводится с заморозкой основной части модели, обучаются только параметры классификационной головы)



## Приложение Д. Реализация метода LoRA

Реализация метода осуществлялась с помощью языка Python. Для среды кодирования использовался Jupyter Notebook. Блокнот с результатами представлен в репозитории по <https://github.com/Lemekhova/msc-lemekhova/tree/main> Папка «Реализация методов»/methods.ipynb. Отрывок кода можно видеть на Рисунке 33.

```
def create_lora_model(rank, target_modules):
    base = load_base_model()

    lora_cfg = LoraConfig(
        r=rank,
        lora_alpha=rank * 2,
        lora_dropout=0.05,
        target_modules=target_modules,
        task_type=TaskType.SEQ_CLS
    )
    return get_peft_model(base, lora_cfg)

def create_training_args(rank, target_modules, output_dir="./outputs"):
    name = f"r{rank}_" + "-".join(target_modules)

    return TrainingArguments(
        output_dir=f"{output_dir}/{name}",
        num_train_epochs=1,
        per_device_train_batch_size=4,
        per_device_eval_batch_size=4,
        fp16=False,
        logging_steps=50,
        eval_strategy="epoch",
        save_strategy="no",
        report_to="none",
        remove_unused_columns=False,
        dataloader_num_workers=4,
        logging_dir=f"{output_dir}/{name}/logs",
    )

def compute_metrics(eval_pred):
    logits, labels = eval_pred
    predictions = np.argmax(logits, axis=-1)
    return {
        "accuracy": accuracy_score(labels, predictions),
        "f1": f1_score(labels, predictions, average="weighted")
    }
```

Рисунок 33. Отрывок реализации базового метода LoRA

## Приложение Е. Реализация метода QLoRA

Реализация метода осуществлялась с помощью языка Python. Для среды кодирования использовался Jupyter Notebook. Блокнот с результатами представлен в репозитории по <https://github.com/Lemekhova/msc-lemekhova/tree/main> Папка «Реализация методов»/methods.ipynb. Отрывок кода можно видеть на Рисунке 34.

```
def create_qlora_model(rank, target_modules, quant_type="nf4"):
    """
    Создает модель с 4-битным квантованием и LoRA адаптерами

    Args:
        rank: ранг LoRA
        target_modules: список модулей для адаптации
        quant_type: тип квантования ("nf4" или "fp4")
    """

    # Конфигурация квантования
    bnb_config = BitsAndBytesConfig(
        load_in_4bit=True,
        bnb_4bit_quant_type=quant_type, # "nf4" или "fp4"
        bnb_4bit_compute_dtype=torch.bfloat16,
        bnb_4bit_use_double_quant=True,
    )

    # Загружаем базовую модель с квантованием
    base_model = AutoModelForSequenceClassification.from_pretrained(
        MODEL_NAME,
        num_labels=num_labels,
        quantization_config=bnb_config,
        device_map="auto",
        torch_dtype=torch.bfloat16,
        trust_remote_code=True
    )

    # Конфигурация LoRA
    lora_config = LoraConfig(
        r=rank,
        lora_alpha=rank * 2,
        target_modules=target_modules,
        lora_dropout=0.05,
        bias="none",
        task_type=TaskType.SEQ_CLS
    )
```

Рисунок 34. Отрывок реализации квантованного метода

## Приложение Ж. Реализация метода OrthoGeoLoRA

Реализация метода осуществлялась с помощью языка Python. Для среды кодирования использовался Jupyter Notebook. Блокнот с результатами представлен в репозитории по <https://github.com/Lemekhova/msc-lemekhova/tree/main> Папка «Реализация методов»/methods.ipynb. Отрывок кода можно видеть на Рисунках 35 и 36.

```
class OrthogonalizationLayer(nn.Module):
    def __init__(self, in_dim, rank, dtype):
        super().__init__()
        # Инициализация параметров малого размера
        self.theta = nn.Parameter(torch.randn(in_dim, rank, dtype=torch.float32) * 0.01)

    def forward(self):
        # QR-разложение для ортогонализации
        q, r = torch.linalg.qr(self.theta, mode="reduced")
        sign = torch.sign(torch.diag(r))
        # Коррекция знаков для стабильности
        q = q * sign.unsqueeze(0)
        return q
```

Рисунок 35. Реализация слоя ортогонализации для OrthoGeoLoRA

```
class OrthoGeoLoRALayer(nn.Module):
    def __init__(self, base_lora_layer):
        super().__init__()

        self.base_layer = base_lora_layer.base_layer

        if isinstance(base_lora_layer.r, dict):
            self.rank = list(base_lora_layer.r.values())[0]
        else:
            self.rank = base_lora_layer.r

        if isinstance(base_lora_layer.scaling, dict):
            self.scaling = list(base_lora_layer.scaling.values())[0]
        else:
            self.scaling = base_lora_layer.scaling

        in_features = self.base_layer.in_features
        out_features = self.base_layer.out_features

        dtype = self.base_layer.weight.dtype

        self.A_orth = OrthogonalizationLayer(in_features, self.rank, dtype)
        self.B_orth = OrthogonalizationLayer(out_features, self.rank, dtype)

        self.log_singular = nn.Parameter(torch.zeros(self.rank, dtype=dtype))

    @property
    def singular(self):
        return F.softplus(self.log_singular) + 1e-6
```

Рисунок 36. Основной модуль OrthoGeoLoRA

### Приложение 3. Результаты всех экспериментов

Результаты всех экспериментов представлены в файле на GitHub по адресу <https://github.com/Lemekhova/msc-lemekhova/tree/main> Папка «Эксперименты»/  
all\_exp\_results.csv.

Отрывок результатов можно видеть на Рисунке 37.

| dataset | model | method    | modules | rank | time     | gpu      | loss     | f1       | accuracy | pst_dataset |
|---------|-------|-----------|---------|------|----------|----------|----------|----------|----------|-------------|
| EN      | qwen3 | baseline  |         |      | 18.60313 | 1.290888 | 0.443604 | 0.881535 | 0.881711 | 30000       |
| EN      | qwen3 | LoRA      | q+v     | 4    | 55.68899 | 3.047973 | 0.297119 | 0.936581 | 0.936579 | 30000       |
| EN      | qwen3 | LoRA      | q+v     | 8    | 55.49884 | 3.055236 | 0.289551 | 0.938929 | 0.938947 | 30000       |
| EN      | qwen3 | LoRA      | q+v     | 16   | 55.51305 | 3.069763 | 0.281006 | 0.938532 | 0.938553 | 30000       |
| EN      | qwen3 | LoRA      | q+v     | 32   | 57.60527 | 3.098815 | 0.260498 | 0.941972 | 0.941974 | 30000       |
| EN      | qwen3 | LoRA      | q+k+v   | 4    | 60.56583 | 3.19067  | 0.294189 | 0.938407 | 0.938421 | 30000       |
| EN      | qwen3 | LoRA      | q+k+v   | 8    | 60.64523 | 3.200923 | 0.284424 | 0.940248 | 0.940263 | 30000       |
| EN      | qwen3 | LoRA      | q+k+v   | 16   | 61.37272 | 3.221431 | 0.274658 | 0.942323 | 0.942368 | 30000       |
| EN      | qwen3 | LoRA      | q+k+v   | 32   | 63.15203 | 3.262447 | 0.450195 | 0.938773 | 0.938816 | 30000       |
| EN      | qwen3 | LoRA      | q+k+v+o | 4    | 66.33633 | 3.468406 | 0.400879 | 0.932738 | 0.932763 | 30000       |
| EN      | qwen3 | LoRA      | q+k+v+o | 8    | 66.17652 | 3.482933 | 0.363037 | 0.936529 | 0.936579 | 30000       |
| EN      | qwen3 | LoRA      | q+k+v+o | 16   | 66.97086 | 3.511985 | 0.261475 | 0.943095 | 0.943158 | 30000       |
| EN      | qwen3 | LoRA      | q+k+v+o | 32   | 69.90403 | 3.570091 | 0.291504 | 0.941583 | 0.941579 | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+v     | 4    | 70.67405 | 2.345311 | 0.305817 | 0.937348 | 0.937368 | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+v     | 8    | 70.702   | 2.363453 | 0.308715 | 0.936431 | 0.936447 | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+v     | 16   | 70.60593 | 2.373127 | 0.286546 | 0.939975 | 0.94     | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+v     | 32   | 71.10907 | 2.405415 | 0.271296 | 0.943774 | 0.943816 | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+k+v   | 4    | 75.25723 | 2.439141 | 0.314004 | 0.936066 | 0.936053 | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+k+v   | 8    | 73.5699  | 2.447541 | 0.307831 | 0.937291 | 0.937368 | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+k+v   | 16   | 74.45158 | 2.474839 | 0.28963  | 0.939809 | 0.939868 | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+k+v   | 32   | 74.83583 | 2.511612 | 0.28014  | 0.940597 | 0.940658 | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+k+v+o | 4    | 80.79419 | 2.612324 | 0.296663 | 0.937836 | 0.937895 | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+k+v+o | 8    | 77.67346 | 2.620541 | 0.277365 | 0.941297 | 0.941316 | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+k+v+o | 16   | 77.35513 | 2.656994 | 0.262291 | 0.942828 | 0.942895 | 30000       |
| EN      | qwen3 | QLoRA nf4 | q+k+v+o | 32   | 78.09856 | 2.715008 | 0.257335 | 0.945643 | 0.945658 | 30000       |
| EN      | qwen3 | QLoRA fp4 | q+v     | 4    | 70.54059 | 2.354832 | 0.314408 | 0.932487 | 0.9325   | 30000       |
| EN      | qwen3 | QLoRA fp4 | q+v     | 8    | 70.46896 | 2.352711 | 0.305279 | 0.934651 | 0.934605 | 30000       |
| EN      | qwen3 | QLoRA fp4 | q+v     | 16   | 70.22256 | 2.375569 | 0.294636 | 0.937363 | 0.937368 | 30000       |
| EN      | qwen3 | QLoRA fp4 | q+v     | 32   | 71.81199 | 2.401753 | 0.283977 | 0.940528 | 0.940526 | 30000       |
| EN      | qwen3 | QLoRA fp4 | q+k+v   | 4    | 75.21136 | 2.437432 | 0.3154   | 0.935308 | 0.935263 | 30000       |
| EN      | qwen3 | QLoRA fp4 | q+k+v   | 8    | 74.98937 | 2.4534   | 0.298222 | 0.937895 | 0.937895 | 30000       |
| EN      | qwen3 | QLoRA fp4 | q+k+v   | 16   | 75.03643 | 2.471421 | 0.289275 | 0.939186 | 0.939211 | 30000       |
| EN      | qwen3 | QLoRA fp4 | q+k+v   | 32   | 75.61725 | 2.516495 | 0.279283 | 0.941534 | 0.941579 | 30000       |
| EN      | qwen3 | QLoRA fp4 | q+k+v+o | 4    | 80.34188 | 2.60526  | 0.298337 | 0.936135 | 0.936184 | 30000       |
| EN      | qwen3 | QLoRA fp4 | q+k+v+o | 8    | 79.08074 | 2.622006 | 0.285707 | 0.939449 | 0.939474 | 30000       |
| EN      | qwen3 | QLoRA fp4 | q+k+v+o | 16   | 78.67437 | 2.650891 | 0.274107 | 0.941536 | 0.941579 | 30000       |

Рисунок 37. Отрывок данных - результаты всех экспериментов