

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК**

Лемехова Ольга Александровна

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Исследование методов эффективного применения адаптеров (LoRA) для
дообучения моделей в условиях ограниченных вычислительных ресурсов

по направлению 01.04.02 Прикладная математика и информатика
образовательная программа «Аналитика больших данных»

Студент

О.А. Лемехова

Научный руководитель

старший преподаватель
департамента больших данных и
информационного поиска ФКН НИУ ВШЭ
Е.А. Паточенко

Соруководитель

Ведущий специалист по науке о данных
ООО Ле Монлид Цифровые Технологии
Е.В. Гаврилова

Москва 2026

ОГЛАВЛЕНИЕ

Аннотация	4
Список ключевых слов	4
Глава 1. Введение	5
1.1. Актуальность исследования	5
1.2. Цель и задачи исследования	6
1.3. Объект и предмет исследования	7
1.4. Научная новизна	7
1.5. Практическая значимость	8
Глава 2. Обзор литературы и теоретические основы.....	8
2.1. Проблема дообучения LLM в условиях ограниченных ресурсов.....	8
2.2. Parameter-Efficient Fine-Tuning (PEFT).....	8
2.3. Метод LoRA и его развитие	8
2.4. Совместное применение LoRA и квантизации	9
2.5. Геометрические и структурные расширения LoRA	9
2.6. Выводы	10
Глава 3. Данные	10
3.1. Описание и источники данных	10
3.2. Сбор, очистка и предобработка данных	12
3.3. Формирование обучающих выборок	12
Глава 4. Описание методологии эксперимента	13
4.1. Open-source библиотеки для дообучения LLM.....	13
4.2. Подходы к дообучению	14
4.3. Метрики для оценки	15
4.4. Ограничения экспериментов	15
4.5. Постановка NLP-задачи	16
4.6. Выбор базовой языковой модели	17
4.7. Предобработка данных	18
Глава 5. Построение базовой модели.....	18
5.1. Конфигурация	18
5.2. Результаты базовой конфигурации.....	19
Глава 6. Дообучение языковой модели с использованием LoRA, QLoRA и OrthoGeoLoRA ...	20
6.1. Исследуемые параметры LoRA.....	20
6.2. Интеграция LoRA в архитектуру модели.....	21
6.3. Методы квантизации - QLoRA.....	21
6.4 Геометрическая модификация - OrthoGeoLoRA	22

6.5. Экспериментальная схема обучения	24
Глава 7. Анализ и визуализация результатов	25
7.1. Методология анализа и статистические методы	25
7.2 Выявленные зависимости и закономерности	26
7.2.1. Сравнение моделей	26
7.2.2. Исследование влияния ранга LoRA на качество адаптации	27
7.2.3. Расширение target modules. Сравнение: $q+v$, $q+k+v$, $q+k+v+o$	29
7.2.4. QLoRA vs LoRA	31
7.2.5. FP4 vs NF4	33
7.2.6. Baseline vs LoRA	33
7.2.7. Влияние языка (RU vs EN)	34
7.2.8. Метод OrthoGeoLoRA (OGLoRA)	35
7.3 Количественные зависимости и закономерности	37
7.4 Общие выводы	39
7.5 Выбор оптимальных конфигураций	40
8. Заключение	44
Приложения	49

Аннотация

Список ключевых слов

Глава 1. Введение

1.1. Актуальность исследования

С каждым годом большие языковые модели (LLM) показывают все большую эффективность в области обработки естественного языка, включая генерацию, суммаризацию и классификацию текста. Однако, использование LLM ограничено в условиях лимитированной инфраструктуры (одиночные GPU, локальные машины, исследовательские среды). В последнее время, можно наблюдать внедрение компактных моделей (0.5-7 млрд параметров), например семейства Qwen [21]. Их применение более доступно. Однако, применение даже таких моделей зависит от располагаемых вычислительных ресурсов.

Т.к. полное дообучение все еще требует больших объемов видеопамяти (VRAM), времени и вычислительных мощностей, в практике распространены параметрически эффективные методы дообучения (PEFT - parameter-efficient fine-tuning), среди которых одно из популярных – LoRA (Low-Rank Adaptation) и ее вариаций, направленных на экономию ресурсов и достижение конкурентного качества, их число растет каждый год [2]. Такие подходы позволяют снизить вычислительные затраты за счет того, что обновляют только небольшую часть обучаемых параметров модели, но в итоге выдают конкурентное качество.

Эффективность методов PEFT зависят от выбираемых параметров, таких как ранг адаптеров (rank), выбор модулей (target modules), тип квантизации, объем данных, язык обучающей выборки и т.д. В существующих работах часто данные параметры рассматриваются изолированно, либо в ограниченных сценариях [19]. Отмечается недостаток исследований, направленных на разработку конфигураций, адаптированных под конкретные задачи и условия применения [18]. В отсутствие конкретных рекомендаций часто подбор параметров в практических работах осуществляется методом проб и ошибок [17], что требует проведения большого количества экспериментов для нахождения оптимальных значений [18].

Также, в литературе наблюдается недостаточное количество исследований, направленных на комплексный анализ влияния этих факторов в совокупности, в частности, в контексте задач классификации коротких текстов в условиях ограниченных ресурсов [19]. Так, я не обнаружила систематизированные рекомендации по выбору конфигураций для LoRA и ее модификаций, таких, чтобы обеспечивали оптимальный компромисс между качеством модели и затратами ресурсов (время обучения, потребление GPU-памяти). В литературе в основном проводится сравнительный анализ методов LoRA без особого внимания к их настройкам и вариантам ограниченности исходных данных [20].

Таким образом, актуальность данного исследования можно обосновать:

1. необходимостью экономии вычислительных затрат при дообучении языковых моделей;

2. отсутствием практических рекомендаций по выбору конфигураций LoRA и ее модификаций (в частности для задач классификации текстов);
3. отсутствием комплексного анализа влияния параметров PEFT-методов на качество и эффективность.

1.2. Цель и задачи исследования

Целью работы является выявление закономерностей и определение оптимальных конфигураций методов параметрически эффективного дообучения (LoRA, QLoRA и их модификаций), обеспечивающих наилучший компромисс между точностью и вычислительными затратами (время, VRAM) при работе с языковыми моделями в условиях ограниченной инфраструктуры.

Таким образом, основной задачей стоит исследование влияния параметров методов параметрически эффективного дообучения (LoRA, QLoRA и их модификаций) на качество и вычислительную эффективность языковых моделей, а также выявление закономерностей и количественная оценка компромисса между точностью и ресурсными затратами для определения оптимальных конфигураций в условиях ограниченной инфраструктуры.

Таким образом, решаемая задача является многокритериальной, т.е. для каждой конфигурации из спектра параметров (rank, набор адаптируемых модулей, тип квантизации, объём данных) необходимо оценить одновременно и показатели качества (accuracy, F1) и ресурсоёмкость (VRAM, время обучения). При этом задача классификации текста в данной работе выступает своего рода бенчмарком, т.е. управляемой экспериментальной средой, которая позволяет получить воспроизводимые эксперименты и сопоставимые результаты по всем вариантам конфигураций.

Для реализации поставленных задач предусматривается выполнение следующих шагов:

1. Провести анализ современных PEFT-методов (LoRA, QLoRA, OrthoGeoLoRA).
2. Изучить особенности применения данных методов в условиях ограниченных вычислительных ресурсов.
3. Подготовить экспериментальную среду и датасеты (англоязычные и русскоязычные).
4. Реализовать baseline-подход и методы дообучения (LoRA, QLoRA, OrthoGeoLoRA) для задач классификации текстов.
5. Провести серию экспериментов на различных предобученных моделях разного размера (Qwen2.5-1.5B и Qwen3-0.6B) с варьированием параметров: rank (4, 8, 16, 32), набора модулей (q_v, q_k_v, q_k_{vo}), типа квантизации (nf4, fp4), объёма обучающей выборки.
6. Оценить влияние параметров конфигурации на показатели качества (accuracy, F1).
7. Проанализировать вычислительные затраты (время обучения, потребление GPU-памяти).

8. Исследовать зависимости и выявить закономерности между параметрами модели, качеством и ресурсами.
9. Количественно оценить баланс между качеством и вычислительными затратами для каждого метода и конфигурации.
10. Определить конфигурации, обеспечивающие наилучший компромисс между качеством и ресурсоёмкостью, и сформулировать практические рекомендации.

1.3. Объект и предмет исследования

Объект - закономерности и компромисс между качеством классификации и вычислительными ресурсами при использовании методов LoRA, QLoRA и их модификаций.

Предмет - зависимости между параметрами методов параметрически эффективного дообучения (rank, набор адаптируемых модулей, тип квантизации, объём данных) и показателями качества модели и вычислительных затрат.

1.4. Научная новизна

Научная новизна работы заключается в следующем:

1. В работе проведен многокритериальный анализ пространства конфигураций LoRA, QLoRA и OrthoGeoLoRA для моделей семейства Qwen разного размера (0.6B и 1.5B), а именно проведена совместная оценка по четырём осям (rank, набор модулей, тип квантизации, объём данных) с одновременным измерением качества и ресурсоёмкости.
2. Показано, при каких значениях ранга дальнейшее увеличение качества модели перестаёт давать значимый прирост точности при продолжающемся росте потребления VRAM, а также выявлено различное влияние rank при разном объеме данных на разных моделях.
3. Проведен анализ взаимодействия факторов (ранг и объём обучающих данных, набор модулей и ресурсы, и т.д.), позволяющий выявить эффективные конфигурации.
4. В сравнительный анализ включена новая вариация LoRA - OrthoGeoLoRA [Wang et al., 2026].
5. Проведено исследование влияния объёма обучающих данных на эффективность PEFT для русского и английского языков в условиях одного GPU. Определен порог объёма данных, начиная с которого различия в эффективности конфигураций LoRA становятся незначительными, а влияние PEFT меняется.
6. Установлены различия в поведении моделей разных архитектур и масштабов (Qwen2.5 vs Qwen3), которые заключаются в разной чувствительности к параметрам PEFT и объёму исходных данных.
7. Выявлены зависимости между точностью, потреблением VRAM и временем обучения, формирующие воспроизводимый бенчмарк для оценки будущих PEFT-методов.

8. Сформулированы практические рекомендации по выбору конфигураций PEFT в условиях ограниченных вычислительных ресурсов, в том числе если в распоряжении слишком малая выборка для обучения.

1.5. Практическая значимость

Разработанный подход может использоваться для быстрой классификации текста на основе LLM при ограниченных вычислительных ресурсах, например, классификация в новостных агрегаторах, для задач классификации обращений в поддержку или в государственные органы и т.п.).

Результаты позволяют осознанно выбирать модель, ранг, набор модулей и метод квантизации без полного перебора конфигураций на основе имеющихся данных.

Выявленные зависимости от объёма данных помогают оценить минимально достаточную выборку либо выбрать подход работы с уже имеющимися данными ограниченного объёма.

Реализованные эксперименты могут служить бенчмарком для сравнения будущих PEFT-методов, включая OrthoGeoLoRA.

Глава 2. Обзор литературы и теоретические основы

2.1. Проблема дообучения LLM в условиях ограниченных ресурсов

Основные проблемы дообучения LLM в условиях ограниченных ресурсов - это высокие требования к видеопамяти, длительное время обучения и значительные затраты на хранение моделей при дообучении LLM в условиях ограниченных ресурсов (например, одной GPU).

2.2. Parameter-Efficient Fine-Tuning (PEFT)

Существующие методы дообучения (PEFT) позволяют адаптировать модели за счёт обучения лишь небольшой части параметров, что снижает требования к памяти и вычислениям, ускоряет обучение и упрощает воспроизводимость экспериментов. Среди различных подходов PEFT наибольшее практическое распространение получили методы, основанные на низкоранговой параметризации обновлений весов, прежде всего - семейство LoRA [1].

2.3. Метод LoRA и его развитие

Метод Low-Rank Adaptation (LoRA) является одним из наиболее эффективных и широко используемых подходов PEFT. Его ключевая идея заключается в представлении обновлений весов в виде произведения двух матриц малого ранга ($\Delta W = BA^T$), при этом исходные веса модели остаются замороженными [2]. LoRA обеспечивает значительное сокращение числа обучаемых параметров, тем самым снижая требования к памяти и обеспечивая качество, сопоставимое с

полным дообучением. LoRA применяется к слоям внимания трансформера (например, проекциям q , k , v , o), однако его эффективность зависит от выбора параметров.

На базе LoRA сформировалось активное направление исследований, направленное на улучшение эффективности и адаптивности этого метода, среди которых:

QLoRA, L4Q, CoA-LoRA - LoRA сочетается с 4-битной квантизацией весов, что позволяет дообучать крупные модели затрачивая меньше памяти и сохраняя уровень качества [1][13][14][15].

AdaLoRA, DoRA, GLoRA - вводят адаптивное распределение ранга и более гибкую параметризацию обновлений [3].

ARD-LoRA и GeLoRA - предлагают динамическое или теоретически обоснованное распределение ранга между слоями и головами внимания [4][5].

LoRA Soups - исследуют объединение нескольких LoRA-адаптеров для формирования мультизадачных моделей и т.д. [6]

OrthoGeoLoRA - вводит геометрические ограничения на параметры адаптеров [7] и т.д.

Таким образом, LoRA стал базовой архитектурой, вокруг которой формируется широкая система методов, направленных на повышение эффективности использования параметров.

2.4. Совместное применение LoRA и квантизации

Даже при использовании LoRA основная модель остаётся ресурсоёмкой. Поэтому важным направлением является сочетание LoRA с квантизацией.

Ключевой метод в этом направлении - QLoRA квантует веса модели до 4 бит (например NF4, FP4), обучает только LoRA-адаптеры и позволяет дообучать модели на одной GPU [1][13].

2.5. Геометрические и структурные расширения LoRA

Одним из современных направлений развития является метод OrthoGeoLoRA (Orthogonal Geometric Low-Rank Adaptation), который вводит геометрические ограничения на параметры адаптеров [Wang et al., 2026] [7]. В отличие от стандартного LoRA ($\Delta W = BA^T$), он использует разложение вида: $\Delta W = B\Sigma A^T$, где матрицы имеют ортонормированные столбцы.

Преимущества подхода состоит в более стабильной оптимизации, предотвращении коллапса ранга, более эффективном использовании параметров, улучшенном качестве без увеличения вычислительных затрат [7].

Данный подход показывает, что дальнейшее развитие LoRA связано не только с выбором ранга и квантизации, но и с геометрией параметрического пространства.

2.6. Выводы

Большинство современных исследований в части формирования новых методов LoRA сосредоточено на решении задач экономии ресурсов и их число продолжает расти, а интерес к поиску наиболее эффективных настроек не иссякает. Остается еще ряд вопросов, которые могут быть изучены, такие как выбор оптимального ранга, чувствительность слоёв модели, неочевидная деградация качества при более «мощных» параметрах, влияние квантизации на стабильность обучения, зависимость эффективности от объёма данных, отсутствие практических рекомендаций для разных языков, в том числе для русского.

Систематических сравнительных исследований, объединяющих все перечисленные факторы, в литературе не обнаружена, а именно к задаче классификации коротких текстов для разных языков в условиях ограниченных ресурсов. Обзорные исследования в основном проводятся на английских данных и не учитывают специфику морфологически богатых языков (русский, немецкий, финский).

LoRA является центральным методом *parameter-efficient fine-tuning* и фактически стандартом для дообучения языковых моделей в условиях ограниченных ресурсов. Вокруг него сформировалось активное исследовательское направление, включающее адаптивные, геометрические и квантизационные расширения. Наиболее практичными на сегодняшний день являются комбинации LoRA и QLoRA, обеспечивающие хороший баланс между качеством и вычислительными затратами, а также различные новые методы, повышающие эффективность параметризации.

Далее в работе основное внимание будет уделено экспериментальному анализу эффективности применения LoRA и его вариантов при дообучении моделей семейства Qwen для задач классификации текста (EN, RU). Будут рассмотрены различные значения ранга (4, 8, 16, 32), конфигурации адаптации ($q+v$, $q+k+v$, $q+k+v+o$), методы LoRA, QLoRA (NF4, FP4) и OrthoGeoLoRA, а также влияние объёма обучающей выборки на качество при различных конфигурациях параметров.

Глава 3. Данные

3.1. Описание и источники данных

Работа проводилась на двух вариантах данных:

1) **Эталонный набор данных - AG_News – английский язык:**

Набор данных AG по классификации новостных тем на английском языке (Версия 3, 09.09.2015)

ИСТОЧНИК

AG - это коллекция из новостных статей. Новостные статьи были собраны ComeToMyHead из более чем 2000 источников за более чем год работы. ComeToMyHead - это академическая поисковая система новостей, работающая с июля 2004 года. Набор данных предоставляется академическим сообществом для исследовательских целей в области интеллектуального анализа данных (кластеризация, классификация и т. д.), поиска информации (ранжирование, поиск и т. д.), XML, сжатия данных, потоковой передачи данных и любой другой некоммерческой деятельности.

Набор данных для классификации новостных тем, созданный AG, разработан Сян Чжаном (xiang.zhang@nyu.edu). Он используется в качестве эталонного набора данных для классификации текста в следующей статье: Xiang Zhang, Junbo Zhao, Yann LeCun. Character-level Convolutional Networks for Text Classification. Advances in Neural Information Processing Systems 28 (NIPS 2015).

ОПИСАНИЕ

Набор данных для классификации новостных тем формируется путем выбора 4 крупнейших классов из исходного корпуса. Каждый класс содержит 30 000 обучающих и 1900 тестовых образцов. Классы строго сбалансированы. Общее количество обучающих образцов составляет 120 000, а тестовых - 7600.

Файл classes.txt содержит список классов, соответствующих каждой метке. Файлы train.csv и test.csv содержат все обучающие выборки в виде значений, разделенных запятыми [16].




Рисунок 1. Распределение длины текста в датасете AG_News (EN)

2) Самостоятельно собранные данные (далее – PD_News от parsed data news) – заголовки новостных статей русскоязычных сайтов.

ИСТОЧНИК

Данные были собраны самостоятельно с русскоязычных новостных сайтов Санкт-Петербурга fontanka.ru («Фонтанка») и dp.ru («Деловой Петербург») с помощью библиотек Selenium и BeautifulSoup. (приложение)

ОПИСАНИЕ

Представляют собой набор заголовков новостных статей по четырем темам: Спорт, Недвижимость, Финансы, Авто.

В итоге формируется набор данных, разбитый на 4 класса (sport, realty, finances, auto). В каждом классе по 10265 образцов. Классы сбалансированные. Общее количество образцов составляет - 41060, что соответствует **34,2%** от количества образцов эталонного набора данных.




Рисунок 2. Распределение длины текста в датасете PD_News (RU)

3.2. Сбор, очистка и предобработка данных

Данные AG_News – эталонные, не требующие дополнительной очистки или обработки.

Данные PD_News были предобработаны и очищены: удалены повторяющиеся заголовки, лишние символы и «мусор», удалены технические наименования, наименования подразбук и авторы статей, например «Александр Исаев. Страхование.:» , «Надежда Кузнецова. Налоги.:» или «(фото, видео)» и т.п. (ссылка на ноутбук - [data_preprocessing.ipynb](#)).

Следует отметить, что в среднем длина заголовков русскоязычных данных короче, чем англоязычных, с этим, в том числе, будут связаны некоторые различия в поведении метрик.

3.3. Формирование обучающих выборок

Данные AG_News уже имеют разбивку на тренировочную и тестовую выборки в размере 30 000 и 1 900 заголовков в каждом классе соответственно. Общее количество обучающих образцов – 120 000, а тестовых - 7600.

Для данных PD_News с помощью функции train_test_split библиотеки sklearn в каждом классе было сформировано 8212 обучающих и 2053 тестовых образцов (деление 80/20%).

Обучающая выборка составляет 27% от обучающей выборки AG_News. Общее количество обучающих образцов составляет 32848, а тестовых — 8212.

Размеры обучающих выборок для экспериментов:

Эксперименты на подвыборках датасета AG_News - **EN**:

- 1% (1 200 заголовков, по 300 в каждой категории)
- 5% (6 000 заголовков, по 1 500 в каждой категории)
- 10% (12 000 заголовков, по 3 000 в каждой категории)
- 27% (32 000 заголовков, по 8 000 в каждой категории)
- 50% (60 000 заголовков, по 15 000 в каждой категории)
- 100% (120 000 заголовков, по 30 000 в каждой категории)

Эксперименты на подвыборках самостоятельно собранного датасета PD_News - **RU**:

- 3,6% (1 200 заголовков, по 300 в каждой категории) – 1% AG_News
- 18% (6 000 заголовков, по 1 500 в каждой категории) – 5% AG_News
- 37% (12 000 заголовков, по 3 000 в каждой категории) – 10% AG_News
- 97% (32 000 заголовков, по 8 000 в каждой категории) – 27% AG_News
- 100% (32 848 заголовков, по 8 212 в каждой категории) – 34% AG_News

Глава 4. Описание методологии эксперимента

4.1. Open-source библиотеки для дообучения LLM

Современные исследования в области дообучения больших языковых моделей активно поддерживаются развитой экосистемой open-source инструментов. Наиболее распространённые библиотеки ориентированы на упрощение интеграции методов parameter-efficient fine-tuning (PEFT), включая LoRA и его модификации.

Ключевыми инструментами являются:

- Transformers (Hugging Face) - базовая библиотека для работы с предобученными языковыми моделями, предоставляющая унифицированный интерфейс для обучения, инференса и токенизации [8];
- PEFT (Parameter-Efficient Fine-Tuning) - специализированная библиотека, реализующая методы LoRA, QLoRA, Prefix Tuning и другие подходы [9];
- BitsAndBytes - библиотека для низкобитной квантизации (4-bit, 8-bit), используемая в QLoRA [10];
- Accelerate - инструмент для оптимизации обучения и эффективного использования доступных вычислительных ресурсов [11].

Данные библиотеки обеспечивают быструю интеграцию LoRA в архитектуру модели, поддержку квантизации (NF4, FP4), воспроизводимость экспериментов, возможность работы в условиях ограниченных ресурсов (одна GPU).

Таким образом, современный стек инструментов делает практическое применение LoRA и QLoRA доступным даже при ограниченной вычислительной инфраструктуре.

4.2. Подходы к дообучению

Full Fine-Tuning характеризуется крайне высокой вычислительной стоимостью и требует значительных ресурсов видеопамяти. В условиях ограниченной инфраструктуры (одиночная GPU, локальная машина) его применение затруднено, поэтому в данной работе данный подход не рассматривается [12].

В качестве базовой точки отсчёта (baseline) используется модель с частичным дообучением (**head-only**), при котором обучается только классификационная голова, а остальные параметры остаются замороженными. Такой подход отличается низкими требованиями к ресурсам, высокой скоростью обучения и простотой реализации, однако, как правило, уступает по качеству более гибким методам адаптации. Реализация baseline представлена в **Приложении** и подробно описана в главе 5.

Далее в работе рассматриваются методы параметрически эффективного дообучения (PEFT), поскольку целью исследования является анализ влияния параметров таких методов (в первую очередь LoRA, QLoRA и их модификаций).

Ключевым представителем данного класса является метод **LoRA** (реализация метода в **приложении**), основанный на обучении низкоранговых добавок к весам модели вместо полного обновления параметров. Его развитием является **QLoRA** (реализация метода в **приложении**), дополнительно использующий низкоразрядную (4-битную) квантизацию весов, что существенно снижает потребление видеопамяти. В работе рассматриваются форматы квантизации NF4 и FP4. Также анализируется модификация **OrthoGeoLoRA** (реализация в **приложении**), направленная на улучшение качества адаптации за счёт введения дополнительных ограничений на обучаемые матрицы [1][7][13]. Подробное описание рассматриваемых методов приведены в главе 6.

Каждый эксперимент повторялся 3 раза. Для анализа использовались усреднённые значения метрик с исключением выбросов, определяемых на основе стандартного отклонения (**приложение №, наименование ноутбука**).

LoRA и его расширения фактически стали стандартом дообучения LLM в условиях ограниченных ресурсов, а большинство современных исследований направлены на развитие и улучшение данной парадигмы. В рамках работы проводится сравнительный анализ подходов: head-only, LoRA, QLoRA (NF4, FP4) и OrthoGeoLoRA.

4.3. Метрики для оценки

Для комплексного анализа эффективности методов используются как качественные, так и ресурсные метрики.

Метрики качества:

- Ассигасу - основная метрика классификации, поскольку задача классификации новостных заголовков предполагает выбор одного корректного класса, а ассигасу напрямую отражает долю правильно классифицированных примеров. Эта метрика легко интерпретируема и позволяет сравнивать различные конфигурации моделей.
- F1-score (weighted) - учитывает баланс классов;
- Loss (cross-entropy) - характеризует процесс обучения. В отличие от ассигасу и F1, которые оценивают итоговое качество, функция потерь отражает степень уверенности модели в предсказаниях и позволяет выявлять проблемы обучения, такие как переобучение или численная нестабильность (например, возникновение NaN).

Ресурсные метрики:

- время обучения. Выбрано как ключевой показатель вычислительной стоимости. Эта метрика позволяет оценить практическую применимость различных конфигураций.
- потребление GPU-памяти. Является критически важным показателем при использовании PEFT-методов, так как одной из их ключевых задач является снижение требований к видеопамяти. Сравнение методов по этому параметру позволяет оценить их пригодность для использования на ограниченном оборудовании.

Такой набор метрик позволяет оценить не только точность модели, но и её практическую применимость в условиях ограниченных ресурсов.

4.4. Ограничения экспериментов

Проводимое исследование имеет ряд ограничений:

- использование одной GPU и ограниченной видеопамяти. Все эксперименты проводились в контролируемых условиях на локальной вычислительной системе (GPU: AMD Radeon RX 9070 XT, RAM: 32 GB) с минимизацией фоновой нагрузки, что обеспечивало сопоставимость полученных результатов;
- фиксированное число эпох (1), что ограничивает сходимость моделей;
- ограниченный набор моделей (Qwen2.5-1.5B и Qwen3-0.6B);
- исследование проводится на задаче классификации (без генеративных задач);
- ограниченный набор данных (2 языка (EN, RU) из определенной сферы) ограниченного объема;

- фиксированные гиперпараметры (dropout, scaling).

Также следует учитывать, что:

- результаты могут зависеть от случайной инициализации (seed), поэтому во всех экспериментах seed фиксирован и равен 42;
- условия проведения экспериментов, фиксированные гиперпараметры и используемые конфигурации обеспечивают воспроизводимость полученных результатов при повторении вычислений в аналогичной программно-аппаратной среде;
- в связи с ограниченным объёмом доступных данных для русскоязычного датасета, в целях обеспечения чистоты экспериментов для сопоставительного анализа влияния языка данных эксперименты проводились на датасете, составленном из двух выборок - AG_news (EN) и PD_news (RU) - в эквивалентном диапазоне, а именно по 300, 1500, 3000 и 8000 образцов на каждый класс обучающей выборки. Для экспериментов по оценке влияния квантизации, типов адаптеров, рангов и архитектур моделей был использован эталонный англоязычный датасет AG_news. Для него были сформированы выборки объёмом 300, 1500, 3000, 8000, 15000 и 30000 примеров на каждый класс обучающей выборки.

4.5. Постановка NLP-задачи

В рамках данной работы рассматривается классификации текстов как частный случай задач обработки естественного языка (Natural Language Processing, NLP). Основное внимание уделяется исследованию эффективности методов дообучения языковых моделей с использованием адаптеров типа LoRA в условиях ограниченных вычислительных ресурсов.

Формализация задачи:

Пусть задана $D = \{(x_i, y_i)\}_{i=1}^N$ обучающая выборка:

где (x_i) — текстовый документ, а (y_i) — соответствующая метка класса.

дописать

Рассматриваемая задача характеризуется следующими особенностями:

- использование моделей различного масштаба (1.5B и 0.6B параметров);
- данные на разных языках (английский и русский языки);
- ограниченные ресурсы (ограничения по памяти, времени обучения и ограниченный объем обучающей выборки);
- необходимость эффективного дообучения модели без полного дообучения всех параметров.

Основная цель - определить конфигурации, обеспечивающие наилучший компромисс между качеством модели и вычислительными затратами.

Таким образом, задача формулируется как многокритериальная оптимизация, в которой необходимо максимизировать качество модели при одновременной минимизации вычислительных затрат.

Задача: Классификация текстов

Размер обучающей выборки:

количество новостных заголовков в одном классе обучающей выборки:						
EN:	30000	/	15000	/	8000/	3000 / 1500 / 300
RU:	-	/	8212	/	8000/	3000 / 1500 / 300

Параметры обучения:

batch size: 4

число эпох: 1

максимальная длина: 256 токенов

оптимизация: стандартный Trainer из Hugging Face Transformers

смешанная точность: не используется (fp16=False) (отключен из-за особенностей используемой видеокарты)

4.6. Выбор базовой языковой модели

В качестве базовых моделей используются современные предобученные трансформерные архитектуры. Выбор пал на модели **Qwen2.5-1.5B** и **Qwen3-0.6B**, поскольку они из одного семейства, но представляют разные масштабы (1.5 млрд и 0.6 млрд параметров соответственно) и доступны в открытом доступе, что обеспечивает воспроизводимость результатов исследования.

Семейство моделей Alibaba Qwen 3 – это трансформерная модель архитектуры Mixture-of-Experts (MoE). Ключевые инновации включают гибридную систему рассуждений, предлагающую режимы «мышления» и «немышления» для адаптивной обработки, а также поддержку расширенных контекстных окон, повышающих эффективность и масштабируемость [21].

Qwen2.5 от Alibaba - это языковая модель, использующая только декодер, доступна в различных размерах. Эта модель предварительно обучена на больших наборах данных, поддерживая расширенную длину контекста и многоязычную коммуникацию. Семейство включает в себя специализированные модели для кодирования, математики и мультимодальных задач, таких как обработка изображений и звука [22].

Выбор данных моделей обусловлен следующими факторами:

- наличие предобучения на больших корпусах текстов;
- поддержка эффективных методов дообучения (LoRA, QLoRA);
- различие в размере моделей, позволяющее анализировать влияние масштаба.

Архитектура

Используемые модели основаны на архитектуре трансформера [23]. Для решения задачи классификации в архитектуру добавляется классификационная голова, принимающая выходное представление модели и отображающая его в пространство классов.

Таблица 2

Различия моделей

Характеристика	Qwen2.5-1.5B	Qwen3-0.6B
Поколение	Qwen2.5 (2024 г)	Qwen3 (2025 г)
Параметры	1.5B	0.6B
Контекст	до 128K	~32K
Архитектура	Transformer + GQA	Улучшенный Transformer
Обучение	~18 трлн токенов	~36 трлн токенов
На диске	3 ГБ	1–1.3 ГБ

4.7. Предобработка данных

Перед обучением данные проходят этап токенизации:

- используется токенизатор, соответствующий выбранной модели;
- применяется усечение последовательностей до длины 256 токенов;
- используется padding до максимальной длины (padding="max_length");
- текстовая колонка преобразуется в формат, пригодный для PyTorch;
- целевая переменная приводится к формату labels.

Для формирования батчей используется динамический паддинг через DataCollatorWithPadding.

Глава 5. Построение базовой модели

5.1. Конфигурация

Для анализа эффективности методов адаптации (LoRA и QLoRA) необходимо было задать базовую точку отсчёта - baseline-модель. В рамках данной работы baseline представляет собой предобученную языковую модель с минимальными изменениями, дообучаемую только за счёт классификационной головы. Таким образом, количество обучаемых параметров минимально, что позволяет оценить качество модели без применения адаптеров.

Особенности baseline-обучения

В baseline-подходе обучение проводится с заморозкой основной части модели, все параметры базовой языковой модели фиксируются, обучаются только параметры

классификационной головы (classifier / score). Количество обучаемых параметров при этом существенно меньше общего числа параметров модели, что снижает вычислительную нагрузку и требования к памяти.

Реализация метода и результаты экспериментов для baseline представлены:

в **приложении И** для Qwen2.5-1.5 и AG_news (EN) для разного объема выборок;

в **приложении И** для Qwen3-0.6 и AG_news (EN) для разного объема выборок;

в **приложении И** для Qwen2.5-1.5 и PD_news (RU) для разного объема выборок;

в **приложении И** для Qwen3-0.6 и PD_news (RU) для разного объема выборок.


Для оценки baseline-модели используются определенные в главе 4 метрики для всех экспериментов: accuracy, F1-score, loss, время обучения, потребление GPU памяти на обучение. Используя все вариации модификации экспериментов для baseline в дальнейшем анализе участвуют результаты 22 экспериментов. Полученные значения метрик представлены в **приложении N**.

5.2. Результаты базовой конфигурации

Базовая модель задаёт границу качества, относительно которой оценивается эффективность других методов обучения - LoRA, QLoRA и OrthoGeoLoRA.

Проведённые эксперименты показывают, что:

- качество базовой модели определяется типом модели;
- обучение по базовой конфигурации обеспечивает низкие вычислительные затраты;
- увеличение объёма обучающей выборки приводит к росту качества модели. Хорошие результаты по *accuracy* можно наблюдать уже на объеме 3000 образцов в каждом классе обучающей выборки.
- Qwen3-0.6 показывает более высокое качество и меньший расход GPU на базовой конфигурации.
- На больших моделях (Qwen2.5-1.5) Baseline-подход демонстрирует низкую эффективность: увеличение объёма данных и вычислительных ресурсов не приводит к устойчивому росту качества, что подтверждает необходимость применения методов параметрически эффективного дообучения, таких как LoRA и ее модификаций.



Заменить картинки на актуальные Рисунок 3. Сравнение моделей по качеству, застратам GPU и времени для baseline с указанием объема обучающей выборки

Глава 6. Дообучение языковой модели с использованием LoRA, QLoRA и OrthoGeoLoRA

В данной главе рассматривается применение методов параметр-эффективного дообучения (PEFT) для двух языковых моделей: Qwen2.5-1.5B и Qwen3-0.6B с использованием LoRA, её квантованных модификаций (QLoRA) и геометрических модификаций (OrthoGeoLoRA) на примере задачи классификации двух различных датасетов на английском и русском языках. Основной целью является исследование компромисса между качеством модели, временем обучения, потреблением GPU-памяти и размером выборки при различных конфигурациях.

6.1. Исследуемые параметры LoRA

В ходе экспериментов варьировались ключевые гиперпараметры LoRA:

1) Ранг (rank, r)

Рассматривались значения: $r = 4, 8, 16, 32$

Что позволяет оценить влияние ранга на качество модели (accuracy, F1), время обучения и использование памяти

2) Набор адаптируемых модулей

Были исследованы следующие конфигурации: $(q + v)$, $(q + k + v)$, $(q + k + v + o)$

Это позволяет оценить вклад различных частей механизма внимания в итоговое качество модели.

3) Коэффициенты масштабирования

Параметр $\alpha = 2r$ и dropout = 0.05

использовались фиксированно во всех экспериментах.

Функция создания LoRA-модели и проведенные с ней эксперименты представлены представлены:

- в приложении И для Qwen2.5-1.5 и AG_news (EN) для разного объема выборок;
- в приложении И для Qwen3-0.6 и AG_news (EN) для разного объема выборок;
- в приложении И для Qwen2.5-1.5 и PD_news (RU) для разного объема выборок;
- в приложении И для Qwen3-0.6 и PD_news (RU) для разного объема выборок.

Используя все вариации факторов экспериментов для LoRA в дальнейшем анализе участвуют результаты 264 экспериментов. Полученные значения метрик представлены в приложении N.

6.2. Интеграция LoRA в архитектуру модели

В рамках данного исследования разработана инфраструктура для дообучения языковых моделей с использованием метода LoRA (Low-Rank Adaptation). Реализация выполнена на основе библиотек Hugging Face (Transformers, PEFT, TRL) и фреймворка PyTorch.

Конфигурация LoRA-адаптера задается гиперпараметрами ранг (rank) и target_modules.

В рамках данной работы:

- LoRA внедрялась в линейные слои механизма внимания: q_proj , k_proj , v_proj , o_proj
- Базовые веса модели замораживались
- Обучались только LoRA-адаптеры и классификационная голова

Формально обновление весов представляется как: $W' = W + BA$, где:

W - исходная матрица весов

$A \in \mathbb{R}^{r \times d}$, $B \in \mathbb{R}^{d \times r}$ - обучаемые матрицы

r - ранг разложения

6.3. Методы квантизации - QLoRA

Для снижения требований к GPU-памяти применялась квантизация весов модели.

Рассматривались два метода:

I - NF4 (NormalFloat4)

- Специальный формат 4-битной квантизации
- Учитывает распределение весов
- Используется как стандарт в QLoRA

II - FP4 (Float4)

- Более простой формат 4-битного представления
- Быстрее в вычислениях
- Может уступать NF4 в точности

Особенности QLoRA:

- Базовая модель хранится в 4-битном виде
- LoRA-адаптеры обучаются в более высокой точности (FP16/BF16)
- Используется двойная квантизация (double quantization)

Функция создания QLoRA-модели и проведенные с ней эксперименты представлены
представлены:

- в **приложении И** для Qwen2.5-1.5 и AG_news (EN) для разного объема выборок;
- в **приложении И** для Qwen3-0.6 и AG_news (EN) для разного объема выборок;
- в **приложении И** для Qwen2.5-1.5 и PD_news (RU) для разного объема выборок;
- в **приложении И** для Qwen3-0.6 и PD_news (RU) для разного объема выборок.

Используя все вариации факторы экспериментов для LoRA в дальнейшем анализе участвуют результаты 528 экспериментов. Полученные значения метрик представлены в **приложении N**.

6.4 Геометрическая модификация – OrthoGeoLoRA

OrthoGeoLoRA (Orthogonal Geometric Low-Rank Adaptation) представляет собой современную модификацию метода LoRA, направленную на устранение фундаментальных геометрических недостатков стандартной низкоранговой адаптации [Wang et al., 2026][7]. В отличие от базовой LoRA, где обновление весов представляется как произведение двух матриц $\Delta W = BA\Delta W = BA$ без каких-либо ограничений на их структуру, OrthoGeoLoRA накладывает условие ортогональности на факторы A и B , что обеспечивает более стабильное и эффективное обучение.

Механизм метода

Согласно работам [7][24], стандартная LoRA страдает от трех основных проблем: *калибровочная свобода* $\Delta W = B\Sigma A^T$ (gauge freedom), когда одно и то же обновление может быть представлено бесконечным множеством пар (A, B) ; *масштабная неоднозначность* (scale ambiguity), затрудняющая настройку скорости обучения; и *склонность к коллапсу ранга* (rank collapse), когда эффективный ранг обновления оказывается ниже заданного, что ограничивает выразительную способность модели.

OrthoGeoLoRA решает эти проблемы путем введения SVD-подобной параметризации обновляющей матрицы: где:

- Матрицы $A \in \mathbb{R}^{d \times r}$ и $B \in \mathbb{R}^{k \times r}$ ортогональны (принадлежат многообразию Штифеля, Stiefel manifold);
- $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$ - диагональная матрица сингулярных значений.

Такая параметризация гарантирует, что столбцы A и B ортонормированы, т.е. каждый новый признак, вносимый адаптером, ортогонален остальным. Сингулярные значения обучаются явно, т.е. параметр $\log_singular$ в реализации позволяет модели регулировать "важность" каждого из r направлений адаптации. Отсутствует калибровочная свобода, а именно представление ΔW становится единственным для заданного ранга, что улучшает сходимость.

Программная реализация

В оригинальной работе OrthoGeoLoRA Wang et al. (2026) [7] отсутствует открытая реализация метода или подробное описание программной части, которое можно использовать для непосредственного воспроизведения экспериментов. В связи с этим в рамках данного исследования реализация OrthoGeoLoRA была выполнена самостоятельно [ссылка на приложение и ноутбук] на основе представленного теоретического описания и математической формализации метода.

Реализация OrthoGeoLoRA интегрирована с существующей экосистемой Hugging Face PEFT. Реализация состоит из двух ключевых компонентов: слоя ортогонализации и основного модуля OrthoGeoLoRA (приложение). Данный слой использует QR-разложение для преобразования произвольной матрицы параметров θ в ортогональную матрицу Q . Процедура коррекции знаков обеспечивает детерминированность отображения, что важно для воспроизводимости результатов (приложение).

Особенностью реализации является явное разделение направлений (ортогональные матрицы A и B) и амплитуд (диагональная матрица Σ). Функция *softplus* гарантирует положительность сингулярных чисел, что соответствует физическому смыслу важности каждого направления адаптации (приложение).




Рисунок 4. Геометрическая интерпретация преобразования метода OrthoGeoLoRA

Геометрическая интерпретация этого преобразования представлена на Рисунке 4 [7]. Входной вектор x сначала проецируется на ортогональный базис A (шаг 1), затем каждая проекция масштабируется соответствующим сингулярным значением (шаг 2), после чего результат проецируется на выходное пространство через ортогональный базис B^T (шаг 3). Такая структура обеспечивает максимальную эффективность использования каждого обучаемого параметра, так как между направлениями в пространстве признаков отсутствует корреляция.

Разработанная функция `convert_lora_to_orthogeolora` позволяет преобразовывать уже созданные LoRA-модели в OrthoGeoLoRA без необходимости повторной инициализации. Это дает возможность использовать стандартную конфигурацию PEFT и затем "усилить" модель геометрическими ограничениями, что существенно упрощает эксперименты по сравнению с ортогональными методами ([приложение](#)).

Эксперименты на основе OrthoGeoLoRA проводились на разно-масштабных моделях (Qwen2.5-1.5 и Qwen3-0.6) и разноязычных данных (EN и RU).

Эксперименты на Qwen2.5 не дали стабильных результатов, что ожидаемо, о таком эффекте говорится в статье R. Chirkova et al. (2026) [24]. Наблюдался «развал» обучения, а именно около 30% результатов экспериментов являлись $\text{loss} = \text{nan}$, $\text{accuracy} = 0.25$, $f1 = 0.10$, что не дает права говорить об этом методе как о рабочем для модели Qwen2.5-1.5. На Qwen3-0.6 результаты были стабильные. Поэтому далее в работе анализировалось поведение OrthoGeoLoRA только для модели Qwen3-0.6.

Функция создания OrthoGeoLoRA модели и проведенные с ней эксперименты представлены:

в [приложении И](#) для Qwen3-0.6 и AG_news (EN) для разного объема выборок;

в [приложении И](#) для Qwen3-0.6 и PD_news (RU) для разного объема выборок.

Используя все вариации факторы экспериментов для LoRA в дальнейшем анализе участвуют результаты 132 экспериментов. Полученные значения метрик представлены в [приложении N](#).

6.5. Экспериментальная схема обучения

Факторы для экспериментов:

Модели: Qwen2.5-1.5B / Qwen3-0.6B

Язык: RU / EN

Метод: LoRA / QLoRA / OrthoGeoLora

Квантизация: NF4 / FP4

Ранг: 4 / 8 / 16 / 32

Модули: $q+v$ / $q+k+v$ / $q+k+v+o$

Объем данных: 300/1500/3000/8000/15000/30000 образцов в классе

Метрики качества

Для оценки используются определенные в главе 4 метрики для всех экспериментов: accuracy, F1-score, loss, время обучения, потребление GPU памяти на обучение. Используя все вариации факторов экспериментов всего в дальнейшем анализе участвуют результаты 934 эксперимента. Полученные значения метрик представлены в **приложении N**

Глава 7. Анализ и визуализация результатов

7.1. Методология анализа и статистические методы

В данной главе представлены результаты экспериментального исследования, направленного на проверку выдвинутых гипотез о влиянии различных факторов на качество и вычислительную эффективность методов параметрически эффективного дообучения.

Далее будут приведены только подтверждённые в ходе экспериментального исследования утверждения и наблюдаемые закономерности. Полный перечень гипотез и процедура их проверки детально описаны в **Приложении**.

Структура анализа

Анализ результатов проводился по следующим направлениям:

- сравнение архитектур моделей (Qwen2.5-1.5B vs Qwen3-0.6B);
- исследование влияния ранга LoRA на качество адаптации;
- анализ эффективности расширения целевых модулей (q+v, q+k+v, q+k+v+o);
- сравнение методов квантизации (LoRA vs QLoRA, NF4 vs FP4);
- оценка базовой-модели относительно методов PEFT;
- анализ влияния языка (русский vs английский)
- влияние объёма обучающих данных.

Методика статистического анализа

Для обеспечения достоверности выводов использовался комплекс статистических методов, выбор которых обусловлен характером анализируемых данных:

Метод	Назначение	Обоснование применения
Критерий Манна–Уитни (Mann-Whitney U test)	Сравнение двух независимых выборок	Распределение метрик качества может отклоняться от нормального; метод устойчив к выбросам и не требует гомогенности дисперсий
Критерий Уилкоксона (Wilcoxon signed-rank test)	Сравнение двух связанных (парных) выборок	Используется для сопоставления LoRA и QLoRA на идентичных конфигурациях

Метод	Назначение	Обоснование применения
Критерий Краскела–Уоллиса (Kruskal-Wallis test)	Сравнение трёх и более независимых выборок	Применён для анализа различий между разными значениями rank
Тест Левена (Levene's test)	Сравнение дисперсий выборок	Оценка стабильности моделей; устойчив к отклонениям от нормального распределения
Двухфакторный дисперсионный анализ (ANOVA [25])	Оценка влияния двух факторов и их взаимодействия	Анализ совместного влияния rank и размера выборки на качество модели
Коэффициент η^2 (eta-squared)	Оценка величины эффекта	Количественная мера вклада каждого фактора в общую вариативность
Cliff's delta	Оценка величины различий между группами	Дополняет p-value информацией о практической значимости эффекта

Инструментальная база


Все статистические расчёты выполнены с использованием библиотек `scipy.stats` и `statsmodels` в среде Jupyter Notebook (приложение). Для каждого статистического теста пороговое значение уровня значимости принято равным $\alpha = 0.05$.

7.2 Выявленные зависимости и закономерности


7.2.1. Сравнение моделей

- При дообучении методами LoRA и QLoRA Qwen2.5-1.5B чаще показывает сопоставимое или лучшее качество при достаточном объёме данных (более 1500 образцов в каждом классе обучающей выборки и больше). А Qwen3-0.6B + QLoRA превосходит Qwen2.5-1.5B при 300 образцов в каждом классе обучающей выборки. Модели статистически значимо различаются по качеству (приложение). При объёме 1500 образцов модели могут вести себя по-разному.

EN



RU









Рисунок 5. Сравнение качества моделей Qwen3-0.6 и Qwen2.5-1.5 в случаях работы на разных объемах данных на разных языках и используя методы LoRA, QLoRA nf4, QLoRA fp4

- Qwen3-0.6В даёт более стабильные результаты (меньше разброс loss). Разброс loss у модели Qwen3 статистически меньше (приложение).




Рисунок 6. Сравнение разброса *Loss* моделей Qwen3-0.6 и Qwen2.5-1.5 в случаях работы на разных языках

7.2.2. Исследование влияния ранга LoRA на качество адаптации

- Оптимальный rank зависит от объёма данных.




Рисунок 7. Влияние ранга на качество модели.

Наибольшая чувствительность ассигасу к рангу проявляется при малых данных (300 образцов). Также, статистические тесты говорят о том, что ни на одном шаге ранга при объеме выборки 1500 и более нельзя утверждать, что ассигасу перестаёт расти, что мы можем наблюдать на Рисунке 8. Парный t-тест показывает значимость ($p < 0.05$) на каждом шаге, включая переход от 16 к 32 рангу ([приложение](#))

Однако, практически картина немного другая и можно наблюдать, что при объеме данных 8000 rank 4 уже даёт 99% от максимального значения ассигасу. При этом все шаги статистически значимы лишь потому, что у нас много повторений и маленький std (0.009), а не потому что разница реально важна. При объеме 3000 rank 8 даёт тоже более 99% от максимума качества. Переход от ранга 4 к рангу 8 статистически незначим ($p = 0.189$) и это как раз можно назвать локальным плато. Затем переход от ранга 8 к 16 и от 16 к 32 снова значимы, но с приростом всего 0.003–0.004 ([приложение](#)). Т.е. здесь можно говорить о практическом плато при статистической значимости, когда тест улавливает разницу, которая не имеет практического смысла.

[Таблица](#)

Rank, при котором достигается 99% от максимального значения ассигасу:

Объем выборки	Ранг (99% от max ассигасу)
300	32 (плато не достигается)
1500	16
3000	8
8000	4

- Различие влияния ранга для разных моделей:

Для оценки силы влияния факторов был рассчитан коэффициент η^2 [25] ([приложение](#)).

Для модели Qwen2.5 основной вклад в качество вносит размер обучающей выборки, в то время как влияние rank является незначительным. Взаимодействие факторов оказывает ограниченное влияние ([приложение](#)).

Для модели Qwen3 наблюдается более выраженное влияние rank и особенно взаимодействия факторов, что указывает на зависимость эффективности выбора rank от объёма обучающей выборки (**приложение**)

Модель Qwen2.5 в основном определяется объёмом данных и слабо зависит от параметров адаптера, тогда как Qwen3 демонстрирует значительно более сложное поведение, включая существенную зависимость от rank и его взаимодействия с размером выборки.

7.2.3. Расширение target modules. Сравнение: q+v, q+k+v, q+k+v+o

- (q+v) даёт лучшее соотношение качество/ресурсы, максимальное качество достигается при использовании (q+k+v+o).






Рисунок 8. **Добавить картинку**

Таблица





При увеличении модулей *Accuracy* растёт слабо ($\approx +1-2\%$), но наблюдается рост времени обучения и GPU, что связано с увеличением числа обновляемых параметров и вычислительной нагрузки. Также, рост модулей не всегда даёт пропорциональный рост ассигу, ($q+v$) часто даёт лучшее качество, чем ($q+k+v$) (приложение). Аномалия с падением качества при добавлении К-проекции без Output проявляется в методах, работающих с полной точностью (LoRA, OGLoRA). В квантованных методах QLoRA эта аномалия исчезает, и добавление К-проекции даёт ожидаемый прирост качества благодаря дополнительной гибкости, компенсирующей ошибки квантизации.


($q+v$) можно использовать для экономии времени и памяти, а ($q+k+v+o$) - для большей точности и более высокой стабильности.

Также следует отметить отсутствие взаимовлияния ранга и модулей. ANOVA показал, что rank и набор модулей влияют на ассигу преимущественно независимо ($p=0.999$ для

взаимодействия). Их эффекты складываются, а не усиливают друг друга. Можно также говорить о взаимокompенсации. При rank=4 переход от q+v к q+k+v+o даёт +0.021 к accuracy. При rank=16 тот же переход даёт -0.002. Это означает, что q+k+v+o и rank частично взаимозаменяемы, т.е. при малом ранге q+k+v+o «добирает» качество за счёт большего охвата модулей механизма внимания.

7.2.4. QLoRA vs LoRA

- QLoRA сохраняет более 95% качества LoRA при значительном снижении затрат памяти, но требует существенно большего времени обучения (**приложение**).






Рисунок Актуализировать картинку

В результате экспериментов установлено, что QLoRA в среднем сохраняет около 98.4% качества LoRA, при этом в 89% случаев достигается уровень не ниже 95%. Однако статистический анализ (тест Уилкоксона, $p = 0.0013$) показывает наличие значимого снижения качества, что не позволяет утверждать сохранение более 95% качества во всех случаях. При этом QLoRA обеспечивает значительное снижение потребления GPU (в среднем до 71.6% от LoRA, $p = 0.001$), что подтверждает его эффективность в условиях ограниченных вычислительных ресурсов. В то же время QLoRA требует большего времени обучения (в среднем время увеличивается на 49% (**приложение**)) причём почти во всех случаях QLoRA. Это связано с дополнительными вычислительными затратами на операции квантования и деквантования.

- На малых данных (300 образцов) *accuracy* с QLoRA ниже, чем с LoRA.





Рисунок. Различие LoRA vs QLoRA при росте данных

При крайне малом размере выборки (300 примеров в классе) QLoRA демонстрирует качество ниже по сравнению с LoRA (разница около 8–10%, $p < 0.001$), что указывает на

недостаточную устойчивость метода в условиях ограниченных данных. Однако при увеличении размера выборки до 1500 и выше различия между методами становятся практически нулевыми (менее 1%) и статистически незначимыми или практически незначимыми с точки зрения эффекта. Таким образом, можно выделить порог стабилизации: начиная примерно с 1500 примеров, QLoRA достигает качества, сопоставимого с LoRA (**приложение**).

7.2.5. FP4 vs NF4

- NF4 и FP4 демонстрируют практически одинаковое качество, несмотря на формальную статистическую значимость различий.




Анализ показал, что различия между NF4 и FP4 по качеству являются статистически значимыми ($p < 0.001$), однако их величина крайне мала. Средняя разница составляет менее 1%, а в более чем 90% случаев она не превышает 2%. При этом величина эффекта (Cliff's delta ≈ 0.04) указывает на пренебрежимо малый эффект, что свидетельствует об отсутствии практической значимости различий (**приложение**).

7.2.6. Baseline

- Baseline проигрывает по качеству.

Разница качества: LoRA vs baseline: +17.5% , QLoRA vs baseline: +16.3%

Различия статистически значимы (**приложение**). Даже на малых данных базовая конфигурация сильно проигрывает методам LoRA



Fine-tuning только головы недостаточен при ограниченных ресурсах. При нетребовательных условиях к качеству модели baseline может быть актуален, т.к. тратит минимум памяти и времени на обучение по сравнению с другими моделями.

7.2.7. Влияние качества набора данных (RU vs EN)

- Качество выше на английском, чем на русском датасете

Результаты экспериментов показывают, что качество моделей на английском языке существенно выше, чем на русском. Средняя разница в ассигасу составляет около 5–6%. При парном сравнении английская версия превосходит русскую в 100% случаев, при этом в 94.6% случаев разница превышает 2% (**приложение**). Статистический анализ подтверждает значимость различий, а величина эффекта ($Cliff's\ delta=0.54$) указывает на сильный эффект (**приложение**).

- При уменьшении данных русский язык теряет в качестве сильнее английского.

Анализ влияния размера обучающей выборки на устойчивость моделей показал, что различия между английским и русским языками проявляются в условиях малых данных. При размере выборки 300 примеров наблюдается статистически значимо более сильная деградация качества на русском языке ($p < 0.001$), с разницей около 7% по величине падения ассигасу. Однако при увеличении размера выборки до 1500 примеров различия становятся минимальными (0.09%) и практически незначимыми с точки зрения эффекта (**приложение**).


- Для русского языка Qwen2.5 дает более высокое качество

Анализ показал, что модель Qwen3 теряет значительно больше качества при переходе с английского на русский датасет по сравнению с Qwen2.5. Среднее снижение accuracy составляет около 6% для Qwen3 против 1.3% для Qwen2.5.

Эти явления могут быть связаны как со сложностью языка так и с качеством подготовки данных. Например, предварительный анализ показал, что в данных на русском языке средняя длина теста значительно короче, чем на английском.



7.2.8. Метод OrthoGeoLoRA (OGLoRA)

- Модель: Эксперименты на Qwen2.5 не дали стабильных результатов. Примерно в 30% экспериментов наблюдался «развал» обучения (loss = nan, accuracy = 0.25, f1 = 0.10), что не дает права говорить о методе OrthoGeoLoRA как о рабочем для модели Qwen2.5-1.5. На Qwen3-0.6 результаты были стабильные. Поэтому в работе анализировалось поведение OrthoGeoLoRA только для модели Qwen3-0.6.
- Ранг: при OrthoGeoLoRA
 - для малых данных (300) качество значительно не увеличивается (может даже уменьшаться при EN), начиная с rank=16,
 - при выборке 1500 и более качество достигает максимума при rank=8-16, далее также значительно не растет (RU) или деградирует (EN) (приложение).



Рисунок

- Число модулей:
 - для лучшего качества на малых данных следует выбирать набор модулей (q+k+v+o)
 - для данных ≥ 1500 : (q+v) (приложение)






Рисунок

- Метод: лучше всего себя проявил OrthoGeoLoRA + Qwen3 на малых данных (<1500):
 - Accuracy: значительно выше других рассмотренных методов (baseline, LoRA, QLoRA).
 - GPU: затраты на GPU ниже, чем у LoRA.
 - Time: занимает гораздо больше времени относительно других методов. Однако, ввиду того, что обучение проводится на малом объеме данных, абсолютные времязатраты сравнительно небольшие (OGLoRA $\approx$ 4 мин vs LoRA $\approx$ 2,5 мин).

Этот эффект был подтвержден как на англоязычном так и на русскоязычном датасете, при этом на русскоязычном датасете эффект был даже ярче, чем на английском.

Этот метод также как и предыдущие изыскания обозначил порог объема датасета в 1500 образцов в каждом классе обучающей выборки, после которого результаты обучения методом OrthoGeoLoRA (OGLoRA) не отличались от результатов других методов LoRA.





Сравнение OrthoGeoLoRA+Qwen3 с другими методами на Qwen2.5

7.3 Количественные зависимости и закономерности

1. Зависимости и закономерности

Для анализа взаимосвязей между качественными и ресурсными характеристиками была построена корреляционная матрица Спирмена, позволяющая выявить монотонные зависимости между параметрами адаптации, объёмом данных и итоговым качеством моделей. Для построения корреляционной матрицы использовалась подвыборка экспериментов в сопоставимом диапазоне объёмов обучающих данных (от 300 до 8000 образцов на класс), включающая только методы LoRA и QLoRA. Метод OGLoRA был исключён из анализа вследствие отсутствия полной серии результатов для модели Qwen2.5, поскольку его включение могло бы привести к смещению оценок и исказить интерпретацию выявленных зависимостей.



Рисунок. Матрица корреляций признаков.

Корреляционный анализ Спирмена показал, что наибольшее влияние на качество классификации оказывает объём обучающей выборки ($\rho = 0.828$). Влияние ранга адаптеров является умеренным ($\rho = 0.247$), что подтверждает эффект убывающей отдачи. Отрицательная корреляция с языковым признаком ($\rho = -0.219$) свидетельствует о большей сложности русскоязычных данных. При этом связь между потреблением GPU-памяти и качеством практически отсутствует ($\rho = -0.062$), что подтверждает возможность эффективной оптимизации вычислительных ресурсов без существенной потери точности.

2. Общий количественный баланс качество/затраты

7.4 Общие выводы

- При дообучении методами LoRA и QLoRA Qwen2.5-1.5B чаще показывает сопоставимое или лучшее качество при достаточном объёме данных (более 1500 образцов в каждом классе обучающей выборки и больше). А Qwen3-0.6B + QLoRA превосходит Qwen2.5-1.5B при 300 образцов в каждом классе обучающей выборки. Модели статистически значимо различаются по качеству (**приложение**). При объеме 1500 образцов модели могут вести себя по-разному.
- Qwen3-0.6B даёт более стабильные результаты (меньше разброс loss). Разброс loss у модели Qwen3 статистически меньше (**приложение**).
- Qwen3-0.6B более экономная в части затрат памяти
- Rank, при котором достигается 99% от максимального значения accuracy:


Объем выборки	Ранг (99% от max accuracy)
300	32 (плато не достигается)
1500	16
3000	8
8000	4

- Модель Qwen2.5 в основном определяется объёмом данных и слабо зависит от параметров адаптера, тогда как Qwen3 демонстрирует значительно более сложное поведение, включая существенную зависимость от rank и его взаимодействия с размером выборки
- (q+v) даёт лучшее соотношение качество/ресурсы, максимальное качество достигается при использовании (q+k+v+o).
- QLoRA сохраняет более 95% качества LoRA при значительном снижении затрат памяти, но требует существенно большего времени обучения
- Fine-tuning только головы недостаточен при ограниченных ресурсах.
- Качество выше на английском, чем на русском
- На малых данных русский язык теряет в качестве сильнее английского
- Для русского языка Qwen2.5 дает более высокое качество
- OrthoGeoLoRA работает только на Qwen3-0.6
- На малых данных хорошо работает OrthoGeoLoRA+Qwen3, но долго. Экономнее по GPU, чем LoRA

- Порог объема датасета в 1500 образцов в каждом классе обучающей выборки, после которого результаты обучения различными PFET методами критически не отличаются друг от друга по качеству, но имеет различие по времени и затратам памяти.

7.5 Выбор оптимальных конфигураций

Для задачи классификации текста, выбирая корректные настройки, следует сперва отталкиваться от объема данных, на которых есть возможность обучить модель, далее смотреть на морфологию языка (сложность) и качество исходных данных, затем определить какой объем времени и памяти есть в распоряжении и что в приоритете.



Анализ конфигураций при объеме данных 300 (accuracy > 0.88) - EN






Рисунок. Пример анализа для выбора наиболее оптимальных конфигураций





Выбор конфигураций на частном примере

Отталкиваемся от имеющихся в распоряжении данных. Берем для ориентира самостоятельно собранный датасет (RU).

Малые данные (300), accuracy > 0.84

GPU, Гб \ Time, мин.	< 3	3 - 5	> 5
< 5	Qw3, OGLoRA, q+k+v+o, r=8 Acc = 0.845	Qw3, QLoRA nf4, q+k+v+o, r=32 Acc = 0.847	-
5 - 10	Qw3, OGLoRA, q+v, r=32 Acc = 0.850	-	-
10 - 20	-	-	-
>20	-	-	-

Средние данные (1500), accuracy > 0.88

GPU, Гб Time, мин.	< 3	3 - 5	> 5
< 5	Qw3, OGLoRA, q+v, r=4 Acc = 0.883	-	Qw2.5, LoRA, q+v, r=32 Acc = 0.911
5 - 10	Qw3, OGLoRA, q+v, r=32 Acc = 0.898	Qw3, QLoRA nf4, q+k+v+o, r=32 Acc = 0.917	-
10 - 20	-	-	-
>20	-	-	-

Средние данные (3000), accuracy > 0.89

GPU, Гб Time, мин.	< 3	3 - 5	> 5
< 5	-	-	-
5 - 10	Qw3, OGLoRA, q+v, r=8 Acc = 0.899	Qw3, LoRA, q+k+v+o, r=32 Acc = 0.903	Qw2.5, LoRA, q+k+v+o, r=16 Acc = 0.928
10 - 20	Qw3, OGLoRA, q+k+v, r=16 Acc = 0.904	Qw3, QLoRA nf4, fp4, q+k+v+o, r=32, Acc = 0.923-0.924	-
>20	-	-	-

Большие данные (>8000), accuracy > 0.88

GPU, Гб Time, мин.	< 3	3 - 5	> 5
< 5	-	-	-
5 - 10	-	-	-
10 - 20	Qw3, OGLoRA, q+v, r=4 Acc = 0.904	Qw3, LoRA, q+k+v+o, r=32 Acc = 0.920	Qw2.5, LoRA, q+k+v, r=32 Acc = 0.936
>20	-	Qw3, LoRA, q+k+v+o, r=16-32 Acc = 0.930	-

Общие рекомендации

Как результат работы, сформулированы общие рекомендации по применению адаптеров (LoRA) для дообучения моделей в условиях ограниченных вычислительных ресурсов:

Сценарий	Данных на класс	Модель	Метод	Ранг	Модули
Мало данных, GPU критично	< 1500	Qwen3-0.6B	OGLoRA	8–16	q+k+v+o
Мало данных, время критично	< 1500	Qwen3-0.6B	LoRA	32	q+v
Достаточно данных, GPU критично	≥ 1500	любая	QLoRA NF4	4–32	q+v
Достаточно данных, скорость важна	≥ 1500	Qwen2.5-1.5B	LoRA	4–16	q+v

8. Заключение

Разработанный подход может использоваться для быстрой классификации текста на основе LLM при ограниченных вычислительных ресурсах, например, в исследовательских работах, классификация в новостных агрегаторах, для задач классификации обращений в поддержку или в государственные органы и т.п.).

Результаты позволяют осознанно выбирать модель, ранг, набор модулей и метод квантизации без полного перебора конфигураций на основе имеющихся данных.

Выявленные зависимости от объёма данных помогают оценить минимально достаточную выборку либо выбрать подход работы с уже имеющимися данными ограниченного объёма.

Реализованные эксперименты могут служить бенчмарком для сравнения будущих PEFT-методов, включая OrthoGeoLoRA.

ССЫЛКИ:

1. <https://arxiv.org/abs/2303.15647>
2. <https://arxiv.org/abs/2106.09685> 2021-2022 г
3. [2303.10512] AdaLoRA: Adaptive Budget Allocation for Parameter-Efficient Fine-Tuning (<https://github.com/QingruZhang/AdaLoRA>)
4. <https://arxiv.org/pdf/2506.18267>)
5. <https://aclanthology.org/2025.findings-emnlp.1372.pdf>
6. <https://aclanthology.org/2025.coling-industry.55.pdf>) (COLING 2025, Industry
7. Wang Z., Wu X., Li W., et al. OrthoGeoLoRA: Geometric Parameter-Efficient Fine-Tuning for Structured Social Science Concept Retrieval on the Web // arXiv:2601.09185 [cs.CL]. 2026. URL: <https://arxiv.org/abs/2601.09185>
8. <https://huggingface.co/docs/transformers>
9. <https://huggingface.co/docs/peft>
10. <https://github.com/bitsandbytes-foundation/bitsandbytes>
11. <https://huggingface.co/docs/accelerate/index>
12. Howard, J., Ruder, S. (2018) — Universal Language Model Fine-tuning (ULMFiT) <https://arxiv.org/abs/1801.06146>
13. <https://arxiv.org/abs/2305.14314>
14. <https://arxiv.org/abs/2402.04902>
15. <https://arxiv.org/abs/2509.25214>
16. https://huggingface.co/datasets/sh0416/ag_news
17. <https://www.mdpi.com/2075-5309/15/19/3477>
18. <https://www.sciencedirect.com/science/article/abs/pii/S092523122501046X>
19. <https://www.frontiersin.org/journals/big-data/articles/10.3389/fdata.2025.1677331/full>
20. <https://arxiv.org/abs/2601.22708>
21. <https://huggingface.co/models/qwen3-0-6b>
22. <https://huggingface.co/models/qwen2-5-1-5b>
23. <https://arxiv.org/abs/1706.03762>
24. R. Chirkova et al. "When Does Orthogonal LoRA Help Retrieval? Spectral Preservation, Alignment, and Operating Regimes." *TMLR*, 2026. <https://openreview.net/forum?id=zhql8bU0QM>
25. <https://www.statsmodels.org/stable/anova.html>
- 26.

1. <https://arxiv.org/abs/1509.01626>

2. <https://ailynx.ru/news/llm/peft-parameter-efficient-fine-tuning-methods-for-llms/>
3. <https://colab.research.google.com/drive/1B9RsKLMa8SwTxLsxRT8g9OedK10zfBEP?usp=sharing&authuser=1>
4. <https://huggingface.co/docs/peft/index>
5. <https://arxiv.org/abs/2601.06788>
6. <https://aclanthology.org/2025.acl-long.99.pdf>
7. <https://arxiv.org/pdf/2503.12988>
8. <https://arxiv.org/abs/2106.09685>
- 9.

Приложения

Реализация метода OrthoGeoLoRA

Реализация метода осуществлялась с помощью языка Python. Для среды кодирования использовался Jupyter Notebook. Блокнот с результатами представлен в репозитории по [ссылке](#). Отрывок кода можно видеть на Рисунке 35 и 36.

```
class OrthogonalizationLayer(nn.Module):
    def __init__(self, in_dim, rank, dtype):
        super().__init__()
        # Инициализация параметров малого размера
        self.theta = nn.Parameter(torch.randn(in_dim, rank, dtype=torch.float32) * 0.01)

    def forward(self):
        # QR-разложение для ортогонализации
        q, r = torch.linalg.qr(self.theta, mode="reduced")
        sign = torch.sign(torch.diag(r))
        # Коррекция знаков для стабильности
        q = q * sign.unsqueeze(0)
        return q
```

Рисунок. Реализация слоя ортогонализации для OrthoGeoLoRA

```
class OrthoGeoLoRALayer(nn.Module):
    def __init__(self, base_lora_layer):
        super().__init__()

        self.base_layer = base_lora_layer.base_layer

        if isinstance(base_lora_layer.r, dict):
            self.rank = list(base_lora_layer.r.values())[0]
        else:
            self.rank = base_lora_layer.r

        if isinstance(base_lora_layer.scaling, dict):
            self.scaling = list(base_lora_layer.scaling.values())[0]
        else:
            self.scaling = base_lora_layer.scaling

        in_features = self.base_layer.in_features
        out_features = self.base_layer.out_features

        dtype = self.base_layer.weight.dtype

        self.A_orth = OrthogonalizationLayer(in_features, self.rank, dtype)
        self.B_orth = OrthogonalizationLayer(out_features, self.rank, dtype)

        self.log_singular = nn.Parameter(torch.zeros(self.rank, dtype=dtype))

    @property
    def singular(self):
        return F.softplus(self.log_singular) + 1e-6
```

Рисунок . Основной модуль OrthoGeoLoRA

