ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ НАЦИОНАЛЬНЫЙ
ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК

Лемехова Ольга Александровна

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

Исследование методов эффективного применения адаптеров (LoRA) для дообучения моделей в условиях ограниченных вычислительных ресурсов

по направлению 01.04.02 Прикладная математика и информатика
образовательная программа «Аналитика больших данных»

Студент

_____

Ольга Александровна Лемехова

Научный руководитель

_____

старший преподаватель
департамента больших данных и
информационного поиска ФКН НИУ ВШЭ
Евгений Анатольевич Паточенко

2026

СОДЕРЖАНИЕ

Глава 1. Введение 4
1.1. Актуальность исследования 4
1.2. Цель и задачи исследования 5
1.3. Объект и предмет исследования 5
1.4. Научная новизна 6
Глава 2. Обзор литературы и теоретические основы 6
2.1. Проблема дообучения LLM в условиях ограниченных ресурсов 6
2.2. Parameter-Efficient Fine-Tuning (PEFT) 7
2.3. Метод LoRA и его развитие 7
2.4. Геометрические и структурные расширения LoRA 8
2.5. Совместное применение LoRA и квантизации 8
2.6. Ограничения и открытые проблемы 8
2.7. Выводы 9
Глава 3. Анализ существующих решенийи и постановка задачи 9
3.1. Open-source библиотеки для дообучения LLM 9
3.2. Сравнение подходов к дообучению 10
3.3. Формулировка исследовательских гипотез 11
3.4. Метрики оценки 12
3.5. Ограничения экспериментов 12
3.6. Постановка задачи исследования 12
Глава 4. Подготовка и анализ данных 13
4.1. Постановка NLP-задачи 13
4.2. Описание и источники данных 14
4.3. Сбор, очистка и предобработка данных 16
4.4. Формирование обучающих выборок 17
Глава 5. Построение baseline-модели 17
5.1 Выбор базовой языковой модели 17
5.2. Метрики качества 19
5.3. Результаты baseline 20
Глава 6. Дообучение языковой модели с использованием LoRA и квантизации 21
6.1. Интеграция LoRA в архитектуру модели 21
6.2. Исследуемые параметры LoRA 22
6.3. Методы квантизации 22

6.4. Экспериментальная схема обучения 22
6.5. Эксперименты .....**Error! Bookmark not defined.**
Глава 7. Анализ и визуализация результатов.....24
7.1 Сравнение моделей.....24
7.2 Эффект насыщения для rank.....27
7.3 Расширение target modules. Сравнение: q+v, q+k+v, q+k+v+o.....31
7.4. QLoRA vs LoRA 34
7.5. FP4 vs NF4 37
7.6. Baseline vs LoRA 38
7.7. Влияние языка (RU vs EN).....39
7.8. Влияние объема данных.....40

Глава 1. Введение

1.1. Актуальность исследования

В последние годы большие языковые модели (Large Language Models, LLM) стали основой большинства современных систем обработки естественного языка. Модели, такие как Qwen, LLaMA, GPT и Gemini, демонстрируют высокую эффективность в задачах генерации, суммаризации, извлечения информации и классификации текста. Однако их практическое применение в реальных проектах часто сталкивается с серьёзным ограничением: дефицитом вычислительных ресурсов.

Полное дообучение (full fine-tuning) даже относительно компактных моделей объёмом 1–7 миллиардов параметров требует десятков гигабайт видеопамяти (VRAM), нескольких высокопроизводительных графических ускорителей и значительного времени. Для многих исследовательских и прикладных задач - особенно в условиях одного GPU, академических вычислительных кластеров или бюджетных облачных сред - такой подход оказывается неприемлемым.

В этой связи особую актуальность приобретают параметрически эффективные методы дообучения (Parameter-Efficient Fine-Tuning, PEFT), среди которых ключевое место занимает семейство адаптеров LoRA (Low-Rank Adaptation). LoRA и её модификации позволяют дообучать модели, изменяя лишь малую долю параметров, что радикально снижает требования к памяти и ускоряет обучение.

Тем не менее, к 2026 году накоплен значительный объём эмпирических данных, показывающих, что эффективность LoRA-адаптеров критически зависит от множества факторов:

- выбора ранга адаптеров;
- набора адаптируемых модулей (например, только QV, QKV или QKVO);
- применения квантизации (NF4, FP4);
- языка и объёма обучающей выборки;
- архитектуры базовой модели.

При этом систематических исследований, объединяющих все эти факторы в единую экспериментальную картину применительно к задаче классификации коротких текстов (новостных заголовков) на разных языках (русском и английском) в условиях жёстких вычислительных ограничнений, до сих пор недостаточно.

Таким образом, актуальность данной работы обусловлена:

1. необходимостью снижения вычислительных затрат при дообучении LLM;
2. отсутствием универсальных рекомендаций по выбору конфигурации LoRA под ограниченные ресурсы;
3. потребностью в сравнении эффективности LoRA, QLoRA (с NF4 и FP4) на реальных задачах классификации;
4. важностью анализа влияния языка и объёма обучающих данных (от сотен до десятков тысяч примеров) на качество адаптации.

1.2. Цель и задачи исследования

Цель работы - экспериментальное исследование влияния параметров адаптеров LoRA, квантизации и объёма обучающих данных на качество и эффективность дообучения языковых моделей в условиях ограниченных вычислительных ресурсов при решении задачи классификации новостных заголовков на русском и английском языках.

Для достижения цели поставлены следующие задачи:

1. Провести анализ современных параметрически эффективных методов дообучения (LoRA, QLoRA).
2. Реализовать экспериментальный стенд для дообучения моделей Qwen2.5-1.5B и Qwen3-0.6B на двух датасетах новостных заголовков (Ru, En).
3. Выполнить серию экспериментов с варьированием:
   - ранга адаптеров (4, 8, 16, 32);
   - набора адаптируемых модулей (QV, QKV, QKVO);
   - метода дообучения (LoRA, QLoRA с NF4, QLoRA с FP4);
   - объёма обучающей выборки (300, 1500, 3000, 8000 примеров на категорию).
4. Оценить модели по метрикам качества (accuracy, F1-score), эффективности (потребление VRAM, время обучения) и loss.
5. Сравнить полученные результаты и сформулировать практические рекомендации по выбору конфигурации адаптеров в условиях ограниченных ресурсов.

1.3. Объект и предмет исследования

Объект исследования - большие языковые модели семейства Qwen (Qwen2.5-1.5B и Qwen3-0.6B), дообучаемые на задачу классификации новостных заголовков.

Предмет исследования - методы параметрически эффективного дообучения (LoRA, QLoRA с NF4/FP4) и влияние их гиперпараметров (ранг, набор модулей, квантизация, объём данных) на качество и вычислительную эффективность.

1.4. Научная новизна

Элементы научной новизны работы заключаются в следующем:

1. Проведено систематическое сравнение LoRA, QLoRA (NF4, FP4 на моделях Qwen разного размера (0.6B и 1.5B) в задаче классификации коротких текстов.
2. Выполнен комплексный анализ влияния ранга (4–32) и набора адаптируемых модулей (QV, QKV, QKVO) на качество и ресурсоёмкость в условиях одного GPU.
3. Исследовано влияние объёма обучающих данных в широком диапазоне на эффективность PEFT-методов для русского и английского языков.
4. Получены эмпирические зависимости между точностью, F1, loss, потреблением видеопамяти и временем обучения для различных конфигураций адаптеров.
5. Предложены практические рекомендации по выбору конфигурации LoRA для задач классификации при ограниченных вычислительных ресурсах.

1.5. Практическая значимость

Практическая значимость работы определяется следующим:

- Разработанный экспериментальный подход может быть использован для быстрого прототипирования классификаторов на основе LLM в условиях ограниченного бюджета вычислений.
- Полученные результаты позволяют инженерам и исследователям осознанно выбирать ранг, набор модулей и метод квантизации без необходимости полного перебора всех конфигураций.
- Выявленные зависимости от объёма данных помогают оценить минимально достаточную выборку для достижения приемлемого качества.
- Реализованные эксперименты и метрики (VRAM, время обучения, accuracy, F1) могут служить бенчмарком для сравнения будущих PEFT-методов.

Глава 2. Обзор литературы и теоретические основы

2.1. Проблема дообучения LLM в условиях ограниченных ресурсов

Современные большие языковые модели содержат миллиарды параметров, что делает их полное дообучение крайне ресурсоёмким. Основные ограничения

включают высокие требования к видеопамяти, длительное время обучения и значительные затраты на хранение моделей. В условиях ограниченных вычислительных ресурсов (например, одной GPU) full fine-tuning становится практически неприменимым.

2.2. Parameter-Efficient Fine-Tuning (PEFT)

В качестве альтернативы полному дообучению активно развиваются методы parameter-efficient fine-tuning (PEFT), позволяющие адаптировать модели за счёт обучения лишь небольшой части параметров. Это снижает требования к памяти и вычислениям, ускоряет обучение и упрощает воспроизводимость экспериментов.

Среди различных подходов PEFT наибольшее практическое распространение получили методы, основанные на низкоранговой параметризации обновлений весов, прежде всего семейство LoRA. https://arxiv.org/abs/2303.15647

2.3. Метод LoRA и его развитие

Метод Low-Rank Adaptation (LoRA) является одним из наиболее эффективных и широко используемых подходов PEFT. Его ключевая идея заключается в представлении обновлений весов в виде произведения двух матриц малого ранга, при этом исходные веса модели остаются замороженными. https://arxiv.org/abs/2106.09685 2021-2022 г

LoRA обеспечивает:

- значительное сокращение числа обучаемых параметров;
- снижение требований к памяти;
- качество, сопоставимое с полным дообучением.

Практически LoRA применяется к слоям внимания трансформера (например, проекциям q, k, v), однако его эффективность зависит от выбора гиперпараметров, таких как ранг (rank) и масштабирование.

На базе LoRA сформировалось активное направление исследований, направленное на улучшение эффективности и адаптивности метода:

- **QLoRA** - сочетает LoRA с 4-битной квантизацией весов (например, NF4), что позволяет дообучать крупные модели на ограниченных ресурсах при сохранении качества. https://arxiv.org/abs/2303.15647
- **AdaLoRA, DoRA, GLoRA** - вводят адаптивное распределение ранга и более гибкую параметризацию обновлений. [2303.10512] AdaLoRA: Adaptive Budget Allocation for Parameter-Efficient Fine-Tuning 2023 г
- **ARD-LoRA и GeLoRA** — предлагают динамическое или теоретически обоснованное распределение ранга между слоями и головами

внимания. https://arxiv.org/pdf/2506.18267) (arXiv 2025) https://aclanthology.org/2025.findings-emnlp.1372.pdf) (Findings EMNLP 2025

- **LoRA Soups** — исследуют объединение нескольких LoRA-адаптеров для формирования мультизадачных моделей. https://aclanthology.org/2025.coling-industry.55.pdf) (COLING 2025, Industry

Таким образом, LoRA стал базовой архитектурой, вокруг которой формируется широкая экосистема методов, направленных на повышение эффективности использования параметров.

2.4. Геометрические и структурные расширения LoRA

Одним из наиболее современных направлений развития является метод **OrthoGeoLoRA**, который вводит геометрические ограничения на параметры адаптеров. https://arxiv.org/abs/2601.09185 2026 г)

В отличие от стандартного LoRA ($\Delta W = BA^T$), используется разложение вида:

$\Delta W = B\Sigma A^T$, где матрицы имеют ортонормированные столбцы.

Преимущества подхода:

- более стабильная оптимизация;
- предотвращение коллапса ранга;
- более эффективное использование параметров;
- улучшение качества без увеличения вычислительных затрат.

Данный подход показывает, что дальнейшее развитие LoRA связано не только с выбором ранга, но и с геометрией параметрического пространства.

2.5. Совместное применение LoRA и квантизации

Даже при использовании LoRA основная модель остаётся ресурсоёмкой. Поэтому важным направлением является сочетание LoRA с квантизацией.

Ключевой метод — **QLoRA**, который:

- квантует веса модели до 4 бит (NF4, FP4);
- обучает только LoRA-адаптеры;
- позволяет дообучать модели с десятками миллиардов параметров на одной GPU.

Дальнейшие работы (например, L4Q, CoA-LoRA) развивают идею совместной оптимизации LoRA и квантизации, улучшая баланс между точностью и эффективностью.

2.6. Ограничения и открытые проблемы

Несмотря на успехи LoRA и его модификаций, остаются нерешённые вопросы:

- выбор оптимального ранга (фиксированный rank не универсален);

- различная чувствительность слоёв модели к адаптации;
- деградация качества при малом ранге;
- влияние квантизации на стабильность обучения;
- зависимость эффективности от объёма данных.

Большинство современных исследований сосредоточено именно на решении этих проблем в рамках расширений LoRA.

2.7. Выводы

LoRA является центральным методом parameter-efficient fine-tuning и фактически стандартом для дообучения языковых моделей в условиях ограниченных ресурсов. Вокруг него сформировалось активное исследовательское направление, включающее адаптивные, геометрические и квантизационно-осознанные расширения.

Наиболее практичными на сегодняшний день являются комбинации LoRA и QLoRA, обеспечивающие хороший баланс между качеством и вычислительными затратами, а также различные новые методы, повышающие эффективность параметризации.

В дальнейшем исследовании основное внимание будет уделено экспериментальному анализу эффективности применения LoRA и его вариантов при дообучении моделей семейства Qwen для задач классификации текста. Будут рассмотрены различные значения ранга (4, 8, 16, 32), конфигурации адаптации (qv, qkv, qkvo), методы LoRA и QLoRA (NF4, FP4), а также влияние объёма обучающей выборки на качество модели.

Глава 3. Анализ существующих решенийи и постановка задачи

3.1. Open-source библиотеки для дообучения LLM

Современные исследования в области дообучения больших языковых моделей активно поддерживаются развитой экосистемой open-source инструментов. Наиболее распространённые библиотеки ориентированы на упрощение интеграции методов parameter-efficient fine-tuning (PEFT), включая LoRA и его модификации.

Ключевыми инструментами являются:

- Transformers (Hugging Face) - базовая библиотека для работы с предобученными языковыми моделями, предоставляющая унифицированный интерфейс для обучения, инференса и токенизации; https://huggingface.co/docs/transformers

- PEFT (Parameter-Efficient Fine-Tuning) - специализированная библиотека, реализующая методы LoRA, QLoRA, Prefix Tuning и другие подходы; https://huggingface.co/docs/peft
- BitsAndBytes — библиотека для низкобитной квантизации (4-bit, 8-bit), используемая в QLoRA; https://github.com/bitsandbytes-foundation/bitsandbytes
- Accelerate - инструмент для оптимизации обучения и эффективного использования доступных вычислительных ресурсов. https://huggingface.co/docs/accelerate/index

Данные библиотеки обеспечивают:

- быструю интеграцию LoRA в архитектуру модели;
- поддержку квантизации (NF4, FP4);
- воспроизводимость экспериментов;
- возможность работы в условиях ограниченных ресурсов (одна GPU).

Таким образом, современный стек инструментов делает практическое применение LoRA и QLoRA доступным даже при ограниченной вычислительной инфраструктуре.

3.2. Сравнение подходов к дообучению

Существующие подходы к дообучению языковых моделей можно разделить на три основные категории:

1. Полное дообучение (Full Fine-Tuning)

Предполагает обновление всех параметров модели. Обеспечивает высокое качество, однако требует значительных ресурсов (VRAM, время обучения). Howard, J., Ruder, S. (2018) — Universal Language Model Fine-tuning (ULMFiT) https://arxiv.org/abs/1801.06146

2. Частичное дообучение

Обучается только часть параметров (например, классификационная голова). Обладает низкой вычислительной стоимостью, но ограниченной выразительной способностью.

3. Parameter-Efficient Fine-Tuning (PEFT)

Наиболее перспективный класс методов, в котором центральное место занимает LoRA. https://arxiv.org/abs/2303.15647

Сравнение подходов:

Подход	Качество	Ресурсы	Гибкость
Full FT	высокое	очень высокие	высокая
Head-only	низкое–среднее	низкие	низкая

LoRA https://arxiv.org/abs/2106.09685	высокое	низкие	высокая
QloRA https://arxiv.org/abs/2305.14314	высокое	очень низкие	высокая

LoRA и его расширения фактически стали стандартом для дообучения LLM в условиях ограниченных ресурсов.

Важно отметить, что:

– большинство современных исследований направлены не на замену LoRA, а на его улучшение;

– такие методы, как QLoRA, OrthoGeoLoRA, AdaLoRA, GeLoRA, развивают именно базовую идею низкоранговой адаптации;

– LoRA выступает фундаментальной архитектурой, вокруг которой формируется исследовательское направление.

3.3. Формулировка исследовательских гипотез

На основе анализа существующих решений формулируются следующие исследовательские гипотезы.

Группа гипотез 1. Влияние LoRA при малом объёме данных

Использование LoRA позволяет существенно повысить качество модели по сравнению с baseline (обучение только классификационной головы), особенно на малых выборках.

Ожидается, что:

– выигрыш от LoRA максимален при ограниченных данных;

– при увеличении объёма данных разница между методами уменьшается.

Группа гипотез 2. Влияние ранга и target modules

Качество модели существенно зависит от конфигурации LoRA:

– увеличение ранга (с 4 до 32) улучшает качество, но увеличивает вычислительные затраты;

– различные наборы модулей (qv, qkv, qkvo) по-разному влияют на результат;

– не все слои требуют одинаковой степени адаптации.

Ожидается существование оптимального баланса между:

числом параметров, качеством модели, вычислительными затратами.

Группа гипотез 3. Влияние квантизации (QLoRA)

Использование QLoRA позволяет существенно снизить требования к памяти без значительной потери качества.

Предполагается, что:

– NF4 обеспечивает лучшее качество по сравнению с FP4;

– QLoRA демонстрирует близкое к LoRA качество при меньших ресурсах;

– влияние квантизации усиливается на больших моделях.

Группа гипотез 4. Влияние масштаба модели и языка

Эффективность LoRA может зависеть от:

- размера модели (0.6B vs 1.5B);
- языка данных (EN vs RU);
- объёма обучающей выборки.

3.4. Метрики оценки

Для комплексного анализа эффективности методов используются как качественные, так и ресурсные метрики.

Метрики качества:

- Accuracy - основная метрика классификации;
- F1-score (weighted) - учитывает баланс классов;
- Loss (cross-entropy) - характеризует процесс обучения.

Ресурсные метрики:

- время обучения;
- потребление GPU-памяти.

Такой набор метрик позволяет оценить не только точность модели, но и её практическую применимость в условиях ограниченных ресурсов.

3.5. Ограничения экспериментов

Проводимое исследование имеет ряд ограничений:

- использование одной GPU и ограниченной видеопамяти. Все эксперименты проводились в контролируемых условиях на локальной вычислительной системе (GPU: AMD Radeon RX 9070 XT, RAM: 32 GB) с минимизацией фоновой нагрузки, что обеспечивало сопоставимость полученных результатов;
- фиксированное число эпох (1), что ограничивает сходимость моделей;
- ограниченный набор моделей (Qwen2.5-1.5B и Qwen3-0.6B);
- исследование проводится на задаче классификации (без генеративных задач);
- ограниченный набор датасетов (2 языка, 2 домена) ограниченного объема;
- фиксированные гиперпараметры (dropout, scaling).

Также следует учитывать, что:

- результаты могут зависеть от случайной инициализации (seed), поэтому во всех экспериментах seed фиксирован и равен 42.
- Ввиду ограниченности объёмов данных для русскоязычного датасета, для чистоты экспериментов по исследованию влияния квантизации, модулей, рангов и видов моделей использовался эталонный датасет на английском языке AG_news с выборками по 300, 1500, 3000, 8000, 15000 и 30000 образцов в каждом классе. Влияние языка и неэталонного датасета исследовалось на датасете, собранном из

двух выборок — AG_news и PD_news — в одинаковом диапазоне, а именно для 300, 1500, 3000 и 8000 образцов в каждом классе

3.6. Постановка задачи исследования

На основе проведённого анализа формулируется задача исследования.

Цель работы - исследовать эффективность методов LoRA и QLoRA для дообучения языковых моделей в условиях ограниченных вычислительных ресурсов.

Для достижения цели необходимо:

а) Сравнить baseline-подход и методы LoRA/QLoRA;

б) Исследовать влияние:

- ранга адаптеров (r = 4, 8, 16, 32),
- набора адаптируемых модулей (q, v, qkv, qkvo),
- типа квантизации (NF4, FP4),
- объёма обучающих данных;

в) Оценить компромисс между:

- качеством модели,
- временем обучения,
- потреблением памяти;

г) Провести анализ на:

- двух моделях (разного масштаба),
- двух языках (английский и русский).

Таким образом, задача формулируется как многокритериальная оптимизация, направленная на поиск наиболее эффективных конфигураций LoRA в условиях ограниченных ресурсов.

Глава 4. Подготовка и анализ данных

https://arxiv.org/abs/2106.09685
https://arxiv.org/abs/2305.14314
https://arxiv.org/abs/1509.01626

4.1. Постановка NLP-задачи

В рамках данной работы рассматривается задача классификации текстов как частный случай задач обработки естественного языка (Natural Language Processing, NLP). Основное внимание уделяется исследованию эффективности методов дообучения языковых моделей с использованием адаптеров типа LoRA в условиях ограниченных вычислительных ресурсов.

Формализация задачи:

Пусть задана $D = \{(x_i, y_i)\}_{i=1}^{N}$ обучающая выборка:

где (*xi*) — текстовый документ, а (*yi*) — соответствующая метка класса.

Требуется построить $f_\theta(x)$ модель , которая отображает входной текст в пространство меток:

$$f_\theta : x \to y.$$

Обучение модели заключается в минимизации функции потерь:

$$\mathcal{L}(\theta) = \mathbb{E}_{(x,y)\sim D}\, \ell(f_\theta(x), y),$$

где в качестве функции потерь используется кросс-энтропия.

Особенности постановки задачи

Рассматриваемая задача характеризуется следующими особенностями:

- использование моделей различного масштаба (1.5B и 0.6B параметров);
- наличие мультиязычного сценария (английский и русский языки);
- ограниченные вычислительные ресурсы (ограничения по GPU памяти, времени обучения и объема выборки);
- необходимость эффективной адаптации модели без полного дообучения всех параметров.

Основная цель - определить конфигурации, обеспечивающие наилучший компромисс между качеством модели и вычислительными затратами.

Особое внимание уделяется анализу зависимости качества модели от вычислительных затрат, что позволяет выявить наиболее эффективные конфигурации в условиях ограниченных ресурсов.

Таким образом, задача формулируется как многокритериальная оптимизация, в которой необходимо максимизировать качество модели при одновременной минимизации вычислительных затрат.

4.2. Описание и источники данных

Работа проводилась на двух вариантах данных:

1) Эталонный набор данных - AG_News:

Набор данных AG по классификации новостных тем на английском языке (Версия 3, 09.09.2015)

ИСТОЧНИК

AG — это коллекция из новостных статей. Новостные статьи были собраны ComeToMyHead из более чем 2000 источников за более чем год работы. ComeToMyHead — это академическая поисковая система новостей, работающая с июля 2004 года. Набор данных предоставляется академическим сообществом для исследовательских целей в области интеллектуального анализа данных

(кластеризация, классификация и т. д.), поиска информации (ранжирование, поиск и т. д.), XML, сжатия данных, потоковой передачи данных и любой другой некоммерческой деятельности.

Набор данных для классификации новостных тем, созданный AG, разработан Сян Чжаном (xiang.zhang@nyu.edu) на основе вышеупомянутого набора данных. Он используется в качестве эталонного набора данных для классификации текста в следующей статье: Xiang Zhang, Junbo Zhao, Yann LeCun. Character-level Convolutional Networks for Text Classification. Advances in Neural Information Processing Systems 28 (NIPS 2015).

ОПИСАНИЕ

Набор данных для классификации новостных тем формируется путем выбора 4 крупнейших классов из исходного корпуса. Каждый класс содержит 30 000 обучающих и 1900 тестовых образцов. Классы строго сбаланнсированы. Общее количество обучающих образцов составляет 120 000, а тестовых — 7600.

Файл classes.txt содержит список классов, соответствующих каждой метке.

Файлы train.csv и test.csv содержат все обучающие выборки в виде значений, разделенных запятыми. В них три столбца, соответствующие индексу класса (от 1 до 4), заголовку и описанию. Заголовок и описание экранируются двойными кавычками ("), а любые внутренние двойные кавычки экранируются двумя двойными кавычками ("). Новые строки экранируются обратной косой чертой с последующим символом "n", то есть "\n". https://huggingface.co/datasets/sh0416/ag_news

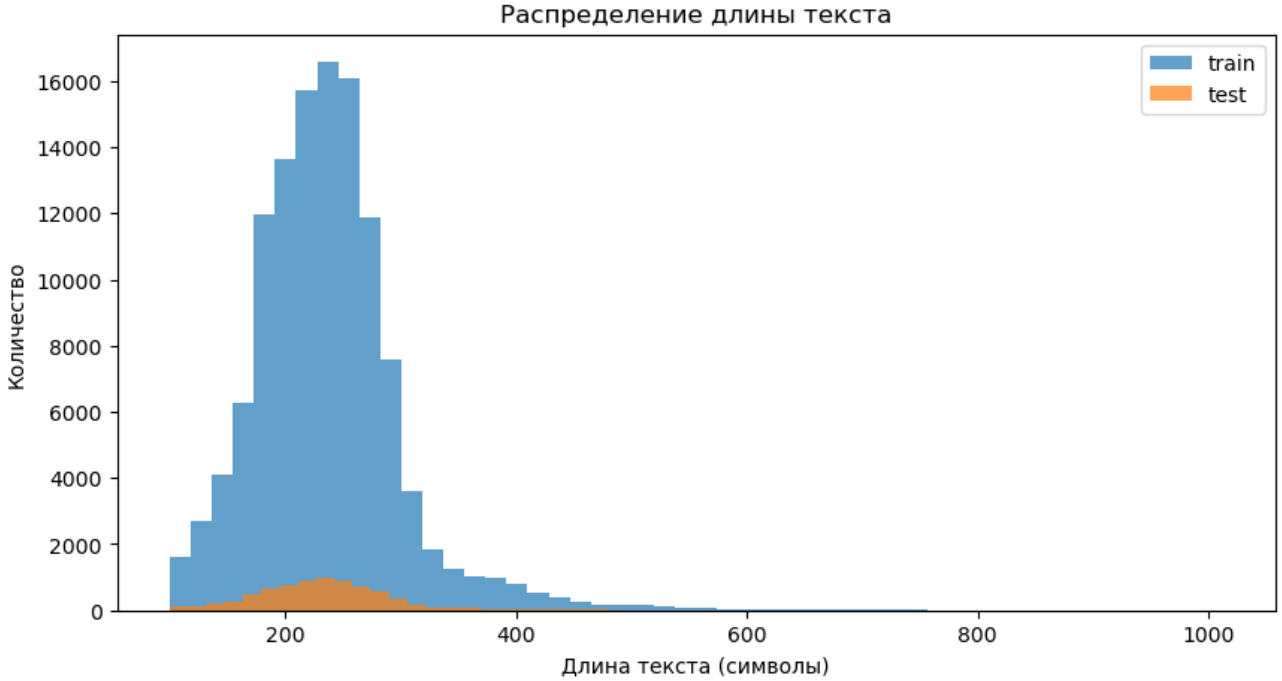

2) Самостоятельно собранные данные (далее – PD_News от parsed data news) – заголовки новостных статей русскоязычных сайтов.

ИСТОЧНИК

Данные были собраны самостоятельно с рускоязычных новостных сайтов Санкт-Петербурга:

- **fontanka.ru** («Фонтанка»)

- dp.ru («Деловой Петербург»)

с помощью библиотек Selenium и BeautifulSoup. (scraper_data.ipynb)

ОПИСАНИЕ

Представляют собой набор заголовков новостных статей по четырем темам: Спорт, Недвижимость, Финансы, Авто.

В итоге формируется набор данных, разбитый на 4 класса (sport, realty, finances, auto). В каждом классе по 10265 образцов. Классы сбалансированные. Общее количество образцов составляет - 41060, что соответсвует **34,2%** от количества образцов эталонного набора данных.

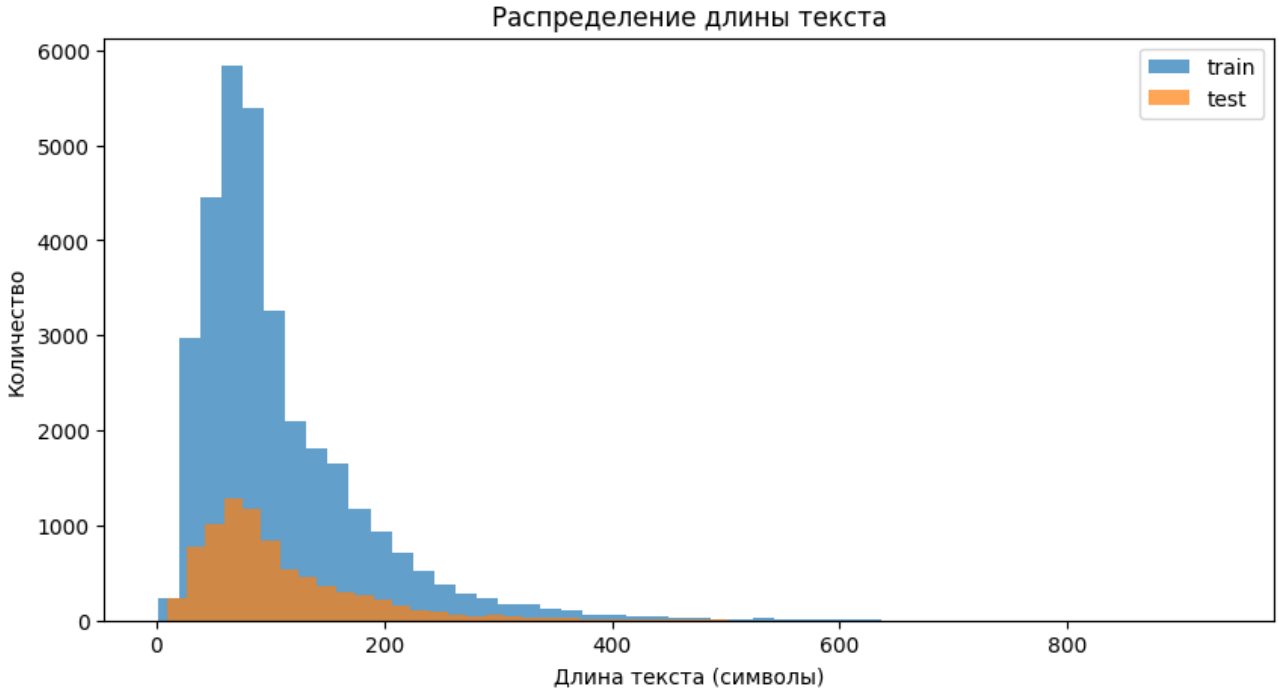

4.3. Сбор, очистка и предобработка данных

Данные AG_News – эталонные, не требующие дополнительной очистки или обработки.

Данные PD_News были предобработаны и очищены: удалены повторяющиеся заголовки, лишниие символы и «мусор», удалены технические наименования, наименования подрубрик и авторы статей, например «Александр Исаев. Страхование.:» , «Надежда Кузнецова. Налоги.:» или «(фото, видео)» и т.п. (ссылка на ноутбук - data_preprocessing.ipynb).

4.4. Формирование обучающих выборок

Данные AG_News уже имеют разбивку на тренировочную и тестовую выборки в размере 30 000 и 1 900 заговловков в каждом классе соответсвенно. Общее количество обучающих образцов – 120 000, а тестовых - 7600.

Для данных PD_News с помощью функции train_test_split библиотеки sklearn в каждом классе было сформировано 8212 обучающих и 2053 тестовых образцов (деление 80/20%). Обучающая выборка составляет 27% от обучающей выборки AG_News. Общее количество обучающих образцов составляет 32848, а тестовых — 8212.

Размеры обучающих выборок для экспериментов:

Эксперименты на подвыборках датасета AG_News - **EN**:

- 1% (1 200 заголовков, по 300 в каждой категории)
- 5% (6 000 заголовков, по 1 500 в каждой категории)
- 10% (12 000 заголовков, по 3 000 в каждой категории)
- 27% (32 000 заголовков, по 8 000 в каждой категории)
- 50% (60 000 заголовков, по 15 000 в каждой категории)
- 100% (120 000 заголовков, по 30 000 в каждой категории)

Эксперименты на подвыборках самостоятельно собранного датасета PD_News - **RU**:

- 3,6% (1 200 заголовков, по 300 в каждой категории) – 1% AG_News
- 18% (6 000 заголовков, по 1 500 в каждой категории) – 5% AG_News
- 37% (12 000 заголовков, по 3 000 в каждой категории)– 10% AG_News
- 97% (32 000 заголовков, по 8 000 в каждой категории)– 27% AG_News
- 100% (32 848 заголовков, по 8 212 в каждой категории) – 34% AG_News

Глава 5. Построение baseline-модели

Для анализа эффективности методов адаптации (LoRA и QLoRA) необходимо было задать базовую точку отсчёта - baseline-модель. В рамках данной работы baseline представляет собой предобученную языковую модель с минимальными изменениями, дообучаемую только за счёт классификационной головы.

5.1 Выбор базовой языковой модели

В качестве базовых моделей используются современные предобученные трансформерные архитектуры. Выбор пал на модели Qwen2.5-1.5B и

Qwen3-0.6B, поскольку они представляют разные масштабы (1.5 млрд и 0.6 млрд параметров соответственно) и доступны в открытом доступе, что обеспечивает воспроизводимость результатов исследования.

Семейство моделей Alibaba Qwen 3 включает в себя плотные архитектуры и архитектуры типа «смесь экспертов» (Mixture-of-Experts, MoE). Ключевые инновации включают гибридную систему рассуждений, предлагающую режимы «мышления» и «немышления» для адаптивной обработки, а также поддержку расширенных контекстных окон, повышающих эффективность и масштабируемость. https://apxml.com/models/qwen3-0-6b?utm_source=chatgpt.com

Qwen2.5 от Alibaba - это семейство плотных языковых моделей, использующих только декодер, доступных в различных размерах, причем некоторые варианты используют алгоритм Mixture-of-Experts. Эти модели предварительно обучены на больших наборах данных, поддерживая расширенную длину контекста и многоязычную коммуникацию. Семейство включает в себя специализированные модели для кодирования, математики и мультимодальных задач, таких как обработка изображений и звука. https://apxml.com/models/qwen2-5-1-5b

Выбор данных моделей обусловлен следующими факторами:

- наличие предобучения на больших корпусах текстов;
- поддержка эффективных методов дообучения (LoRA, QLoRA);
- различие в размере моделей, позволяющее анализировать влияние масштаба.

Архитектура

Используемые модели основаны на архитектуре трансформера (см. Attention Is All You Need).

Для решения задачи классификации в архитектуру добавляется классификационная голова, принимающая выходное представление модели и отображающая его в пространство классов.

Различия моделей

Характеристика	**Qwen2.5-1.5B**	**Qwen3-0.6B**
Поколение	Qwen2.5	Qwen3
Параметры	1.5B	0.6B
Контекст	до 128K	~32K
Архитектура	Transformer + GQA	Улучшенный Transformer
Обучение	~18 трлн токенов	~36 трлн токенов
На диске	3 ГБ	1–1.3 ГБ

(https://apxml.com/models/qwen3-0-6b?utm_source=chatgpt.com)

В baseline-подходе все параметры базовой модели замораживаются, обучаются только параметры классификационного слоя.

Таким образом, количество обучаемых параметров минимально, что позволяет оценить качество модели без применения адаптеров.

Основные параметры обучения:

- количество эпох: 1;
- размер батча (train и eval): 4;
- функция потерь: кросс-энтропия;
- оптимизатор: используется реализация по умолчанию в библиотеке Transformers (AdamW);
- стратегия оценки: на каждой эпохе (eval_strategy="epoch");
- сохранение чекпоинтов: отключено (save_strategy="no");
- логирование: каждые 50 шагов;
- отчёт в внешние системы: отключён (report_to="none");
- смешанная точность: не используется (fp16=False).

Предобработка данных

Перед обучением данные проходят этап токенизации:

- используется токенизатор, соответствующий выбранной модели;
- применяется усечение последовательностей до длины 256 токенов;
- используется padding до максимальной длины (padding="max_length");
- текстовая колонка преобразуется в формат, пригодный для PyTorch;
- целевая переменная приводится к формату labels.

Для формирования батчей используется динамический паддинг через DataCollatorWithPadding.

Особенности baseline-обучения

В baseline-подходе обучение проводится с заморозкой основной части модели:

- все параметры базовой языковой модели фиксируются;
- обучаются только параметры классификационной головы (classifier / score).

Количество обучаемых параметров при этом существенно меньше общего числа параметров модели, что снижает вычислительную нагрузку и требования к памяти.

5.2. Метрики качества

Для оценки baseline-модели используются опредленные в главе 3 метрики для всех экспериментов: accuracy, F1-score, loss, время обучения; потребление

GPU памяти на обучение. Полученные значения метрик представлены в приложении N.

5.3. Результаты baseline

Baseline-модель задаёт нижнюю границу качества, относительно которой оценивается эффективность параметрически эффективных методов дообучения. Результаты baseline-модели служат точкой отсчёта для последующего сравнения с методами LoRA и QLoRA.

Проведённые эксперименты показывают, что:

- качество классификации ограничено возможностями фиксированной языковой модели;
- обучение только классификационной головы обеспечивает низкие вычислительные затраты;
- увеличение объёма обучающей выборки приводит к росту accuracy, однако эффект насыщения достигается относительно быстро. Хорошие результаты по accuracy уже на объеме 3000 образцов в каждом классе обучающей выборки. Для задач классификации новостей небольшие обучающие выборки могут быть достаточны при использовании предобученных моделей на меньших моделях (Qwen3-0.6).
- Qwen3-0.6 показывает более высокое качество и меньший расход GPU на baseline.
- На больших моделях (Qwen2.5-1.5) Baseline-подход демонстрирует низкую эффективность масштабирования: увеличение объёма данных и вычислительных ресурсов не приводит к устойчивому росту качества, что подтверждает необходимость применения методов параметрически эффективного дообучения, таких как LoRA.

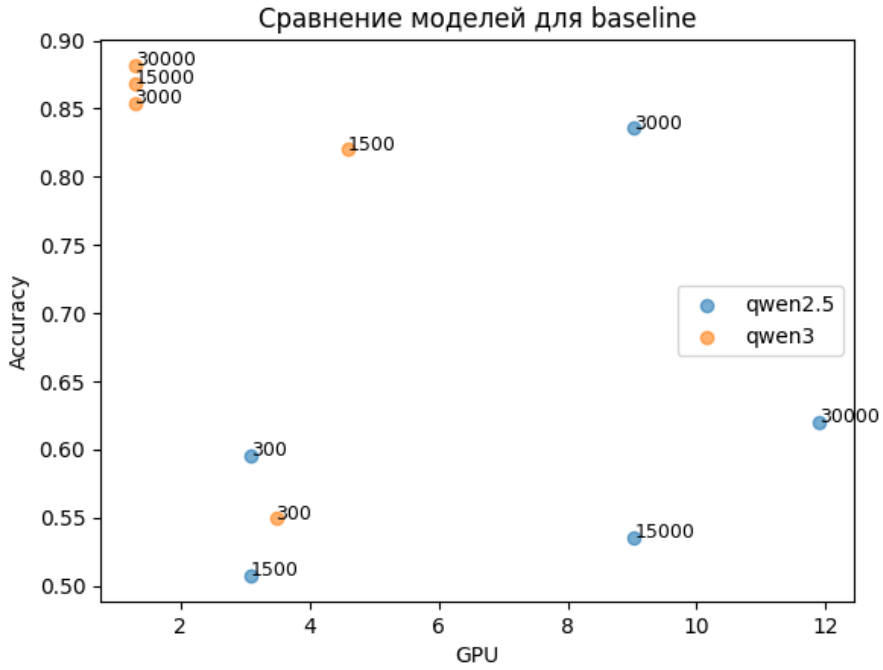

Глава 6. Дообучение языковой модели с использованием LoRA и квантизации

В данной главе рассматривается применение методов параметр-эффективного дообучения (PEFT) для двух языковых моделей: Qwen2.5-1.5B и Qwen3-0.6B с использованием LoRA и её квантованных модификаций (QLoRA) на примере двух различных датасетов на английском и русском языках. Основной целью является исследование компромисса между качеством модели, временем обучения, потреблением GPU-памяти и размером выборки при различных конфигурациях.

6.1. Интеграция LoRA в архитектуру модели

Метод LoRA (Low-Rank Adaptation) основан на замене обучения полных весов модели на обучение низкоранговых матриц, добавляемых к исходным слоям.

В рамках данной работы:

- LoRA внедрялась в линейные слои механизма внимания:
- q_proj , k_proj , v_proj , o_proj
- Базовые веса модели замораживались
- Обучались только LoRA-адаптеры и классификационная голова

Формально обновление весов представляется как: W′=W+BA, где:

W - исходная матрица весов

$A \in \mathbb{R}^{r \times d}, B \in \mathbb{R}^{d \times r}$ - обучаемые матрицы

r - ранг разложения

Такой подход снижает число обучаемых параметров и требования к памяти.

6.2. Исследуемые параметры LoRA

В ходе экспериментов варьировались ключевые гиперпараметры LoRA:

1) Ранг (rank, r)

Рассматривались значения: r = 4, 8, 16, 32

Цель - оценить влияние ранга на: - качество модели (accuracy, F1)
- время обучения
- использование памяти

2) Набор адаптируемых модулей

Были исследованы следующие конфигурации: (q + v)

(q + k + v)

(q + k + v + o)

Это позволяет оценить вклад различных частей механизма внимания в итоговое качество модели.

3) Коэффициенты масштабирования

Параметр α = 2r и dropout = 0.05

использовались фиксированно во всех экспериментах.

6.3. Методы квантизации

Для снижения требований к GPU-памяти применялась квантизация весов модели (QLoRA).

Рассматривались два метода:

I - NF4 (NormalFloat4)

- Специальный формат 4-битной квантизации
- Учитывает распределение весов
- Используется как стандарт в QLoRA

II - FP4 (Float4)

- Более простой формат 4-битного представления
- Быстрее в вычислениях
- Может уступать NF4 в точности

Особенности QLoRA:

- Базовая модель хранится в 4-битном виде
- LoRA-адаптеры обучаются в более высокой точности (FP16/BF16)
- Используется double quantization

6.4. Экспериментальная схема обучения

Эксперименты проводились в следующих условиях:

Все эксперименты проводились в контролируемых условиях на локальной вычислительной системе (GPU: AMD Radeon RX 9070 XT, RAM: 32 GB) с минимизацией фоновой нагрузки, что обеспечивало сопоставимость полученных результатов.

Факторы для экспериментов:

Модели: Qwen2.5-1.5B / Qwen3-0.6B

Язык: RU / EN

Метод: LoRA / QLoRA

Квантизация: NF4 / FP4

Ранг: 4 / 8 / 16 / 32

Модули: q+v / q+k+v / q+k+v+o

Размер выборки:

количество новостных заголовков в одном классе обучающей выборки:

EN: 30000 /	15000 /	3000 /	1500 /	300
RU: 8212 /		3000 /	1500 /	300

Задача: Классификация текстов

Параметры обучения:

- batch size: 4
- число эпох: 1
- максимальная длина: 256 токенов
- оптимизация: стандартный Trainer из Hugging Face Transformers

Оценка проводилась по метрикам:

- Accuracy
- F1-score (weighted)
- Loss
- Время обучения и инференса
- Использование GPU-памяти

Размер обучающей выборки:

Эксперименты проводились на подвыборках датасета AG_News (EN) и PD_News (RU) на всех представленных выборках, а именно 300/1500/3000/8000/15000/30000 образцов в классе для AG_News и 300/1500/3000/8000/8212 для PD_News.

Это позволило исследовать поведение моделей в условиях ограниченных данных.

В рамках работы были проведены три группы экспериментов:

1) Baseline

- Обучалась только классификационная голова

- Остальные веса модели заморожены

2) LoRA

- Полноточечная модель (FP16)
- Обучаются только LoRA-адаптеры

3) QLoRA (NF4, FP4)

Особенности:

- Квантизация модели до 4 бит
- Существенное снижение потребления памяти

Каждый эксперимент повторялся N раз. Для анализа использовались усреднённые значения метрик с исключением выбросов, определяемых на основе стандартного отклонения (приложение №, наименование ноутбука).

Глава 7. Анализ и визуализация результатов

На основе полученных данных были проведены наблюдения и выдвинуты следующие гипотезы:

7.1 Сравнение моделей

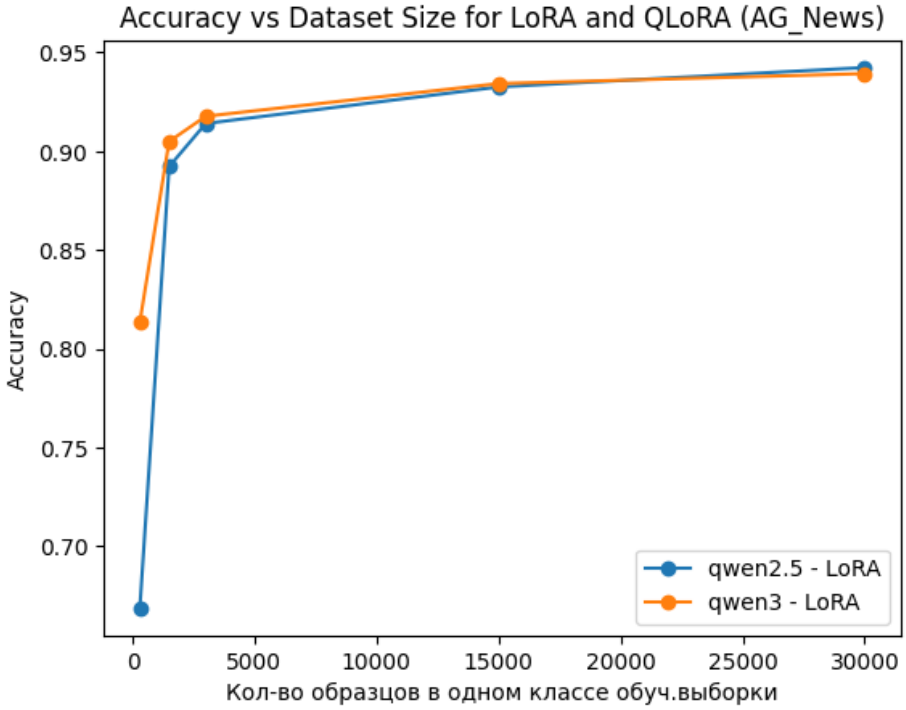

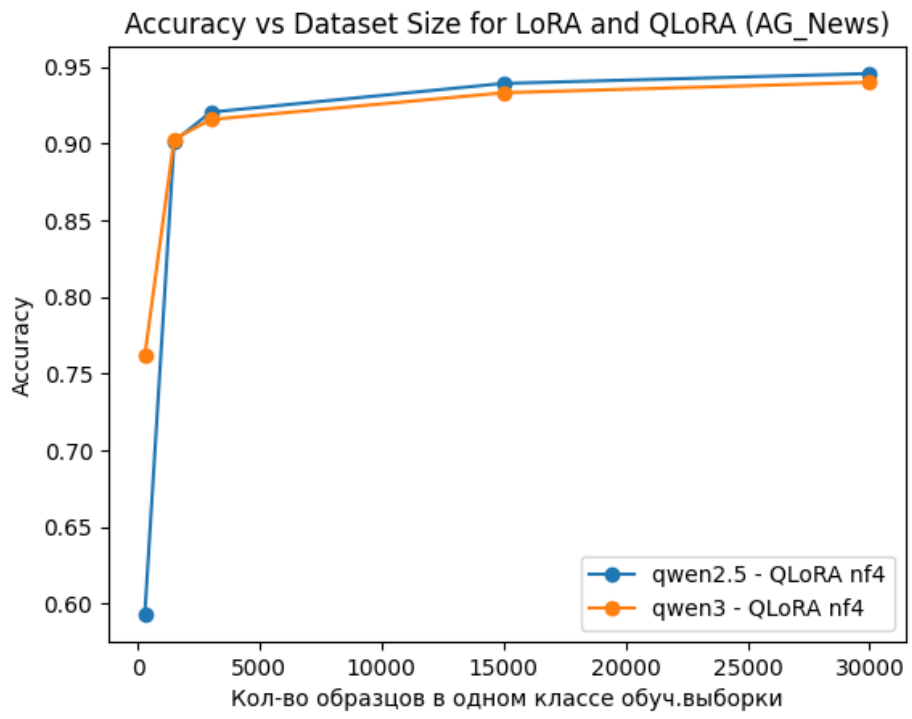

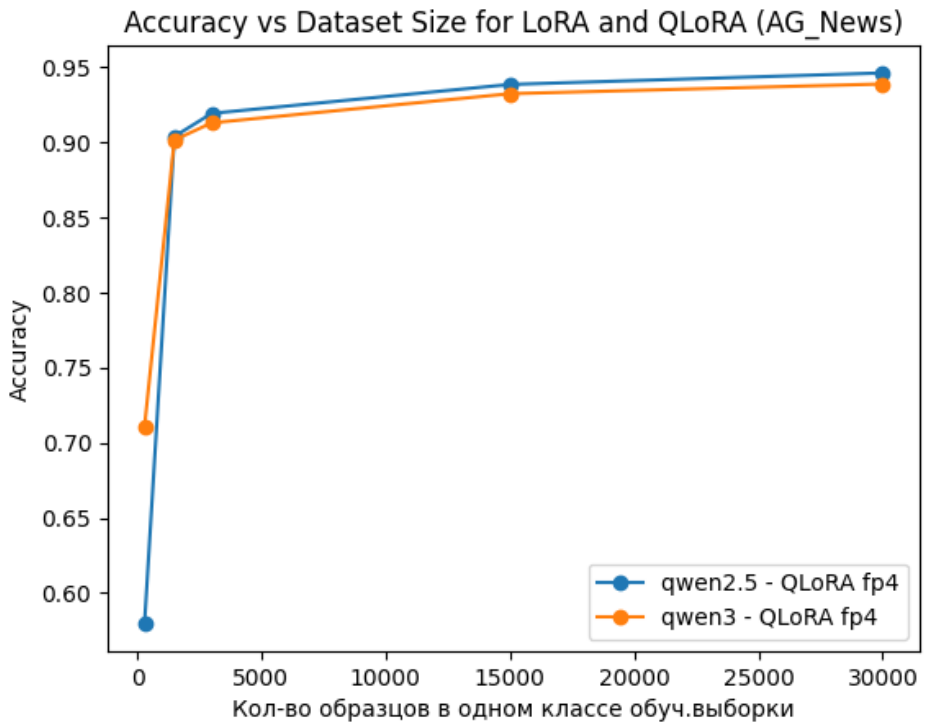

H1: Qwen2.5-1.5B показывает сопоставимое или лучшее качество при достаточном объёме данных (более 15 000 образцов в каждом классе обучающей выборки).

Для сравнения качества моделей использовался критерий Манна–Уитни, поскольку распределение метрик качества может отклоняться от нормального, а также присутствуют выбросы и неоднородность дисперсий.

Получено p = 0.000001, что свидетельствует о наличии статистически значимых различий (ноутбук analitics.ipynb). Это значит, что **модели статистичиески значимо различаются по качеству. Qwen2.5-1.5B показывает**

лучшее качество при достаточном объёме данных (более 15 000 образцов в каждом классе обучающей выборки).

H2: Qwen3-0.6B превосходит Qwen2.5-1.5B при 300-3000 образцов в каждом классе обучающей выборки.

Проведён Mann–Whitney тест. Получено p = 0.010481, что свидетельствует о наличии статистически значимых различий (ноутбук analitics.ipynb), т.е. **Qwen3-0.6B превосходит Qwen2.5-1.5B по качеству при 300-3000 образцов в каждом классе обучающей выборки**.

H3: Qwen3-0.6B даёт более стабильные результаты (меньше разброс loss)

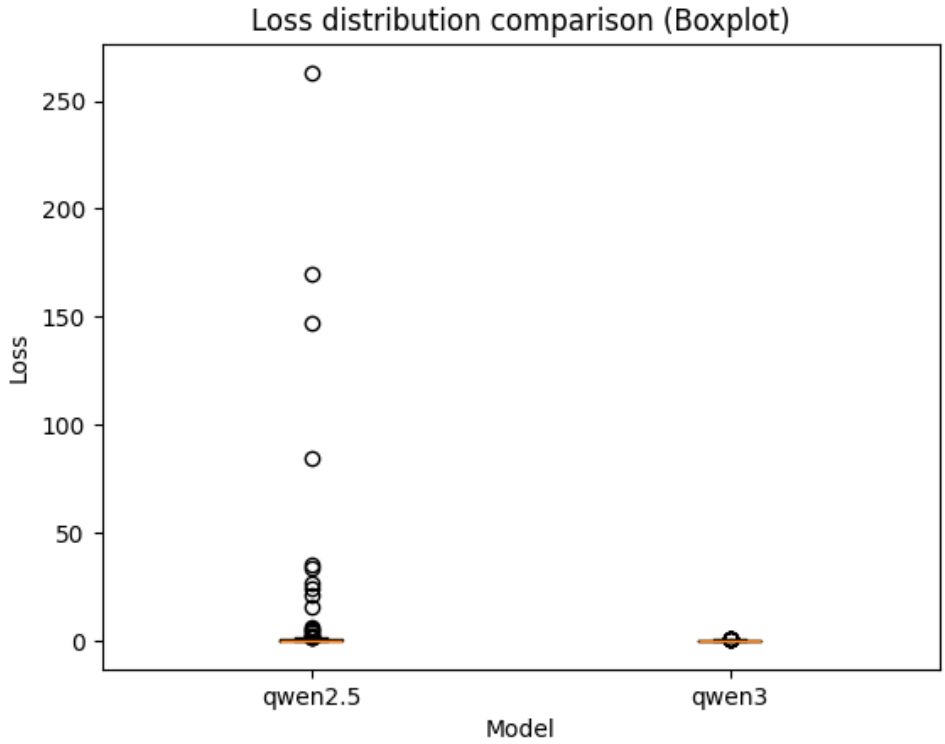

model	mean	std	min	max	count
qwen2.5	6.723886	40.973961	0.252099	580.500000	333
qwen3	0.485958	0.225646	0.257335	1.280976	333

Для оценки стабильности моделей использовался тест Левена, поскольку он позволяет сравнивать дисперсии выборок и устойчив к отклонениям от нормального распределения.

Тест показал:

Levene test p-value: 0.000009 < 0.05

Std Qwen2.5: 6.6713

Std Qwen3: 0.2196

Qwen3 более стабильна (меньше разброс loss). Разброс loss у модели Qwen3 статистически меньше (ноутбук analitics.ipynb).

H4: Qwen3-0.6B более экономная в части затрат памяти

model	mean GPU	min GPU	Max GPU	Std GPU

qwen2.5	5.117096	2.8762214	11.909000	1.806078
qwen3	3.329787	1.289078	5.790635	0.854608

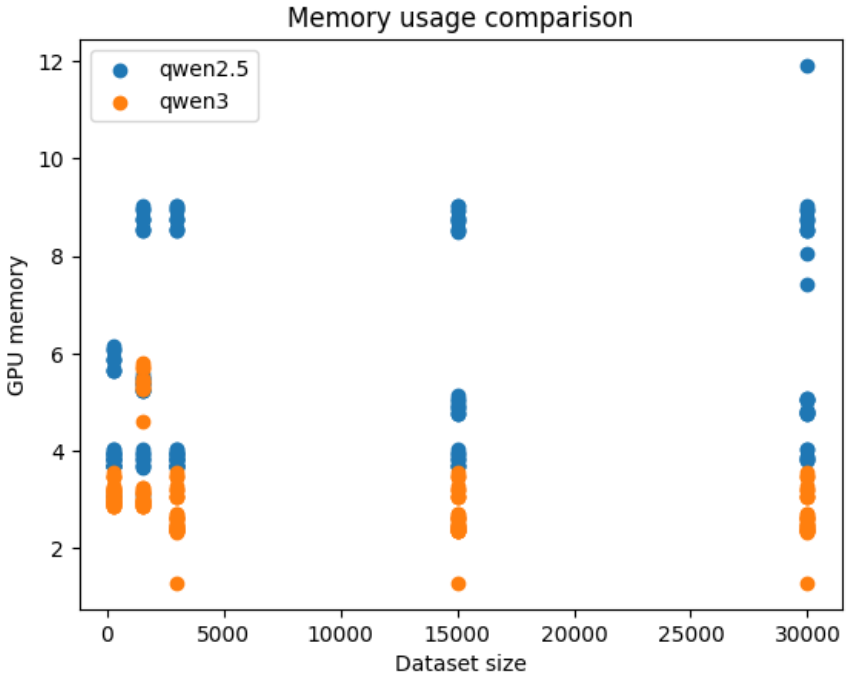

Из графика видно, что **Qwen3 более экономна по использованию памяти**

H5: Qwen3-0.6B отличается более высокой скоростью обучения

model	**mean**	**min**	**max**	**std**
qwen2.5	31.998227	1.498516	107.166794	33.493794
qwen3	23.952696	1.225227	80.794190	26.120518

Из таблицы видно, что **средняя скорость обучения Qwen3 выше.**

7.2 Эффект насыщения для rank

Qwen2.5-1.5B – AG_News (EN)	**Qwen3-0.6B – AG_News (EN)**
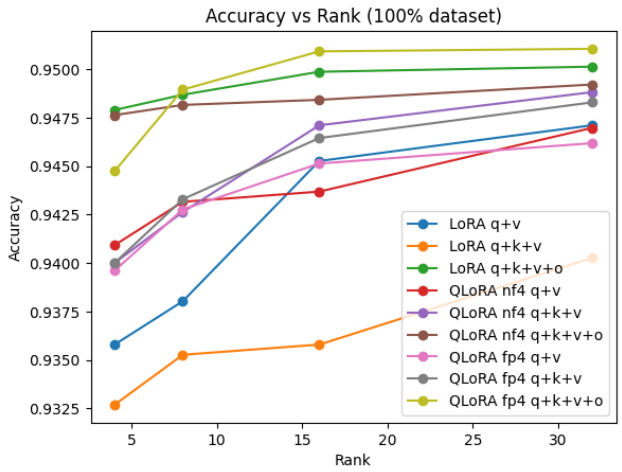	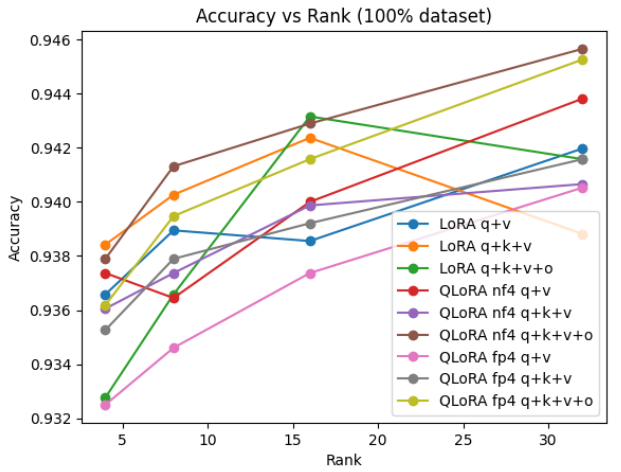

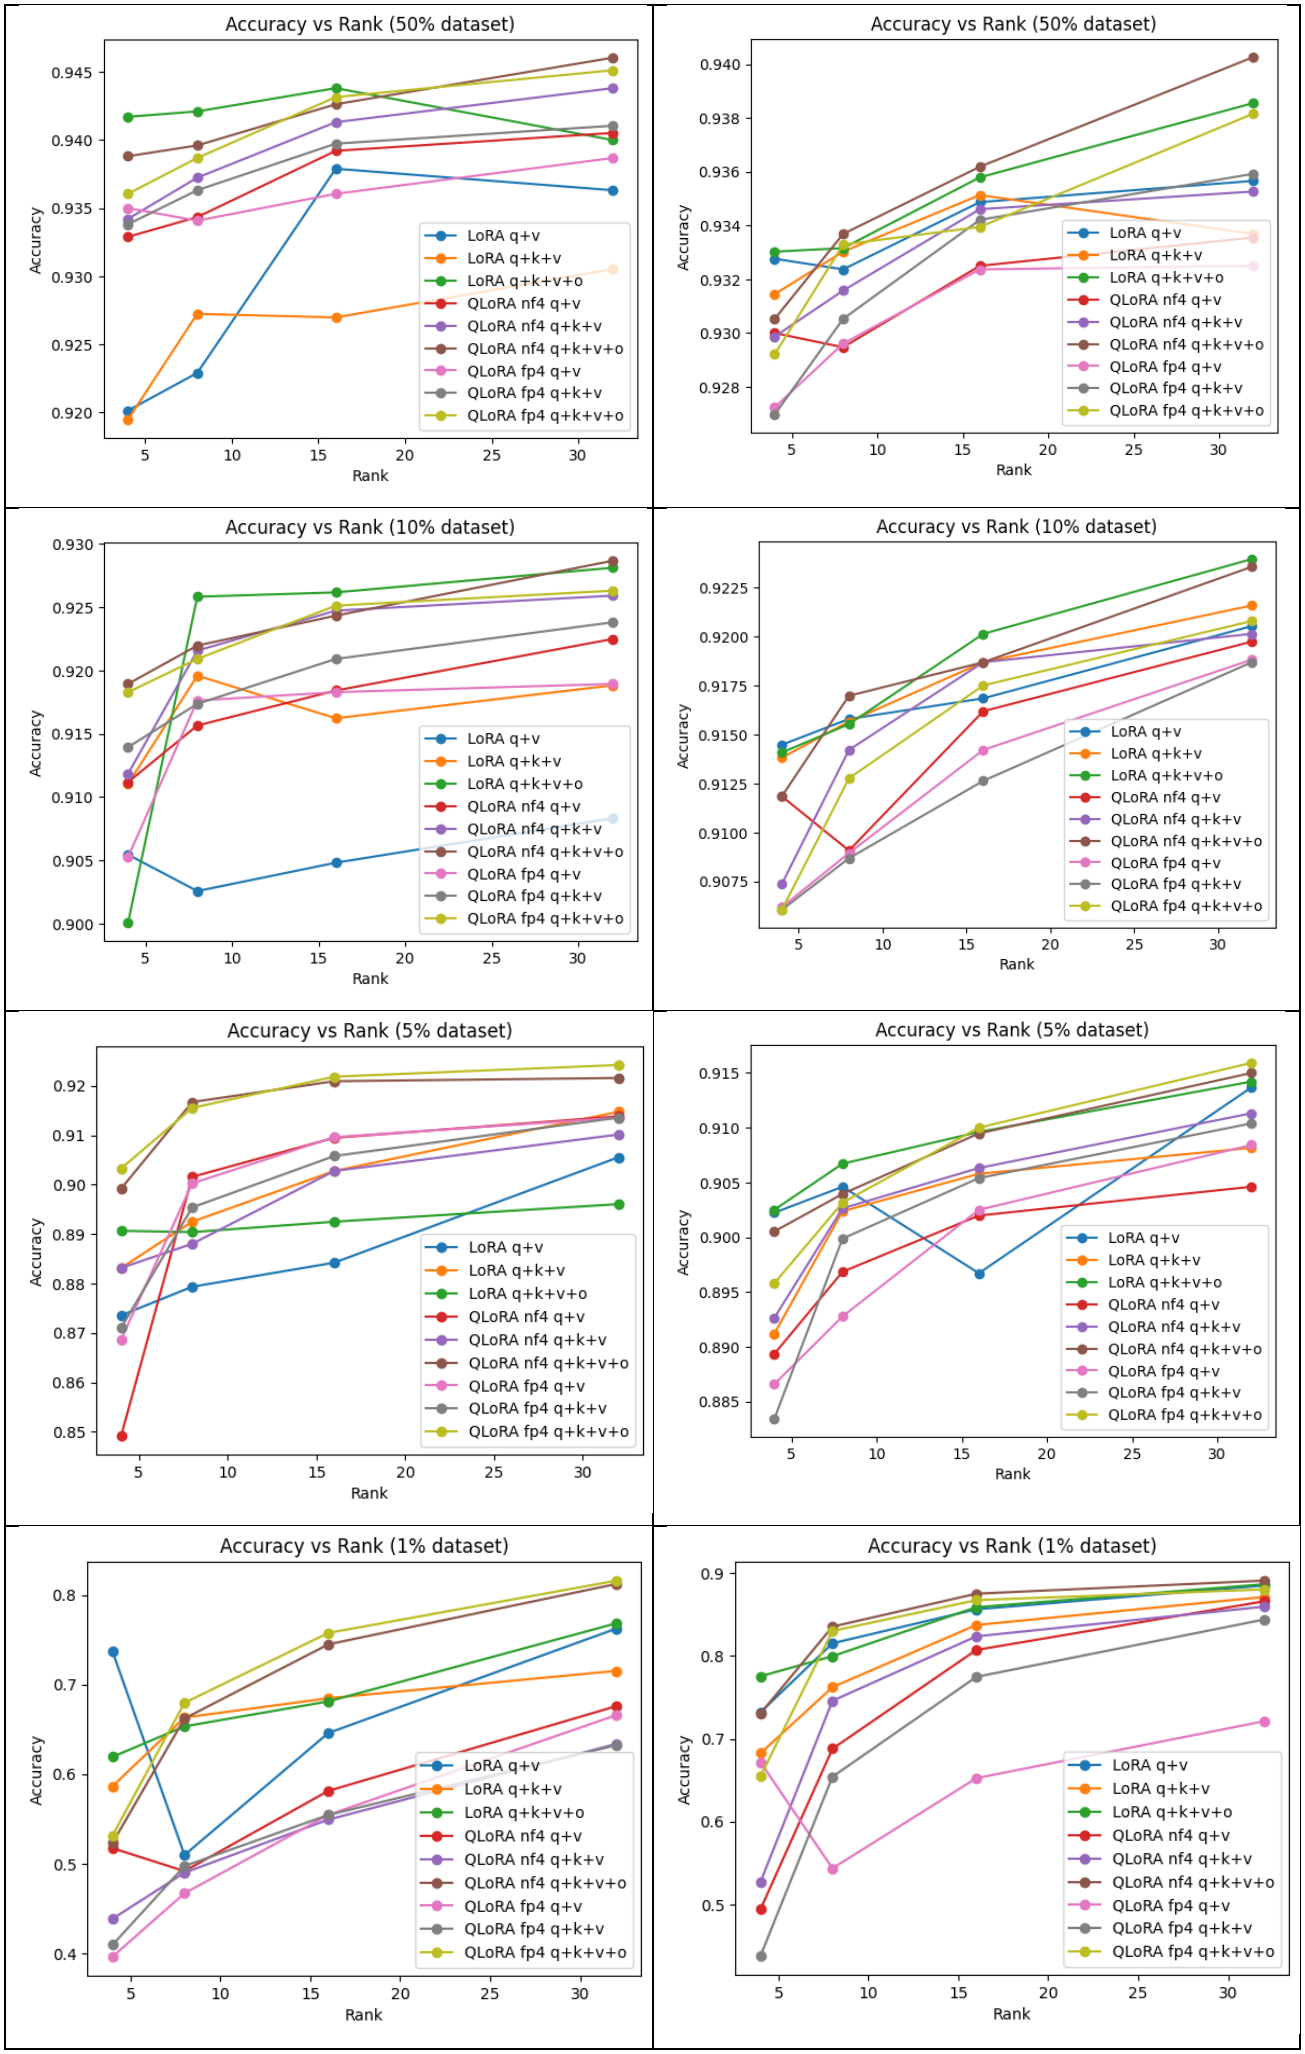
Accuracy vs Rank (50% dataset)
Accuracy vs Rank (50% dataset)
Accuracy vs Rank (10% dataset)
Accuracy vs Rank (10% dataset)
Accuracy vs Rank (5% dataset)
Accuracy vs Rank (5% dataset)
Accuracy vs Rank (1% dataset)
Accuracy vs Rank (1% dataset)
Accuracy
Rank
LoRA q+v
LoRA q+k+v
LoRA q+k+v+o
QLoRA nf4 q+v
QLoRA nf4 q+k+v
QLoRA nf4 q+k+v+o
QLoRA fp4 q+v
QLoRA fp4 q+k+v
QLoRA fp4 q+k+v+o

H6: Начиная с rank = 8, прирост качества становится минимальным.

Увеличение до 32 даёт менее 0.5–1% прироста к accuracy.

Увеличение rank даёт убывающую отдачу после rank=16

Для проверки гипотез 7 и 8 был выбран тест Краскела–Уоллиса написать почему

Kruskal-Wallis p-value для Qwen2.5: 0.025312 < 0.05

Попарные сравнения:

rank 4 vs 8: p=0.240359, mean_diff=0.0146

rank 4 vs 16: p=0.037048, mean_diff=0.0319

rank 4 vs 32: p=0.006365, mean_diff=0.0520

rank 8 vs 16: p=0.268250, mean_diff=0.0173

rank 8 vs 32: p=0.064933, mean_diff=0.0374

rank 16 vs 32: p=0.370220, mean_diff=0.0201

Kruskal-Wallis p-value для Qwen3: 0.016126 < 0.05

Попарные сравнения:

rank 4 vs 8: p=0.281500, mean_diff=0.0283

rank 4 vs 16: p=0.050236, mean_diff=0.0534

rank 4 vs 32: p=0.004183, mean_diff=0.0729

rank 8 vs 16: p=0.264647, mean_diff=0.0251

rank 8 vs 32: p=0.030469, mean_diff=0.0446

rank 16 vs 32: p=0.224633, mean_diff=0.0195

Проведёный тест показал, что **для обеих моделей статистически значимого плато не выявлено, что указывает на более эффективное использование высоких значений rank** (ноутбук analitics.ipynb).

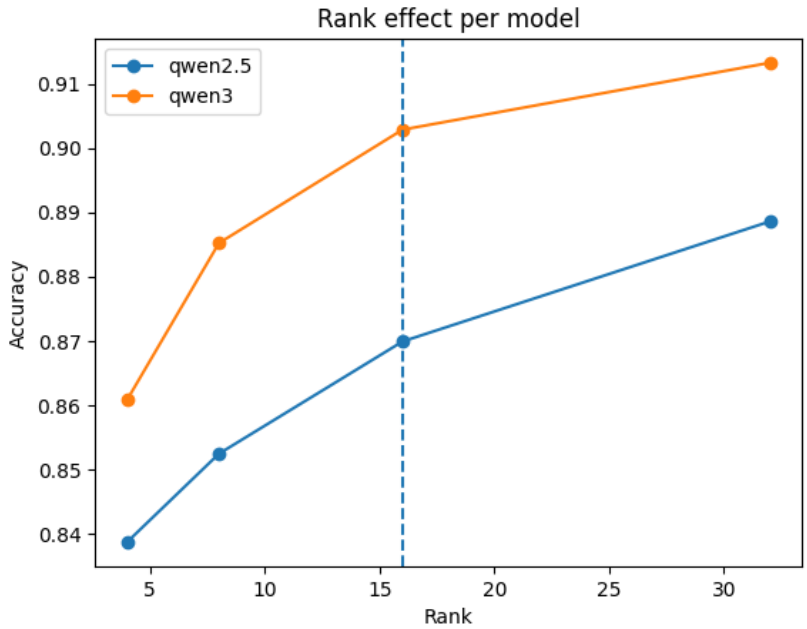

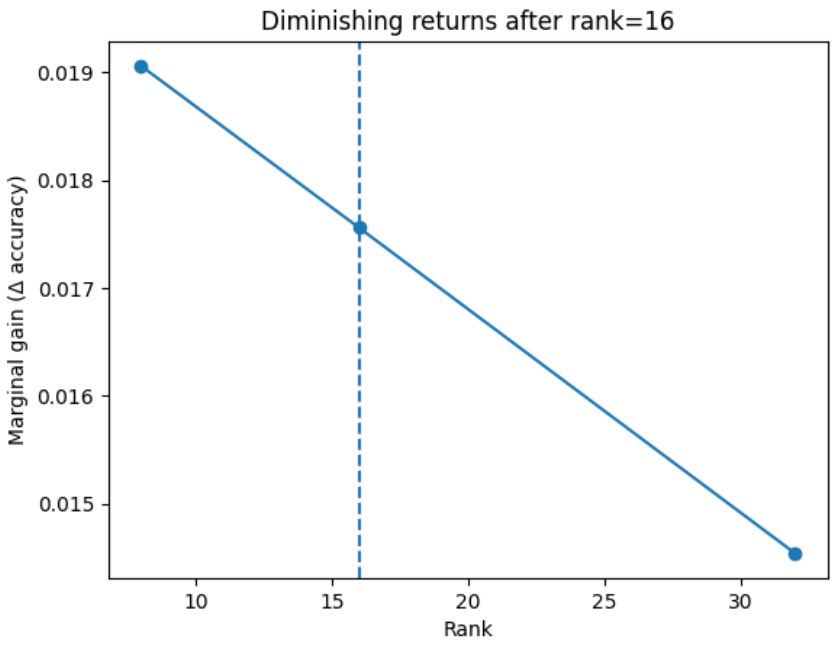

H7: Высокий rank (16-32) неэффективен при малом объёме данных (менее 3000 образцов в каждом классе обучающей выборки)

Проведен тест Мана-Уитни на малых данных (менее 3000 образцов в классе), который показал:

p-value: 0.000009 < 0.05

Low rank mean: 0.7867

High rank mean: 0.8470

Гипотеза о неэффективности высоких значений rank при малых объёмах данных не подтвердилась статистически. Тем не менее, увеличение rank сопровождается ростом вычислительных затрат, что снижает его практическую целесообразность. (ноутбук analitics.ipynb)

H8: Оптимальный rank зависит от объёма данных: малые данные - rank=4-8

большие - rank=16

Проведены попарные тесты Kruskal-Wallis, p-value < 0.05. Полученные результаты показывают, что влияние rank на качество сохраняется независимо от размера обучающей выборки.(ноутбук analitics.ipynb)

Поскольку исследуются категориальные факторы (rank и размер выборки) и их влияние на численную метрику качества, дополнительно был выбран дисперсионный анализ (ANOVA), позволяющий оценить как индивидуальное влияние факторов, так и их взаимодействие.

Для обеих моделей выявлено:

- статистически значимое влияние rank ($p < 0.001$)
- статистически значимое влияние размера выборки ($p < 0.001$)
- статистически значимое взаимодействие факторов ($p < 0.001$)

Наличие взаимодействия свидетельствует о том, что влияние rank на качество модели зависит от объёма обучающих данных. (ноутбук analitics.ipynb)

Однако, двухфакторный анализ (ANOVA) выявил статистически значимое взаимодействие факторов. Это означает, что влияние rank действительно зависит от объёма данных, но эта зависимость не является простой и линейной.

В рамках дисперсионного анализа использовались следующие показатели:

сумма квадратов (sum_sq), отражающая вклад фактора в вариацию данных;

степени свободы (df);

F-статистика, характеризующая отношение объяснённой и необъяснённой вариации;

p-value (PR(>F)), определяющее статистическую значимость;

а также коэффициент η^2, оценивающий величину эффекта.

Для оценки силы влияния факторов был рассчитан коэффициент η^2. (https://www.statsmodels.org/stable/anova.html)

Показатель	sum_sq	df	F	PR(>F)	η^2
qwen2.5-1.5					
C(rank)	0.063103	3.0	12.553398	2.056105e-07	0.019197
C(размер выборки)	2.821160	4.0	420.923776	8.791015e-84	0.858246
C(rank):C(размер выборки)	0.134767	12.0	6.702506	1.106033e-09	0.040998
Residual	0.268092	160.0	NaN	NaN	0.081558
qwen3-0.6					
C(rank)	0.242551	3.0	28.874335	1.980109e-16	0.056916
C(размер выборки)	2.593307	5.0	185.231054	1.781876e-89	0.608537
C(rank):C(размер выборки)	0.585662	15.0	13.943944	9.955210e-27	0.137430
Residual	0.840023	300.0	NaN	NaN	0.197117

(ноутбук analitics.ipynb)

Для модели Qwen2.5 основной вклад в качество вносит размер обучающей выборки ($\eta^2 = 0.86$), в то время как влияние rank является незначительным ($\eta^2 = 0.02$). Взаимодействие факторов оказывает ограниченное влияние.

В отличие от Qwen2.5, для модели Qwen3 наблюдается более выраженное влияние rank ($\eta^2 = 0.057$) и особенно взаимодействия факторов ($\eta^2 = 0.137$), что указывает на зависимость эффективности выбора rank от объёма обучающей выборки.

Модель Qwen2.5 в основном определяется объёмом данных и слабо зависит от параметров адаптера, тогда как Qwen3 демонстрирует значительно более сложное поведение, включая существенную зависимость от rank и его взаимодействия с размером выборки.

7.3 Расширение target modules. Сравнение: q+v, q+k+v, q+k+v+o

H9: (q+v) даёт лучшее соотношение качество/ресурсы

- Accuracy растёт слабо (≈ +1-2%)

- увеличивает время и память. С увеличением количества адаптируемых модулей наблюдается рост времени обучения и GPU, что связано с увеличением числа обновляемых параметров и вычислительной нагрузки.

- рост модулей не всегда дает пропорциональный рост accuracy, (q+v) часто дает лучшее качество, чем (q+k+v).

Использовать (q+v) для экономии времени и памяти либо (q+k+v+o) для большей точности имеет более высокую стабильность.

Qwen2.5-1.5B (EN)	**Qwen3-0.6B (EN)**
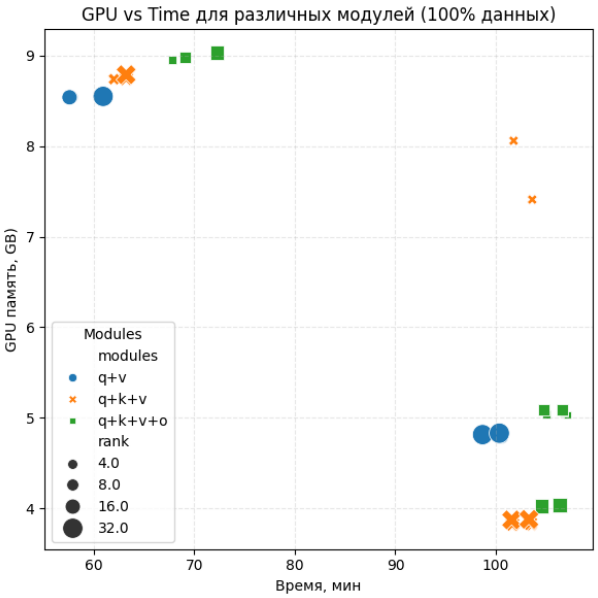	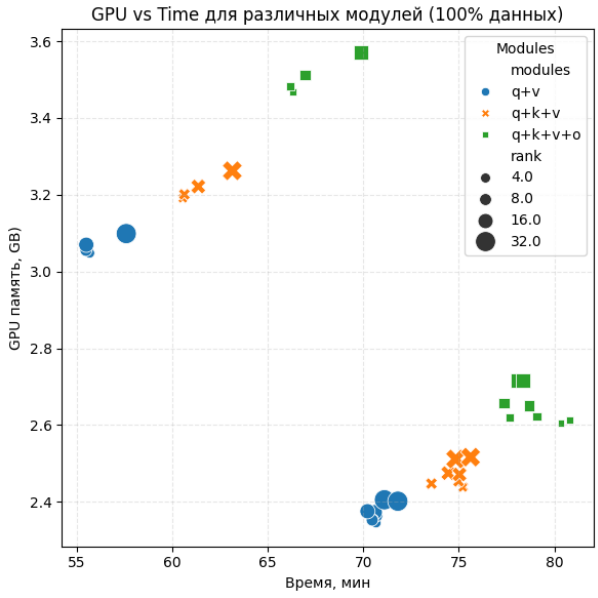
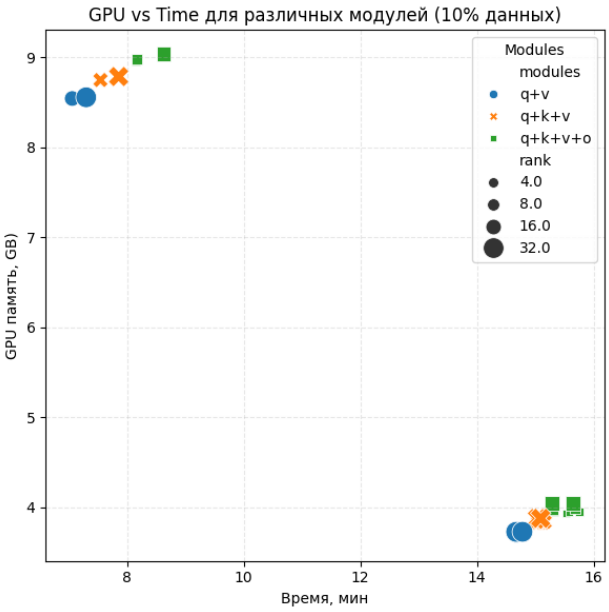	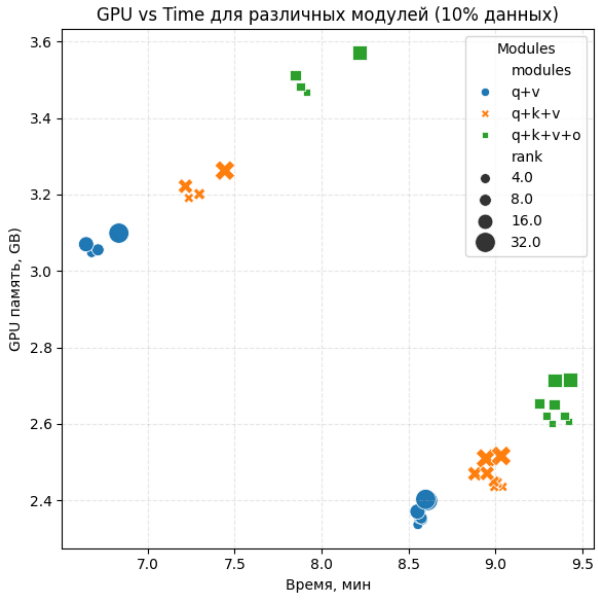

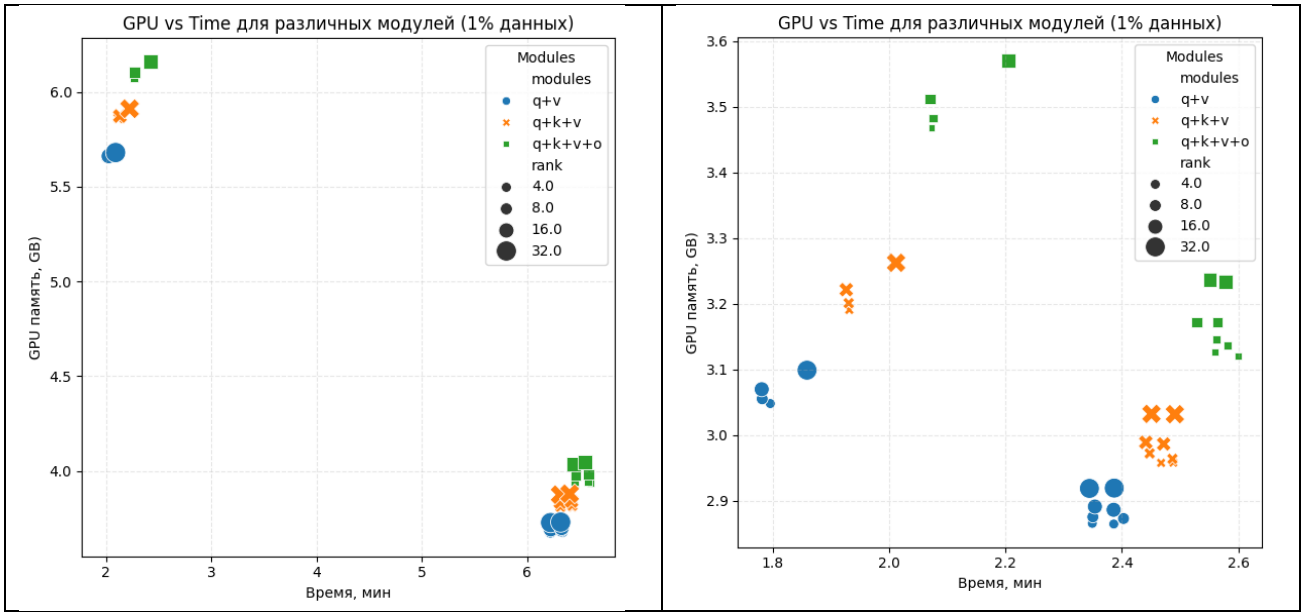

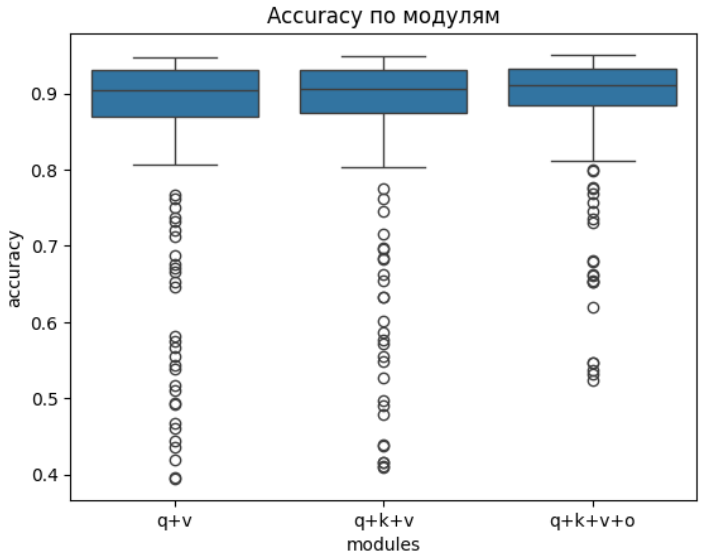

Разница в accuracy между модулями

p-value: 0.043967 < 0.05

q+v: mean=0.8449, std=0.1446

q+k+v: mean=0.8461, std=0.1424

q+k+v+o: mean=0.8735, std=0.1035

Установлено, что (q+v) ≈ (q+k+v)

(q+k+v+o) значимо лучше (~+2.7–2.9%)

Т.е. добавление (o) даёт реальный прирост качества

Модули:	Mean time:	eff_time	Mean GPU:	eff_gpu
q+v	21.893991	0.117249	4.002609	0.244932
q+k+v	22.989166	0.112568	4.127898	0.238179
q+k+v+o	24.726138	0.113545	4.315418	0.230899

При этом наблюдается монотонный рост вычислительных затрат (времени обучения и потребления GPU) с увеличением числа модулей.

Анализ показал, что конфигурация (q+v) обеспечивает наилучшее соотношение качества и вычислительных ресурсов, демонстрируя максимальную

эффективность при минимальных затратах времени и памяти. При этом её качество практически не отличается от (q+k+v).

Добавление выходного слоя (o) ((q+k+v+o)) приводит к статистически значимому увеличению accuracy (~2.7–2.9%), однако сопровождается ростом вычислительных затрат.

Увеличение числа модулей приводит к монотонному росту времени обучения и потребления GPU, что подтверждает увеличение вычислительной нагрузки.

Анализ стабильности не выявил статистически значимых различий между конфигурациями ($p > 0.05$), хотя наблюдаются слабые тенденции к большей стабильности (q+k+v+o) по accuracy.

Таким образом, **гипотеза H11 подтверждается: (q+v) действительно является оптимальной конфигурацией с точки зрения эффективности, а максимальное качество достигается при использовании (q+k+v+o).** (ноутбук analitics.ipynb)

7.4. QLoRA vs LoRA

H10: QLoRA сохраняет ≥95% качества LoRA при значительном снижении VRAM, но требует существенно большего времени обучения.

Accuracy:

- Среднее отношение: 0.976
- Медиана: 0.998
- Доля ≥95%: 87.3%
- Минимум: 0.538
- 5-й перцентиль: 0.754
- Wilcoxon p-value < 0.05

Поскольку сравнивались парные наблюдения (одни и те же конфигурации для LoRA и QLoRA), и распределение метрик не гарантирует нормальность, был использован непараметрический критерий Уилкоксона.

В результате экспериментов установлено, что QLoRA в среднем сохраняет около 98.4% качества LoRA, при этом в 89% случаев достигается уровень не ниже 95%. Однако статистический анализ (тест Уилкоксона, $p = 0.0013$) показывает наличие значимого снижения качества, что не позволяет утверждать сохранение ≥95% качества во всех случаях.

При этом QLoRA обеспечивает значительное снижение потребления GPU (в среднем до 71.6% от LoRA, $p = 0.001$), что подтверждает его эффективность в условиях ограниченных вычислительных ресурсов.

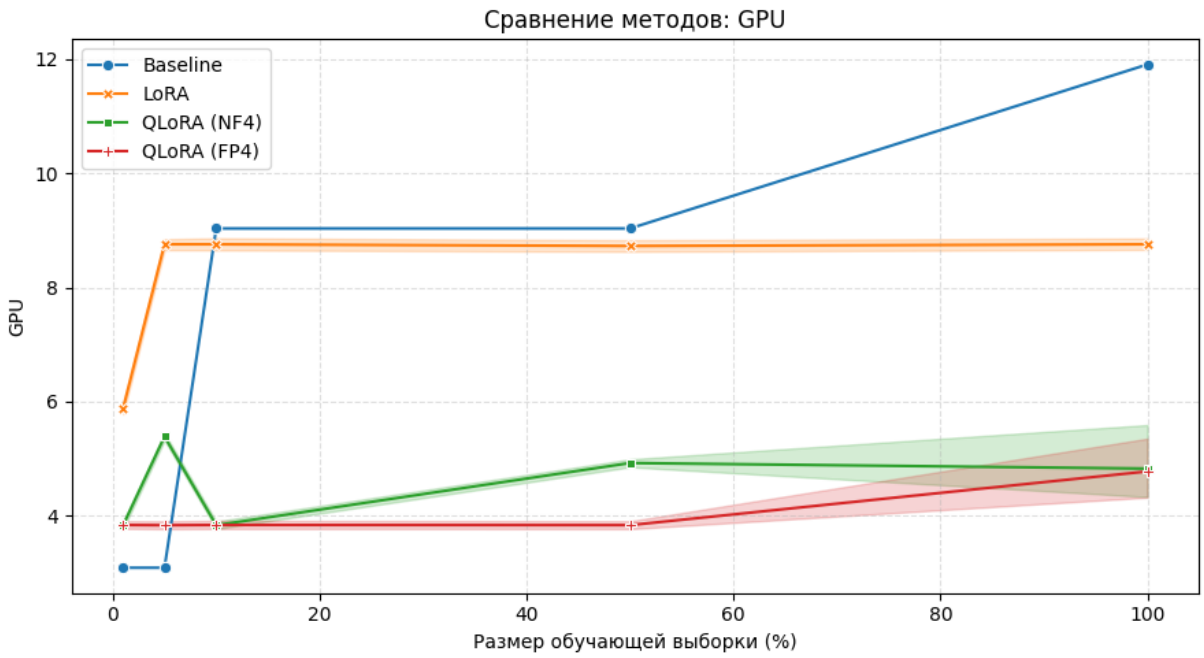

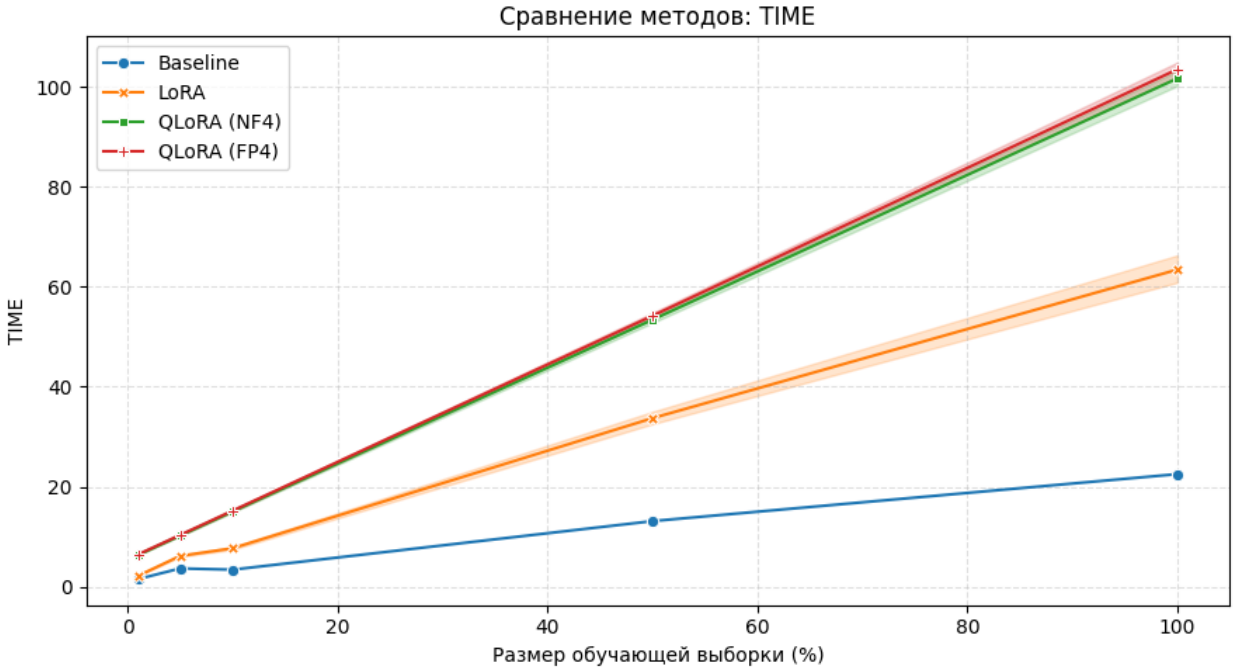

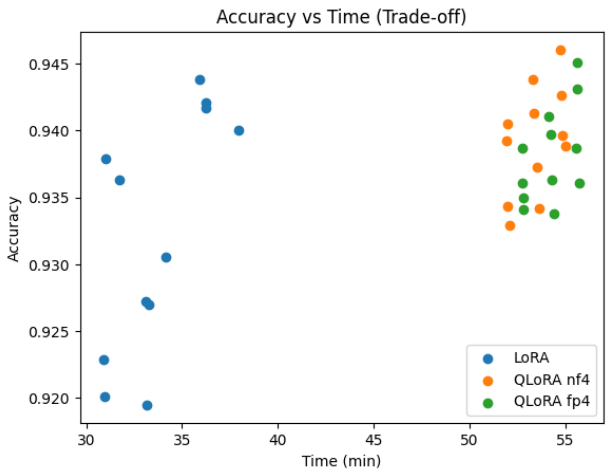

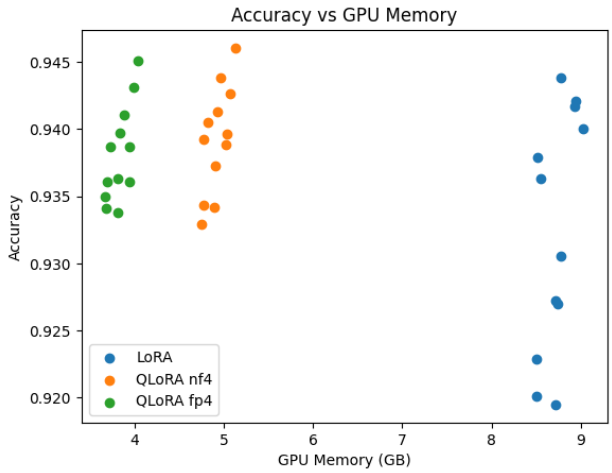

В то же время установлено, что QLoRA требует существенно большего времени обучения: в среднем время увеличивается на 49% (ноутбук analitics.ipynb), причём почти во всех случаях QLoRA оказывается медленнее

LoRA. Это связано с дополнительными вычислительными затратами на операции квантования и деквантования.

Таким образом, **QLoRA представляет собой компромисс: значительная экономия памяти достигается ценой умеренного снижения качества и существенного увеличения времени обучения.**

H11: При малых данных (менее 3000 образцов в каждом классе обучающей выборки) разница между LoRA и QLoRA минимальна

Для малых выборок (<3000) различия между LoRA и QLoRA являются статистически значимыми, при этом среднее абсолютное отклонение составляет около 4.55%. Хотя медианное отклонение невелико (≈1.7%), лишь в 55.7% случаев разница не превышает 2%, что не позволяет считать различия стабильно минимальными.

При этом величина эффекта (Cliff's delta = 0.063) указывает на слабое практическое различие между методами.

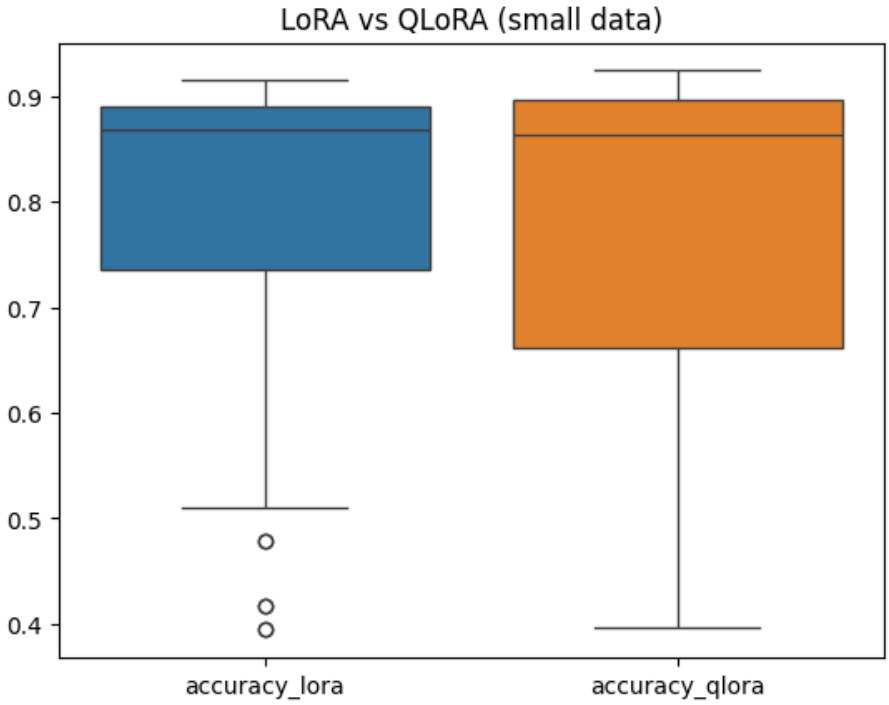

Различие LoRA vs QLoRA при росте данных

	size	mean_diff	mean_abs_diff	median_abs_diff	share_≤2%	wilcoxon_p	n_pairs
0	300	-0.080232	0.103134	0.087105	0.208333	7.186852e-09	96
1	1500	0.001278	0.008433	0.004871	0.854167	6.472859e-01	96
2	3000	-0.000739	0.007642	0.004831	0.979167	3.143720e-04	96

(ноутбук analitics.ipynb)

Анализ показал, что **гипотеза о минимальной разнице между LoRA и QLoRA на малых выборках подтверждается лишь частично и зависит от объёма данных**.

При крайне малом размере выборки (300 примеров) QLoRA демонстрирует существенно более низкое качество по сравнению с LoRA (разница около 8–10%, $p < 0.001$), что указывает на недостаточную устойчивость метода в условиях ограниченных данных.

Однако **при увеличении размера выборки до 1500 и выше различия между методами становятся практически нулевыми** (менее 1%) и статистически незначимыми или практически незначимыми с точки зрения эффекта.

Таким образом, можно выделить порог стабилизации: начиная примерно с 1500 примеров, QLoRA достигает качества, сопоставимого с LoRA.

7.5. FP4 vs NF4

H12: Разница между NF4 и FP4 незначительна по качеству

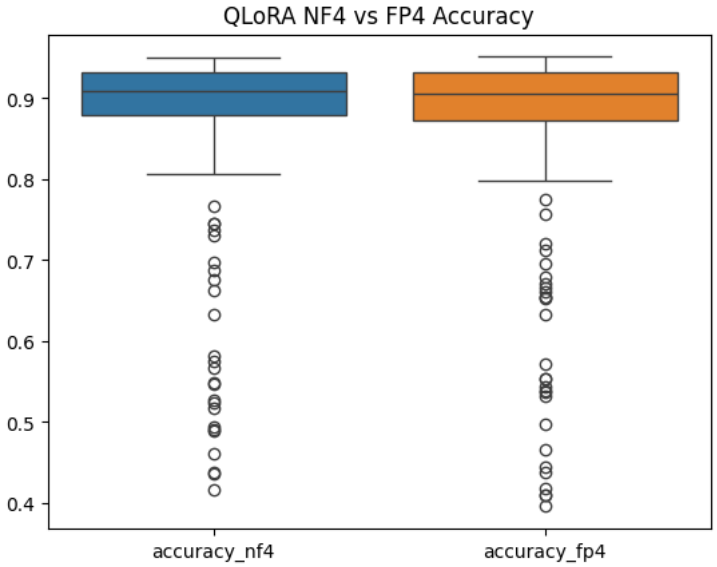

Анализ показал, что различия между NF4 и FP4 по качеству являются статистически значимыми ($p < 0.001$), однако их величина крайне мала. Средняя разница составляет менее 1%, а в более чем 90% случаев она не превышает 2%.

Величина эффекта (Cliff's delta ≈ 0.04) указывает на пренебрежимо малый эффект, что свидетельствует об отсутствии практической значимости различий.

Таким образом, гипотеза H14 подтверждается с точки зрения практической значимости: **NF4 и FP4 демонстрируют практически одинаковое качество, несмотря на формальную статистическую значимость различий.**

(ноутбук analitics.ipynb)

H13: NF4 даёт более стабильный результат

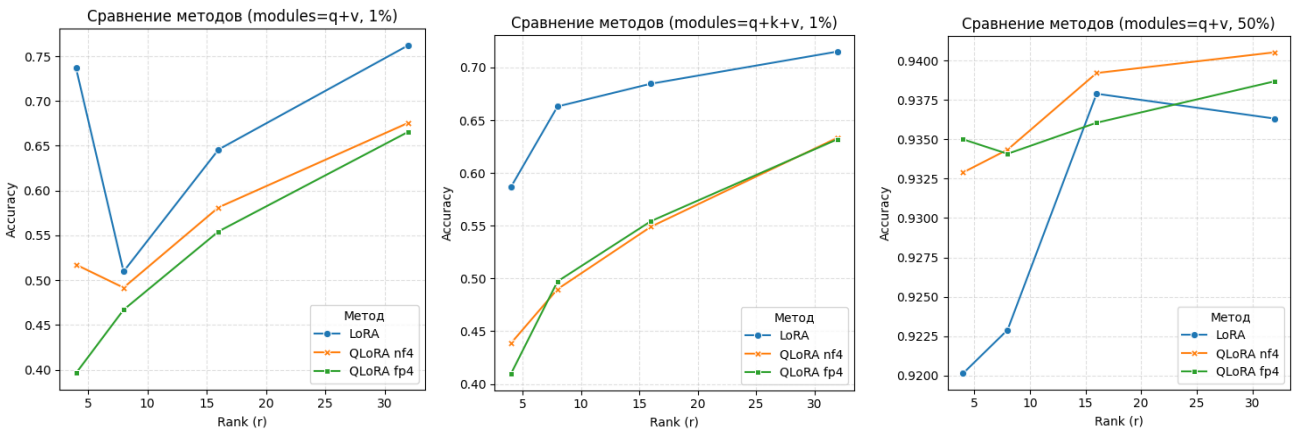

Анализ стабильности показал, что NF4 демонстрирует немного меньшую вариативность по сравнению с FP4 как по accuracy (std = 0.126 против 0.134), так и по loss (std = 0.256 против 0.275). Однако тест Левена не выявил статистически значимых различий дисперсий ($p > 0.05$), что указывает на отсутствие устойчивого различия в стабильности методов. (ноутбук analitics.ipynb)

Таким образом, наблюдаемое **преимущество NF4 носит слабовыраженный характер и не является статистически значимым.**

7.6. Baseline vs LoRA

H14: Baseline проигрывает по качеству.

Разница качества:

- LoRA vs baseline: +17.5%
- QLoRA vs baseline: +16.3%

Статистическая значимость:

- LoRA: $p \approx 1.8e-35$
- QLoRA: $p \approx 7.9e-61$ (ноутбук analitics.ipynb)

Различия значимы

Даже на малых данных baseline сильно проигрывает, особенно LoRA

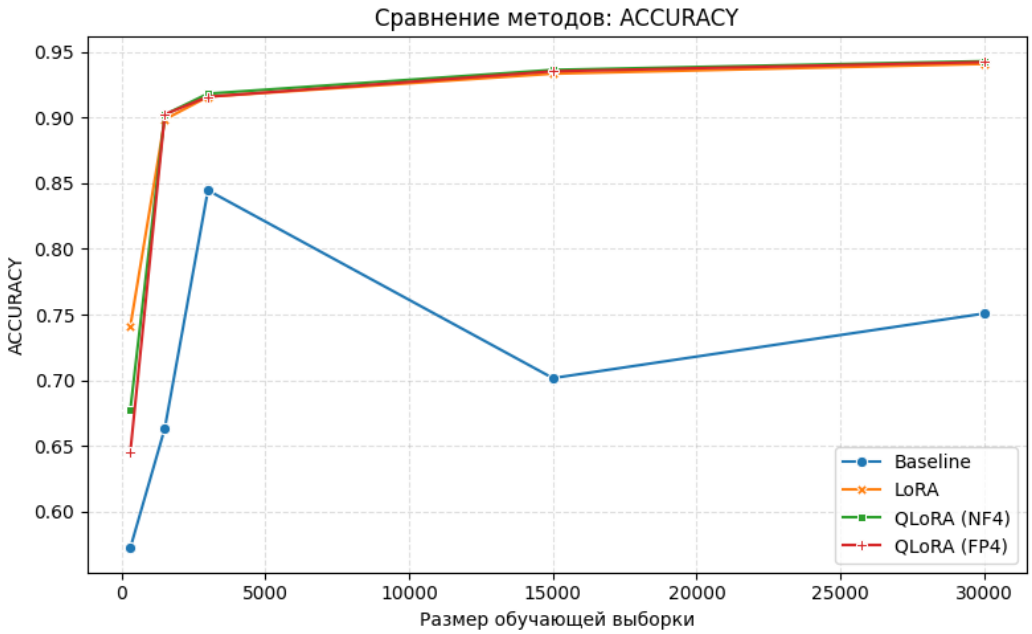

Fine-tuning только головы недостаточен при ограниченных ресурсах. При нетребовательных условиях к качеству модели baseline может быть актуален, т.к. тратит минимум памяти и временени на обучение по сравнению с другими моделями.

7.7. Влияние языка (RU vs EN)

H15: Качество выше на английском, чем на русском

Результаты экспериментов показывают, что качество моделей на английском языке существенно выше, чем на русском. Средняя разница в accuracy составляет около 5–6%. При парном сравнении английская версия превосходит русскую в 100% случаев, при этом в 94.6% случаев разница превышает 2%.

Статистический анализ подтверждает значимость различий ($p < 0.001$), а величина эффекта (Cliff's delta ≈ 0.54) указывает на сильный эффект.

Это может быть связано как с языком так и с качеством подготовки данных.

Таким образом, гипотеза H17 полностью подтверждается: **модели демонстрируют значительно более высокое качество на английском языке.**

H16: Qwen3 меньше теряет качество с уменьшением выборки на русском, чем Qwen2.5

Размер	Qwen2.5 drop	Qwen3 drop	Кто лучше	p-value
300	0.346	0.275	Qwen3	0.002
1500	0.025	0.033	Qwen2.5	0.0004
3000	0.008	0.017	Qwen2.5	1e-07

Qwen3 устойчивее только в экстремально малых выборках

Анализ показал, что **устойчивость моделей к уменьшению размера обучающей выборки на русском языке зависит от объёма данных**.

В условиях крайне малых выборок (300 примеров) модель Qwen3 демонстрирует меньшую деградацию качества по сравнению с Qwen2.5 ($p < 0.01$), что указывает на лучшую устойчивость в low-data режиме.

Однако при увеличении размера выборки (1500 и 3000) ситуация меняется: Qwen2.5 показывает меньшую потерю качества, а различия остаются статистически значимыми ($p < 0.001$).

Таким образом, гипотеза H18 не подтверждается в общем виде. Вместо этого выявлен эффект зависимости от размера данных: **Qwen3 более устойчив в экстремально малых выборках, тогда как Qwen2.5 демонстрирует лучшую стабильность при умеренных и больших объёмах данных.**

H17: Русский язык сильнее страдает при уменьшении данных

Размер выбрки	EN среднее	RU среднее	mean diff RU-EN accuracy	Median diff RU-EN accuracy	p_value	n_pairs

	падение accuracy	падение accuracy				
300	0.228485	0.297669	0.069184	0.056469	8.006213e-10	72
1500	0.015543	0.016448	0.000905	0.001790	1.251771e-02	72

Анализ влияния размера обучающей выборки на устойчивость моделей показал, что различия между английским и русским языками проявляются только в условиях экстремально малых данных. При размере выборки 300 примеров наблюдается статистически значимо более сильная деградация качества на русском языке ($p < 0.001$), с разницей около 7% по величине падения accuracy.

Однако при увеличении размера выборки до 1500 примеров различия становятся минимальными (≈0.09%) и практически незначимыми с точки зрения эффекта.

Таким образом, гипотеза подтверждается частично: **русский язык более чувствителен к уменьшению данных только при выборке 300 образцов в классе, но не демонстрирует систематически более сильную деградацию при увеличении объёма данных.**

H18: Для русского языка Qwen2.5 дает более высокое качество

Mean drop qwen2.5: 0.012628381629629632

Mean drop qwen3: 0.06076628044444446

Median drop qwen2.5: 0.004193478499999959

Median drop qwen3: 0.028711930499999982

Wilcoxon p-value: 3.61998153537165e-14

Cliff's delta: -0.627914951989026

Анализ показал, что модель **Qwen3 теряет значительно больше качества при переходе с английского на русский язык по сравнению с Qwen2.5.** Среднее снижение accuracy составляет около 6% для Qwen3 против 1.3% для Qwen2.5.

Различия являются статистически значимыми ($p < 0.001$), а величина эффекта (Cliff’s delta ≈ -0.63) указывает на сильный эффект.

Таким образом, гипотеза H18 подтверждается: Qwen3 демонстрирует существенно меньшую устойчивость к смене языка по сравнению с Qwen2.5.

7.8. Влияние объема данных

1. Поведение на малых данных

На 300 образцов в классе LoRA лучше по качеству, чем QloRA. На больших объемах данных картина менятеся в обратную сторону.

2. Размер выборки

При 10% датасета (3000 заголовков в классе) метрики уже выходят на хороший уровень, далее рост происходит менее интенсивно, зато затраты на время обучения резко растут

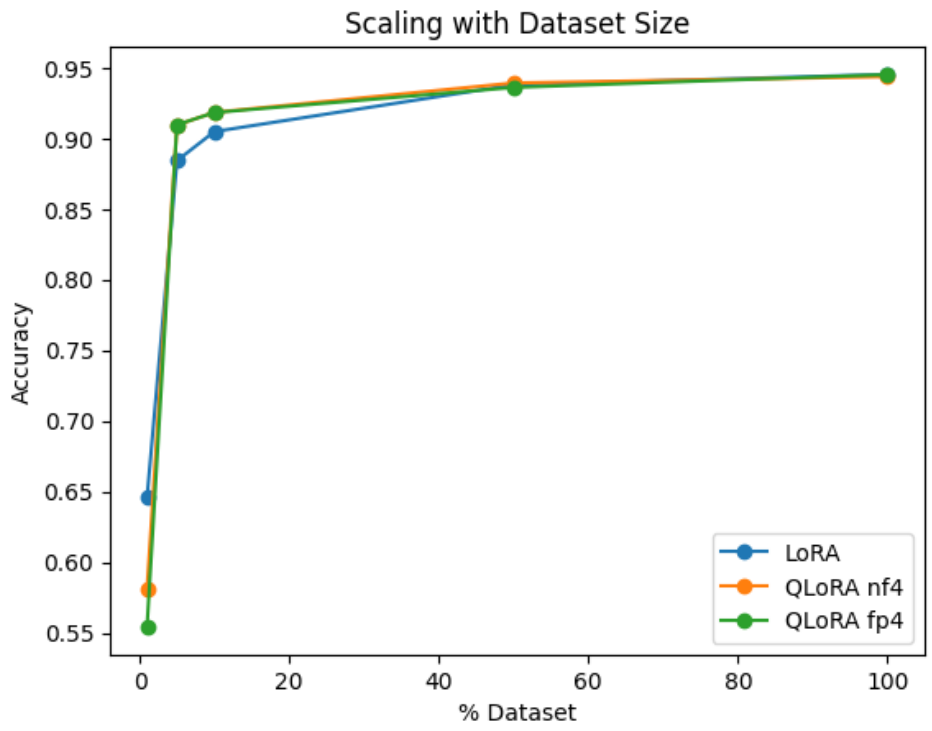

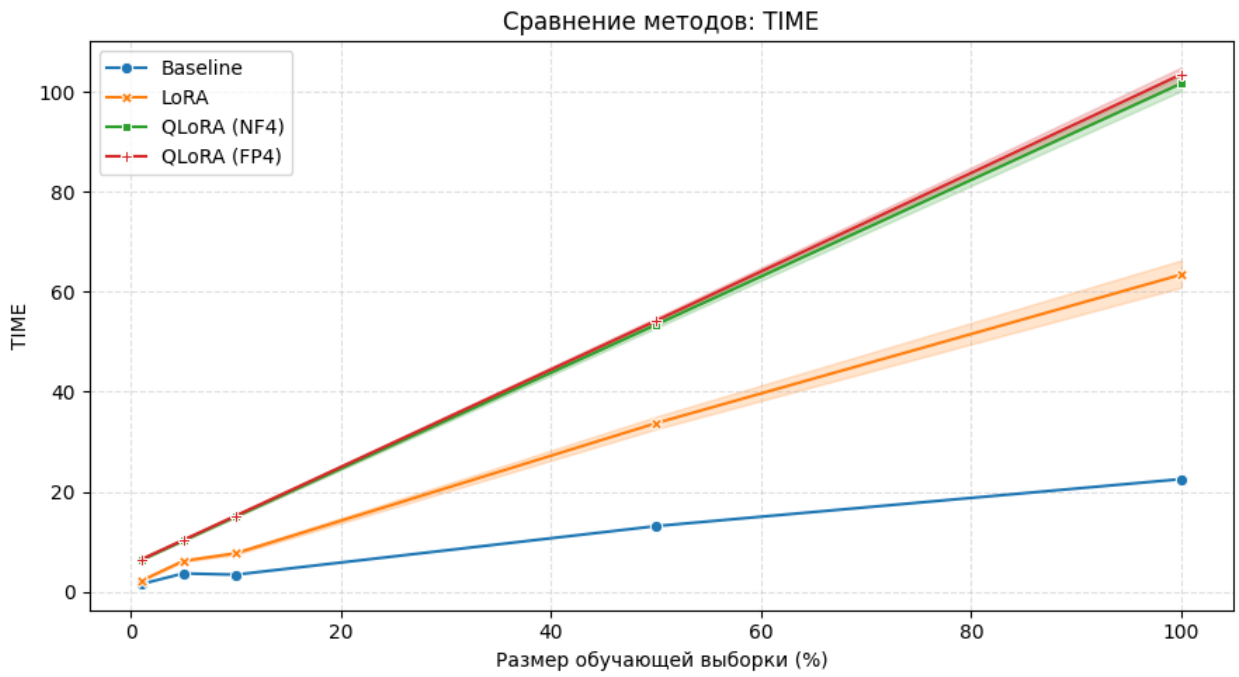

Оптимальный выбор для выборки на русском языке и на английском

H19: Оптимальная конфигурация при ≤10% (менее 3000 образцов) данных:

- Qwen3-0.6B
- rank=4-8
- qv/qkvo

- QloRA

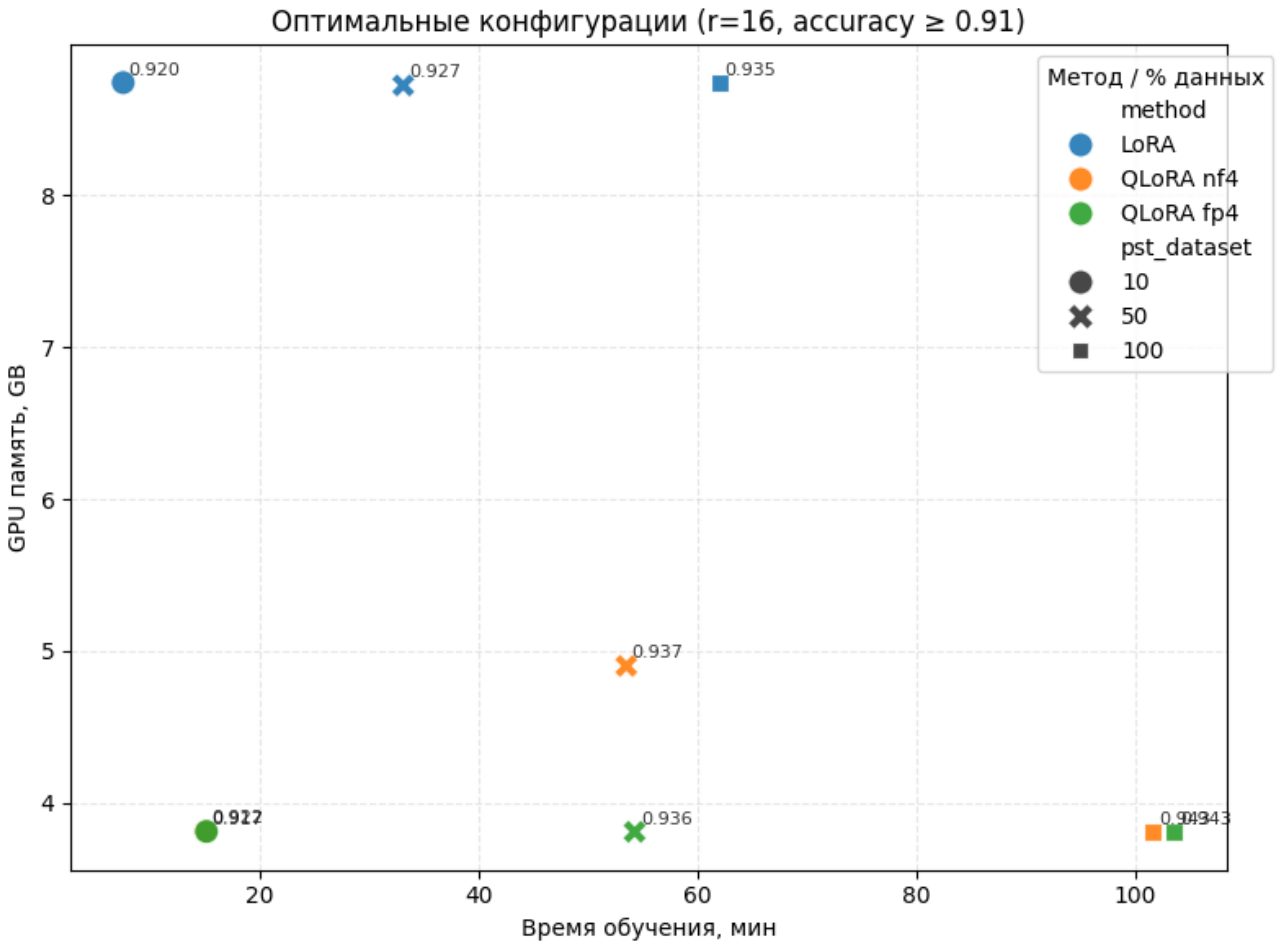

H20: Оптимальная конфигурация при 100%:

- Qwen2.5-1.5B
- rank=16
- qkv/qkvo
- LoRA

Общие выводы:

Qwen2.5-1.5B показывает лучшее качество при достаточном объёме данных (более 1500 образцов в каждом классе обучающей выборки), при 300 образцов в каждом классе обучающей выборки Qwen3-0.6 выдает лучшее качество.

Qwen3 более стабильна (меньше разброс loss) и более экономна по использованию памяти и времени обучения.

Увеличение rank сопровождается ростом качества, но также и ростом вычислительных затрат.

Модель Qwen2.5 в основном определяется объёмом данных и слабо зависит от параметров адаптера, тогда как Qwen3 демонстрирует значительно более сложное поведение, включая существенную зависимость от rank и его взаимодействия с размером выборки.

(q+v) является оптимальной конфигурацией с точки зрения эффективности, а максимальное качество достигается при использовании (q+k+v+o).

QLoRA представляет собой компромисс: значительная экономия памяти достигается ценой умеренного снижения качества и существенного увеличения времени обучения.

Можно выделить порог стабилизации: начиная примерно с 1500 примеров, QLoRA достигает качества, сопоставимого с LoRA.

NF4 и FP4 демонстрируют практически одинаковое качество.

Fine-tuning только головы недостаточен при ограниченных ресурсах.

Русский язык более чувствителен к уменьшению данных при выборке 300 образцов в классе, сильно теряет в качестве.

Qwen3 теряет значительно больше качества при переходе с английского на русский язык по сравнению с Qwen2.5.

В данной задаче классификации новостных заголовков оптимальное поведение демонстрирует обучение QLoRA на 10% датасета при r=16 и модулях q+v.

Таблица вариантов ограничений с предложенной моделью на основе проведенных исследований. Каждое предложение предполагает приемлемое качество модели (не минимальное).

	Минимум памяти	Минимум времени	Минимум объема данных	Высокое качество
Минимум памяти	QLoRA			QLoRA
Минимум времени		Baseline		LoRA
Минимум объема данных			OGLoRA	
Высокое качество				QLoRA

Научная новизна работы

1. .

9. Заключение

ССЫЛКИ:

1. https://arxiv.org/abs/2106.09685
2. https://arxiv.org/abs/2305.14314
3. https://arxiv.org/abs/1509.01626
4. https://ailynx.ru/news/llm/peft-parameter-efficient-fine-tuning-methods-for-llms/
5. https://colab.research.google.com/drive/1B9RsKLMa8SwTxLsxRT8g9OedK10zfBEP?usp=sharing&authuser=1
6. https://huggingface.co/docs/peft/index
7. https://arxiv.org/abs/2303.15647
8. https://arxiv.org/abs/2601.09185
9. https://arxiv.org/abs/2601.06788
10. [2303.10512] AdaLoRA: Adaptive Budget Allocation for Parameter-Efficient Fine-Tuning (https://github.com/QingruZhang/AdaLoRA)
11. https://aclanthology.org/2025.acl-long.99.pdf
12. https://arxiv.org/pdf/2509.25214
13. https://arxiv.org/pdf/2503.12988
14. https://arxiv.org/pdf/2506.18267
15. https://aclanthology.org/2025.findings-emnlp.1372.pdf
16. https://aclanthology.org/2025.coling-industry.55.pdf

Приложения

Приложение А

Результаты экспериментов для модели Qwen2.5-1.5B на датасете AG News

Приложение Б

Результаты экспериментов для модели Qwen3-0.6B на датасете AG News

Приложение В

Результаты экспериментов для модели Qwen3-0.6B на датасете PD News

Приложение Г

Графики на основе результатов экспериментов