



Факультет компьютерных наук

Прикладная математика и
информатика
«Аналитика больших данных»

Москва
2026

Выпускная квалификационная работа:

Исследование методов эффективного применения адаптеров (LoRA) для дообучения моделей в условиях ограниченных вычислительных ресурсов

Студент

О.А. Лемехова

Научный руководитель

Е.А. Паточенко

ст. преп. деп. больших данных и
информационного поиска ФКН НИУ ВШЭ

Соруководитель

Е.В. Гаврилова

Ведущий специалист по науке о данных
ООО Ле Монлид Цифровые Технологии



Актуальность

- Большие языковые модели требуют значительных ресурсов
- Дообучение (fine-tuning) → высокая нагрузка на GPU
- Ограничения:
 - VRAM
 - время обучения
 - доступность оборудования
 - исходный объем данных
- PEFT (LoRA, QLoRA и т.п.) снижает затраты



Проблема

- Эффективность LoRA зависит от параметров:
 - rank
 - target modules
 - квантизация
 - объём данных
- Отсутствуют универсальные рекомендации
- Подбор параметров выполняется эмпирически



Цель и задачи

Цель:

Выявление закономерностей и оптимальных конфигураций методов LoRA.

Задачи:


исследование влияния параметров, выявление закономерностей и поиск компромисса между точностью и ресурсными затратами.




Данные

Задача бенчмарка: классификация коротких текстов

Эталонные: AG_News – новостные заголовки на английском языке, 4 категории по 30000 образцов в каждом классе обучающей выборки и 1900 – в каждом классе тестовой выборки (всего 120000). Классы сбалансированные



Самостоятельно собранные данные с русскоязычных новостных сайтов Санкт-Петербурга fontanka.ru («Фонтанка») и dp.ru («Деловой Петербург»). В каждом классе сформировано 8212 обучающих и 2053 тестовых образцов, всего 41060 образцов.





Экспериментальная среда

1. Бенчмарк: классификация коротких текстов
2. Вычислительные условия: локальная вычислительная система
(GPU: AMD Radeon RX 9070 XT, RAM: 32 GB)
3. Модели для дообучения: Qwen2.5-1.5B , Qwen3-0.6B
4. Методы для исследования: Baseline
LoRA
QLoRA
OrthoGeoLoRA.



Выбранные методы

Baseline (модель с частичным дообучением, обучается только классификационная голова, а остальные параметры остаются замороженными)

LoRA (обновлений весов в виде произведения двух матриц малого ранга ($\Delta W = BA^T$), при этом исходные веса модели остаются замороженными)

QLoRA (квантует веса модели до 4 бит (NF4, FP4), обучает только LoRA-адаптеры)

OrthoGeoLoRA [Wang et al., 2026] (использует разложение вида: $\Delta W = B\Sigma A^T$, где матрицы имеют ортонормированные столбцы)



Серия экспериментов для модификаций LoRA



1. Модели: - Qwen2.5-1.5B , - Qwen3-0.6B
2. Пространство параметров: - Rank: 4, 8, 16, 32
- Наборы модулей: q+v, q+k+v, q+k+v+o
- Типы квантизации для QLoRA: nf4, fp4
3. Объёмы выборки: - 300 / 1500 / 3000 / 8000 / 15000 / 30000
образцов в каждом классе обучающей выборки.
4. Показатели качества: - accuracy, - F1, loss.
5. Вычислительные затраты: - время обучения
- потребление GPU-памяти.

Всего 934 эксперимента с по всем вариантам (от 10 до 120 минут каждый)



Реализация базового подхода

демонстрирует низкую эффективность: увеличение объёма данных не приводит к устойчивому росту качества





Исследование зависимости

- Наибольшее влияние - объём обучающей выборки (0.90)
- Время увеличивается соответственно объёму выборки
- Влияние ранга адаптеров - умеренное (0.25)
- Влияние модулей – слабое (0.11)
- Связь между потреблением GPU-памяти и качеством практически отсутствует (0.06) → возможность эффективной оптимизации вычислительных ресурсов без существенной потери точности.





Ранг-зависимость


Оптимальный rank зависит от объёма данных.

Rank, при котором достигается 99% от максимального значения accuracy:

Объем обучающей выборки, образцов в классе	Ранг
300	32 (плато не достигается)
1500	16
3000	8
8000	4

Модель Qwen2.5 определяется объёмом данных и слабо зависит от параметров адаптера, тогда как Qwen3 демонстрирует более сложное поведение, включая зависимость от rank и его взаимодействия с размером выборки.

Зависимость качества модели от выбора ранга




Влияние LoRA-модулей

(q+v) — оптимальный выбор: лучшее соотношение качество/ресурсы


(q+k+v) — аномалия: добавление k без o снижает качество относительно q+v (для LoRA и OrthoGeoLoRA)

(q+k+v+o) — максимальное качество (+1–2% vs q+v), но рост GPU и времени

Зависимость качества модели от набора модулей






Точечная диаграмма расположения различных конфигураций настроек относительно затратам памяти и времени обучения для Qwen3-0.6B (EN)



LoRA vs QLoRA

- QLoRA сохраняет 98.4% качества LoRA в среднем
- GPU снижается до 71.6% от LoRA (-28%)
- Время обучения растёт на +49% из-за квантования/деквантования
- На малых данных (300): разрыв в ассурасу 8–12% в пользу LoRA
- Порог: при ≥ 1500 примерах разница становится $< 1\%$ и незначима






Сравнение моделей: Qwen2.5 vs Qwen3

Qwen3-0.6B стабильнее и экономичнее;


Qwen3-0.6B точнее на малых данных;

Qwen2.5-1.5B лучше на больших объемах данных, особенно на русском датасете


Потребление памяти для моделей для разных
объемов выборки




Разброс



Accuracy vs Dataset Size for QLoRA (EN)






Accuracy vs Dataset Size for QLoRA (RU)









OrthoGeoLoRA





OrthoGeoLoRA

На малых данных OGLoRA экономит
~38% GPU vs LoRA,
но требует в 1.6× больше времени





Рекомендации по выбору параметров

Сценарий	Данных на класс	Модель	Метод	Ранг	Модули
Мало данных, GPU критично	< 1500	Qwen3-0.6B	OGLoRA	8–16	q+k+v+o
Мало данных, время критично	< 1500	Qwen3-0.6B	LoRA	32	q+v
Достаточно данных, GPU критично	≥ 1500	любая	QLoRA NF4	4–32	q+v
Достаточно данных, скорость важна	≥ 1500	Qwen2.5-1.5B	LoRA	4–16	q+v



Заключение

- Объем данных - главный фактор, но с увеличением объема расет время обучения
- Порог 1500 примеров на класс: до него - методы различаются, после - нет
- Выбор ранга зависит от объема выборки (для LoRA и OGLoRA)
- OGLoRA выигрывает на малых данных по качеству и затратам (+accuracy, -GPU), проигрывает по времени
- QLoRA сохраняет 98% качества LoRA при -28% GPU, но +49% времени
- На больших и «живых» данных Qwen2.5 устойчивее; Qwen3 теряет ~6% accuracy при смене датасета
- Qwen3 устойчивее на малых данных



Выводы

Разработанный подход может использоваться для быстрой классификации текста на основе LLM при ограниченных вычислительных ресурсах, например, классификация в исследовательских работах, классификации в новостных агрегаторах, для задач классификации обращений в поддержку или в государственные органы и т.п.).

Результаты позволяют осознанно выбирать модель, ранг, набор модулей и метод квантизации без полного перебора конфигураций на основе имеющихся данных.

Выявленные зависимости от объёма данных помогают оценить минимально достаточную выборку либо выбрать подход работы с уже имеющимися данными ограниченного объема.

Реализованные эксперименты могут служить бенчмарком для сравнения будущих PEFT-методов, включая OrthoGeoLoRA




Спасибо за внимание !





Поиск наиболее эффективных настроек

Пример для accuracy>0.9






Поиск наиболее эффективного метода

Пример:
данные
образцов
accuracy

EN
300
> 0.88

$$Efficiency = \frac{Accuracy}{GPU * Time}$$






Поиск предпочтительных настроек


Пример:
данные – EN
300 образцов
accuracy > 0.88

Анализ конфигураций при объеме данных 300 (accuracy > 0.88) - EN





OrthoGeoLoRA

Входной вектор x сначала проецируется на ортогональный базис A (шаг 1), затем каждая проекция масштабируется соответствующим сингулярным значением (шаг 2), после чего результат проецируется на выходное пространство через ортогональный базис B (шаг 3). Такая структура обеспечивает максимальную эффективность использования каждого обучаемого параметра, так как между направлениями в пространстве признаков отсутствует корреляция.







Accuracy







GPU

Low data (<1500)



High data (≥ 1500)



Time



Loss





План работы

- Подготовка данных и среды для экспериментов
- Реализация методов (Baseline, LoRA, QLoRA, OrthoGeoLoRA)
- Проведение экспериментов
- Анализ влияния параметров
- Оценка trade-off
- Формирование рекомендаций



Цели и задачи

Цель: выявление закономерностей и определение оптимальных конфигураций методов параметрически эффективного дообучения (LoRA, QLoRA и их модификаций), обеспечивающих наилучший компромисс между точностью и вычислительными затратами (время, VRAM) при работе с языковыми моделями в условиях ограниченной инфраструктуры.

Задачи: исследование влияния параметров методов параметрически эффективного дообучения (LoRA, QLoRA и их модификаций) на качество и вычислительную эффективность языковых моделей, а также выявление закономерностей и количественная оценка компромисса между точностью и ресурсными затратами для определения оптимальных конфигураций в условиях ограниченной инфраструктуры, т.е. для каждой конфигурации из спектра параметров (rank, набор адаптируемых модулей, тип квантизации, объём данных) необходимо оценить одновременно и показатели качества (accuracy, F1) и ресурсоёмкость (VRAM, время обучения).

Задача найти баланс между качеством и ресурсами