



Факультет компьютерных наук

Прикладная математика и
информатика
«Аналитика больших данных»

Москва
2026

Выпускная квалификационная работа:

Исследование методов эффективного применения адаптеров (LoRA) для дообучения моделей в условиях ограниченных вычислительных ресурсов

Студент

О.А. Лемехова

Научный руководитель

Е.А. Паточенко

ст. преп. деп. больших данных и
информационного поиска ФКН НИУ ВШЭ

Соруководитель

Е.В. Гаврилова

Ведущий специалист по науке о данных
ООО Ле Монлид Цифровые Технологии



Актуальность

- Большие языковые модели требуют значительных ресурсов
- Дообучение (fine-tuning) → высокая нагрузка на GPU
- Ограничения:
 - VRAM
 - время обучения
 - доступность оборудования
 - исходный объем данных
- PEFT (LoRA, QLoRA и т.п.) снижает затраты



Проблема

- Эффективность LoRA зависит от параметров:
 - rank
 - target modules
 - квантизация
 - объём данных
- Отсутствуют универсальные рекомендации
- Подбор параметров выполняется эмпирически



Цель и задачи

Цель:

Исследование влияния параметров LoRA-методов на качество и вычислительную эффективность языковых моделей в задачах классификации коротких текстов при ограниченных вычислительных ресурсах.

Задачи:


исследование влияния ранга, набора модулей и размера данных;
выявление закономерностей и поиск компромисса между точностью и ресурсными затратами.




Данные

Задача бенчмарка: классификация коротких текстов

Эталонные: AG_News – новостные заголовки на английском языке, 4 категории по 30000 образцов в каждом классе обучающей выборки и 1900 – в каждом классе тестовой выборки (всего 120000). Классы сбалансированные



Самостоятельно собранные данные с русскоязычных новостных сайтов Санкт-Петербурга fontanka.ru («Фонтанка») и dp.ru («Деловой Петербург»). В каждом классе сформировано 8212 обучающих и 2053 тестовых образцов, всего 41060 образцов.





Экспериментальная среда

1. Бенчмарк: классификация коротких текстов
2. Вычислительные условия: локальная вычислительная система
(GPU: AMD Radeon RX 9070 XT, RAM: 32 GB)
3. Модели для дообучения: Qwen2.5-1.5B , Qwen3-0.6B
4. Методы для исследования: Baseline
LoRA
QLoRA
OrthoGeoLoRA.



Выбранные методы

Baseline (модель с частичным дообучением, обучается только классификационная голова, а остальные параметры остаются замороженными)

Базовый PEFT - LoRA (обновлений весов в виде произведения двух матриц малого ранга ($\Delta W = BA^T$), при этом исходные веса модели остаются замороженными)

Квантованный вариант - QLoRA (квантует веса модели до 4 бит (NF4, FP4), обучает только LoRA-адаптеры)

Современная геометрическая модификация - OrthoGeoLoRA [Wang et al., 2026]
(использует разложение вида: $\Delta W = B\Sigma A^T$, где матрицы имеют ортонормированные столбцы)



Серия экспериментов для модификаций LoRA



1. Модели: - Qwen2.5-1.5B , - Qwen3-0.6B
2. Пространство параметров: - Rank: 4, 8, 16, 32
- Наборы модулей: q+v, q+k+v, q+k+v+o
- Типы квантизации для QLoRA: nf4, fp4
3. Объёмы выборки: - 300 / 1500 / 3000 / 8000 / 15000 / 30000
образцов в каждом классе обучающей выборки.
4. Показатели качества: - accuracy, - F1, loss.
5. Вычислительные затраты: - время обучения
- потребление GPU-памяти.

Всего 934 эксперимента с по всем вариантам (от 10 до 120 минут каждый)



Реализация базового подхода

демонстрирует низкую эффективность: увеличение объёма данных не приводит к устойчивому росту качества





Исследование зависимости

- Наибольшее влияние - объём обучающей выборки (0.90)
- Время увеличивается соответственно объёму выборки
- Влияние ранга адаптеров - умеренное (0.25)
- Влияние модулей – слабое (0.11)
- Связь между потреблением GPU-памяти и качеством практически отсутствует (0.06) → возможность эффективной оптимизации вычислительных ресурсов без существенной потери точности.





Ранг-зависимость


Оптимальный rank зависит от объёма данных.

Rank, при котором достигается 99% от максимального значения accuracy:

Объем обучающей выборки, образцов в классе	Ранг
300	32 (плато не достигается)
1500	16
3000	8
8000	4

Модель Qwen2.5 определяется объёмом данных и слабо зависит от параметров адаптера, тогда как Qwen3 демонстрирует более сложное поведение, включая зависимость от rank и его взаимодействия с размером выборки.

Зависимость качества модели от выбора ранга




Влияние LoRA-модулей

(q+v) — оптимальный выбор: лучшее соотношение качество/ресурсы


(q+k+v) — аномалия: добавление k без o снижает качество относительно q+v (для LoRA и OrthoGeoLoRA, для QLoRA влияние сохраняется)

(q+k+v+o) — максимальное качество (+1–2% vs q+v), но рост GPU и времени

Зависимость качества модели от набора модулей





Точечная диаграмма расположения различных конфигураций настроек относительно затратам памяти и времени обучения для Qwen3-0.6B (EN)



Влияние LoRA-модулей


Набор целевых модулей оказывает более выраженный эффект на память и время обучения, чем ранг. Взаимодействие факторов rank и модулей практически отсутствует, что указывает на аддитивный характер их суммарного вклада в потребление памяти и времени.

Влияние rank и набора модулей на время обучения






LoRA vs QLoRA vs OrthoGeoLoRA




LoRA vs QLoRA vs OrthoGeoLoRA

- QLoRA сохраняет 98.4% качества LoRA в среднем
- GPU снижается до 71.6% от LoRA (−28%)
- Время обучения растёт на +49% из-за квантования/деквантования
- На малых данных (300): разрыв в ассурасу 8–12% в пользу LoRA
- Порог: при ≥ 1500 примерах разница становится $< 1\%$ и незначима
- На малых данных OGLoRA экономит ~38% GPU vs LoRA, но требует в 1.6× больше времени

Time vs Dataset Size - EN



GPU vs Dataset Size - EN






Сравнение моделей: Qwen2.5 vs Qwen3

Qwen3-0.6B стабильнее и точнее на малых данных;

Qwen2.5-1.5B лучше на больших объемах данных, особенно на русском датасете

Qwen3-0.6B быстрее и экономнее





Рекомендации по выбору параметров

Данных на класс	Сценарий	Модель	Метод	Ранг	Модули	Уровень качества (accuracy)	Время обучения, мин	GPU, Гб
300	GPU критично	Qwen3-0.6B	OGLoRA	32	q+v, q+k+v+o	0.85 - 0.89	3.4 - 5.3	2.7 - 2.9
300	время критично	Qwen3-0.6B	LoRA	32	q+v, q+k+v+o	0.82 - 0.88	1.9 - 2.5	3.1 - 4.6
1500-3000	GPU критично	Qwen2.5-1.5B*	QLoRA NF4	16-32	q+v, q+k+v	0.92 - 0.93	7.6 - 12.1 5.3 - 9.0*	3.7 2.5*
1500-3000	время критично	Qwen2.5-1.5B*	LoRA	16-32	q+v	0.91 - 0.93	4.4 - 7.4 4.0 - 6.8*	5.7 3.3*
≥ 8000	GPU критично	Qwen2.5-1.5B*	QLoRA NF4	4-8	q+v	0.93 - 0.94	>27.7 >20*	3.7 2.4*
≥ 8000	время критично	Qwen2.5-1.5B*	LoRA	4-8	q+v	0.93 - 0.94	>17.6	5.9 3.3*

* - для эталонных (высокого качества) данных и для языков менее морфологически сложных можно использовать компактные и более новые модификации моделей (Qwen3-0.6B) с целью экономии памяти и времени на обучение;

** - каждые 1000 образцов в классе добавляет примерно 1.7-2.4 минуты на обучение

Выводы

Разработанный подход может использоваться для быстрой классификации текста на основе LLM при ограниченных вычислительных ресурсах, например, классификация в исследовательских работах, классификации в новостных агрегаторах, для задач классификации обращений в поддержку или в государственные органы и т.п.).

Результаты позволяют осознанно выбирать модель, ранг, набор модулей и метод квантизации без полного перебора конфигураций на основе имеющихся данных.

Выявленные зависимости от объёма данных помогают оценить минимально достаточную выборку либо выбрать подход работы с уже имеющимися данными ограниченного объёма.

Реализованные эксперименты могут служить для сравнения других PEFT-методов



Спасибо за внимание !

