



Факультет компьютерных наук

Прикладная математика и
информатика
«Аналитика больших данных»

Москва
2026

Выпускная квалификационная работа:

Исследование методов эффективного применения адаптеров (LoRA) для дообучения моделей в условиях ограниченных вычислительных ресурсов

Студент

О.А. Лемехова

Научный руководитель

Е.А. Паточенко

ст. преп. деп. больших данных и
информационного поиска ФКН НИУ ВШЭ

Соруководитель

Е.В. Гаврилова

Ведущий специалист по науке о данных
ООО Ле Монлид Цифровые Технологии



Актуальность

- Большие языковые модели требуют значительных ресурсов
- Дообучение (fine-tuning) → высокая нагрузка на GPU
- Ограничения:
 - VRAM
 - время обучения
 - доступность оборудования
 - исходный объем данных
- PEFT (LoRA, QLoRA и т.п.) снижает затраты



Проблема

- Эффективность LoRA зависит от параметров:
 - rank
 - target modules
 - квантизация
 - объём данных
- Отсутствуют универсальные рекомендации
- Подбор параметров выполняется эмпирически



Цель и задачи

Цель:

Выявление закономерностей и оптимальных конфигураций методов LoRA.

Задачи:


исследование влияния параметров, выявление закономерностей и поиск компромисса между точностью и ресурсными затратами.




Данные

Задача бенчмарка: классификация коротких текстов

Эталонные: AG_News – новостные заголовки на английском языке, 4 категории по 30000 образцов в каждом классе обучающей выборки и 1900 – в каждом классе тестовой выборки (всего 120000). Классы сбалансированные



Самостоятельно собранные данные с русскоязычных новостных сайтов Санкт-Петербурга fontanka.ru («Фонтанка») и dp.ru («Деловой Петербург»). В каждом классе сформировано 8212 обучающих и 2053 тестовых образцов, всего 41060 образцов.





Экспериментальная среда

1. Бенчмарк: классификация коротких текстов
2. Вычислительные условия: локальная вычислительная система
(GPU: AMD Radeon RX 9070 XT, RAM: 32 GB)
3. Модели для дообучения: Qwen2.5-1.5B , Qwen3-0.6B
4. Методы для исследования: Baseline
LoRA
QLoRA
OrthoGeoLoRA.



Выбранные методы

Baseline (модель с частичным дообучением, обучается только классификационная голова, а остальные параметры остаются замороженными)

LoRA (обновлений весов в виде произведения двух матриц малого ранга ($\Delta W = BA^T$), при этом исходные веса модели остаются замороженными)

QLoRA (квантует веса модели до 4 бит (NF4, FP4), обучает только LoRA-адаптеры)

OrthoGeoLoRA [Wang et al., 2026] (использует разложение вида: $\Delta W = B\Sigma A^T$, где матрицы имеют ортонормированные столбцы)



Серия экспериментов для модификаций LoRA

1. Модели: - Qwen2.5-1.5B , - Qwen3-0.6B
2. Пространство параметров: - Rank: 4, 8, 16, 32
- Наборы модулей: q+v, q+k+v, q+k+v+o
- Типы квантизации для QLoRA: nf4, fp4
3. Объёмы выборки: - 300 / 1500 / 3000 / 8000 / 15000 / 30000
образцов в каждом классе обучающей выборки.
4. Показатели качества: - accuracy, - F1, loss.
5. Вычислительные затраты: - время обучения
- потребление GPU-памяти.


Всего 934 эксперимента с по всем вариантам (от 10 до 120 минут каждый)




Реализация базового подхода

демонстрирует низкую эффективность: увеличение объёма данных не приводит к устойчивому росту качества


Accuracy vs Dataset Size - EN



Time vs Dataset Size - EN



GPU vs Dataset Size - EN





Исследование зависимости

- Наибольшее влияние - объём обучающей выборки (0.90)
- Время увеличивается соответственно объёму выборки
- Влияние ранга адаптеров - умеренное (0.25)
- Влияние модулей – слабое (0.11)
- Связь между потреблением GPU-памяти и качеством практически отсутствует (0.06) → возможность эффективной оптимизации вычислительных ресурсов без существенной потери точности.





Ранг-зависимость


Оптимальный rank зависит от объёма данных.

Rank, при котором достигается 99% от максимального значения accuracy:

Объем обучающей выборки, образцов в классе	Ранг
300	32 (плато не достигается)
1500	16
3000	8
8000	4

Модель Qwen2.5 определяется объёмом данных и слабо зависит от параметров адаптера, тогда как Qwen3 демонстрирует более сложное поведение, включая зависимость от rank и его взаимодействия с размером выборки.

Зависимость качества модели от выбора ранга




Влияние LoRA-модулей

(q+v) — оптимальный выбор: лучшее соотношение качество/ресурсы


(q+k+v) — аномалия: добавление k без o снижает качество относительно q+v (для LoRA и OrthoGeoLoRA, для QLoRA влияние сохраняется)

(q+k+v+o) — максимальное качество (+1–2% vs q+v), но рост GPU и времени

Зависимость качества модели от набора модулей




Точечная диаграмма расположения различных конфигураций настроек относительно затратам памяти и времени обучения для Qwen3-0.6B (EN)



LoRA vs QLoRA vs OrthoGeoLoRA


Accuracy vs Dataset Size - EN




LoRA vs QLoRA vs OrthoGeoLoRA

- QLoRA сохраняет 98.4% качества LoRA в среднем
- GPU снижается до 71.6% от LoRA (−28%)
- Время обучения растёт на +49% из-за квантования/деквантования
- На малых данных (300): разрыв в ассурасу 8–12% в пользу LoRA
- Порог: при ≥ 1500 примерах разница становится $< 1\%$ и незначима
- На малых данных OGLoRA экономит ~38% GPU vs LoRA, но требует в 1.6× больше времени

Time vs Dataset Size - EN





GPU vs Dataset Size - EN



Сравнение моделей: Qwen2.5 vs Qwen3


Qwen3-0.6B стабильнее и точнее на малых данных;

Qwen2.5-1.5B лучше на больших объемах данных, особенно на русском датасете



Qwen3-0.6B стабильнее и точнее на малых данных;

Qwen2.5-1.5B лучше на больших объемах данных, особенно на русском датасете





Рекомендации по выбору параметров

Сценарий	Данных на класс	Модель	Метод	Ранг	Модули
Мало данных, GPU критично	< 1500	Qwen3-0.6B	OGLoRA	8–16	q+k+v+o
Мало данных, время критично	< 1500	Qwen3-0.6B	LoRA	32	q+v
Достаточно данных, GPU критично	≥ 1500	любая	QLoRA NF4	4–32	q+v
Достаточно данных, скорость важна	≥ 1500	Qwen2.5-1.5B	LoRA	4–16	q+v



Заключение

- Объём данных - главный фактор, но с увеличением объема расет время обучения
- Порог 1500 примеров на класс: до него - методы различаются, после - нет
- Выбор ранга зависит от объема выборки (для LoRA и OGLoRA)
- OGLoRA выигрывает на малых данных по качеству и затратам (+accuracy, -GPU), проигрывает по времени
- QLoRA сохраняет 98% качества LoRA при -28% GPU, но +49% времени
- На больших и «живых» данных Qwen2.5 устойчивее; Qwen3 теряет ~6% accuracy при смене датасета
- Qwen3 устойчивее на малых данных



Выводы

Разработанный подход может использоваться для быстрой классификации текста на основе LLM при ограниченных вычислительных ресурсах, например, классификация в исследовательских работах, классификации в новостных агрегаторах, для задач классификации обращений в поддержку или в государственные органы и т.п.).

Результаты позволяют осознанно выбирать модель, ранг, набор модулей и метод квантизации без полного перебора конфигураций на основе имеющихся данных.

Выявленные зависимости от объёма данных помогают оценить минимально достаточную выборку либо выбрать подход работы с уже имеющимися данными ограниченного объёма.

Реализованные эксперименты могут служить для сравнения других PEFT-методов




Спасибо за внимание !



Поиск наиболее эффективных настроек

Пример для accuracy>0.9






Поиск наиболее эффективного метода

Пример:
данные
образцов
accuracy

EN
300
> 0.88

$$Efficiency = \frac{Accuracy}{GPU * Time}$$






Поиск предпочтительных настроек


Пример:
данные – EN
300 образцов
accuracy > 0.88

Анализ конфигураций при объеме данных 300 (accuracy > 0.88) - EN



OrthoGeoLoRA


Входной вектор x сначала проецируется на ортогональный базис A (шаг 1), затем каждая проекция масштабируется соответствующим сингулярным значением (шаг 2), после чего результат проецируется на выходное пространство через ортогональный базис B (шаг 3). Такая структура обеспечивает максимальную эффективность использования каждого обучаемого параметра, так как между направлениями в пространстве признаков отсутствует корреляция.






OrthoGeoLoRA


Accuracy vs Dataset Size (OGLoRA vs others) - RU



OGLoRA: Accuracy vs Rank (RU)







OGLoRA: Accuracy vs Modules (RU)







OrthoGeoLoRA

На малых данных OGLoRA экономит
~38% GPU vs LoRA,
но требует в 1.6× больше времени







Accuracy







GPU

Low data (<1500)

High data (≥ 1500)





Time





Loss





План работы

- Подготовка данных и среды для экспериментов
- Реализация методов (Baseline, LoRA, QLoRA, OrthoGeoLoRA)
- Проведение экспериментов
- Анализ влияния параметров
- Оценка trade-off
- Формирование рекомендаций



Цели и задачи

Цель: выявление закономерностей и определение оптимальных конфигураций методов параметрически эффективного дообучения (LoRA, QLoRA и их модификаций), обеспечивающих наилучший компромисс между точностью и вычислительными затратами (время, VRAM) при работе с языковыми моделями в условиях ограниченной инфраструктуры.

Задачи: исследование влияния параметров методов параметрически эффективного дообучения (LoRA, QLoRA и их модификаций) на качество и вычислительную эффективность языковых моделей, а также выявление закономерностей и количественная оценка компромисса между точностью и ресурсными затратами для определения оптимальных конфигураций в условиях ограниченной инфраструктуры, т.е. для каждой конфигурации из спектра параметров (rank, набор адаптируемых модулей, тип квантизации, объём данных) необходимо оценить одновременно и показатели качества (accuracy, F1) и ресурсоёмкость (VRAM, время обучения).

Задача найти баланс между качеством и ресурсами